Inhalt:

Kytir, J., Stadler, B.: Die kontinuierliche Arbeitskräfteerhebung im Rahmen des neuen Mikrozensus. Vom „alten“ zum „neuen“ Mikrozensus. STATISTISCHE NACHRICHTEN 6/2004, 511-518.

Haslinger, A., Kytir, J.: Stichprobendesign, Stichprobenziehung und Hochrechnung des Mikrozensus ab 2004. Statistische Nachrichten 6/2006, 510-519.

Moser, W.: Das Datenmanagement im neuen Mikrozensus – Eine Prozessbeschreibung. Austrian Journal of Statistics, Volume 34 (2005), Number 4, 327-343.

Eine Auswahl weiterer Artikel zum Mikrozensus wird auf der Website www.statistik.at unter STATISTIK AUSTRIA - Arbeitsmarkt (Rubrik„Weitere Informationen“) zur Verfügung gestellt.

Die kontinuierliche Arbeitskräfteerhebung im Rahmen des neuen Mikrozensus

Vom „alten" zum „neuen" Mikrozensus

JOSEF KYTIR
BETTINA STADLER

Mit Beginn des Jahres 2004 wurde der seit den frühen 1970er Jahren bestehende Mikrozensus völlig umgestaltet. Um die von der EU an ihre Mitgliedsländer gestellten Anforderungen an die Stichprobe der Europäischen Arbeitskräfteerhebung erfüllen zu können, war es notwendig, den Mikrozensus auf eine neue rechtliche und organisatorische Basis zu stellen. Der vorliegende Beitrag beschreibt das neue, auf der Erwerbs- und Wohnungsstatistikverordnung 2003 beruhende Erhebungskonzept. In weiterer Folge werden die Geschichte sowie die zentralen Begriffe und Definitionen der Europäischen Arbeitskräfteerhebung dargestellt. Ein Ausblick auf das geplante Publikationskonzept der STATISTIK AUSTRIA für die kontinuierliche Arbeitskräfteerhebung rundet den Beitrag ab.

Über dreieinhalb Jahrzehnte hinweg war der Mikrozensus die größte und wichtigste sozialwissenschaftliche Stichprobenerhebung Österreichs.[1]) Basierend auf einer Rechtsgrundlage aus dem Jahr 1967 (BGBl. Nr. 334/1967) wurden seit 1968 Quartal für Quartal (jeweils im März, Juni, September und Dezember) in rund 30.000 privaten Haushalten Erhebungen durchgeführt (Face-to-Face-Befragungen), die Angaben elektronisch erfasst, analysiert und publiziert. Die Erhebung war dabei modular aufgebaut. Ein „Grundprogramm" enthielt die üblicherweise bei einer Volkszählung gestellten Fragen (Geburtsdatum, Geschlecht, Staatsangehörigkeit, Familienstand, Lebensunterhalt, Erwerbstätigkeit, höchste abgeschlossene Ausbildung u.s.w). Für diese Fragen sah die Mikrozensus-Verordnung eine verpflichtende Auskunftserteilung vor. Diese Verpflichtung betraf alle in der Wohnung lebenden, erwachsenen Personen, Proxy-Antworten (von im selben Haushalt lebenden Personen) waren jedoch zulässig. Dazu kamen jeweils wechselnde „Sonderprogramme" zu unterschiedlichen, gesellschaftlich relevanten Themen. Eine Auflistung aller Sonderprogramme der Jahre 1970 bis 2003 findet sich im Internet unter http://www.statistik.at/mikrozensus/start.shtml. Die Beantwortung dieser Fragen erfolgte auf freiwilliger Basis. Mit dem Beitritt Österreichs zur Europäischen Union wurden beginnend mit dem Jahr 1995 jeweils im März die von der EU geforderten Merkmale der Europäischen Arbeitskräfteerhebung (European Labour Force Survey) in Form eines Sonderprogramms erhoben, sofern sie nicht ohnehin durch Fragen des Grundprogramms bereits abgedeckt waren.

Den **Auswahlrahmen für die Stichprobe** des Mikrozensus bildeten die bei der jeweils letzten Volkszählung erhobenen Wohnungen, die um Adressen neu errichteter Wohnungen aus der laufenden Wohnbaustatistik ergänzt wurden. Aus dieser Grundgesamtheit wurde eine nach Bundesland und Gemeindegrößenklasse geschichtete, seit dem Jahr 1984 zusätzlich geklumpte Stichprobe mit ca. 1.100 Samplepoints (=Gemeinden) gezogen. Jede Adresse blieb für insgesamt acht Quartale in der Stichprobe (Achtel-Rotation). Die erhobenen Daten wurden - ergänzt um eine ein Mal jährlich durchgeführte Stichprobenerhebung in Anstaltshaushalten - auf die österreichische Bevölkerung hochgerechnet.

Als **Erhebungsinstrument** dienten scannerfähige Papierbelege. Die Feldphase jeder Erhebung umfasste im Wesentlichen die ersten drei Wochen des letzten Monats im Quartal. Die Rekrutierung, Führung und Betreuung des Interviewerstabes (theoretisch ein Interviewer pro Samplepoint, in der Praxis wurde mitunter mehr als ein Erhebungsgebiet von einem Interviewer betreut) war dezentral organisiert und lag in den Händen der jeweiligen landesstatistischen Dienste. Dazu kamen in unregelmäßigen Abständen Schulungsveranstaltungen durch Mitarbeiter der STATISTIK AUSTRIA.

Für externe Nutzer stehen die **anonymisierten Mikrodaten** aller Mikrozensus-Erhebungen (Grund- und Sonderprogramme) ab dem Jahr 2000 in einer leicht zugänglichen Form als SPSS-Dateien einschließlich aller Meta-Informationen zur Verfügung. Die gesamte Dokumentation sowie ein

[1]) Eine Darstellung der Geschichte des Mikrozensus findet sich in Österreichisches Statistisches Zentralamt (Hrsg.): 25 Jahre Mikrozensus. Symposium am 13. und 14. Oktober 1992. Tagungsbericht. Wien 1993. Für Darstellungen der Methode und der Stichproben siehe Heft 5/1968, S. 316 ff., Heft 6/1968, S. 397 ff., Heft 8/1974, S. 482 ff., Heft 11-12/1984, S. 713 ff. und Heft 4/1996, S. 312 ff.

Subsample aus den Daten (eine drei-prozentige Zufallsstichprobe aller jeweils befragten Haushalte) lassen sich für diese Erhebungen überdies im Internet unter www.statistik.at/mikrozensus/gratis.shtml gratis herunterladen. Die Daten früherer Erhebungen sind zum überwiegenden Teil über das WISDOM beziehbar (www.wisdom.at).

Warum war es notwendig, diese über Jahrzehnte hinweg bewährte Erhebung auf vollkommen neue rechtliche und organisatorische Beine zu stellen? Zunächst sind hier zwei **rechtliche Gegebenheiten** anzuführen:

1. Das Bundesstatistikgesetz 2000 sah das Auslaufen von Rechtsgrundlagen für statistische Erhebungen vor. Zur Schaffung entsprechender neuer Rechtsgrundlagen gab es eine zweijährige Übergangsfrist. Die Mikrozensus-Verordnung aus dem Jahr 1967 trat mit Jahresende 2002 außer Kraft. Im Jahr 2003 wurde der Mikrozensus daher ohne explizite nationale Rechtsgrundlage auf Basis der EU-Verordnungen zur Europäischen Arbeitskräfteerhebung (Verordnung (EG) Nr. 577/98; www.statistik.at/mikrozensus/eu_verordnung.pdf) in allen vier Quartalen mit dem Sonderprogramm „Arbeitskräfteerhebung" durchgeführt. Mit der im November 2003 in Kraft getretenen Erwerbs- und Wohnungsstatistik-Verordnung (EWStV; www.statistik.at/mikrozensus/verordnung.pdf) besitzt der „neue" Mikrozensus nun eine nationale Rechtsgrundlage mit einer entsprechend gesicherten finanziellen Basis.
2. Österreich nützte nach dem Beitritt eine bis Ende 2002 EU-weit geltende Übergangsfrist, um das Stichprobendesign seiner Arbeitskräfteerhebung (also des Mikrozensus) an die geforderten Standards anzupassen. Dies betrifft die Aufteilung der Stichprobe nach Referenzwochen, die den Vorgaben der EU entsprechend, gleichmäßig auf die Kalenderwochen eines Jahres zu verteilen sind (daher: „kontinuierliche Arbeitskräfteerhebung"). Die bereits erwähnte EWStV schreibt dieses Stichprobendesign nun auch auf nationaler Ebene fest.

Die gesamte Organisation des „alten" Mikrozensus war für die Anforderungen einer kontinuierlichen Erhebung allerdings nicht geeignet. Zusätzlich sprach eine Reihe **qualitativer Gründe** für die vollkommene Neuorganisation der Erhebung und Aufarbeitung:

1. Die Organisation der Erhebung und die Aufarbeitung der Daten folgten in ihren wesentlichen Elementen immer noch dem in den frühen 1970er-Jahren entworfenen Muster. Die technologischen Entwicklungen machten eine Neukonzeption daher schon dringend notwendig. Beispielhaft seien etwa die scannerfähigen Papierbelege genannt, die durch ihre diversen technischen Restriktionen nicht mehr den mittlerweile üblichen Qualitätsstandards von Erhebungsinstrumenten für Face-to-Face-Befragungen entsprachen.
2. Die dezentrale Führung des Interviewerstabes hatte neben den zweifellos vorhandenen Vorteilen auch entscheidende Nachteile. So war es nur schwer möglich, einheitliche Qualitätsstandards zu etablieren und zu kontrollieren. Auch die durch die Rekrutierungspraxis traditionell enge Verbindung des Interviewerstabs zu den Verwaltungsapparaten auf Gemeinde-, Bezirks- und Landesebene wurde zunehmend als nicht mehr zeitgemäß empfunden. Dazu kamen manche durch Gesetzesänderungen der vergangenen Jahre hervorgerufenen Probleme im sozialversicherungsrechtlichen Bereich.
3. Mit dem Zentralen Melderegister (ZMR) steht in Österreich seit dem Jahr 2002 eine ständig aktuelle Grundgesamtheit für das Ziehen von Personen- und Wohnungsstichproben zur Verfügung, während die Volkszählung 2001 die wahrscheinlich letzte traditionelle Zählung in Österreich war und Volkszählungsdaten in Zukunft als Auswahlrahmen für Stichproben damit nicht mehr verfügbar sein werden. Trotz der noch bestehenden Qualitätsmängel des ZMR vor allem im Bereich des Wohnungszusammenhangs bietet ein Bevölkerungsregister auf längere Sicht gesehen eine bessere Voraussetzung für Stichprobenerhebungen.
4. Eine Neukonzeption bot im Sinne des Bundesstatistikgesetztes 2000 auch die Chance, die Verbindung der bei den Haushalten erhobenen Daten mit Verwaltungsdaten vorzusehen. Die EWStV schafft dafür die entsprechenden rechtlichen Grundlagen.

Erste konkrete Überlegungen für eine Neukonzeption des Mikrozensus fanden bereits im Jahr 2001 statt. Mitte 2002 wurde ein entsprechendes Planungsprojekt etabliert und parallel dazu der Entwurf für eine neue gesetzliche Basis erstellt. Ein Gesetzentwurf war bis zum Herbst 2002, die Planungen mit Jahresende 2002 im Wesentlichen abgeschlossen. Es dauerte allerdings bis zum September 2003 bis die Verordnung und die darin vorgesehenen finanziellen Zusatzaufwendungen mit dem zuständigen Bundesministerium für Wirtschaft und Arbeit akkordiert waren. In Kraft trat die EWStV schließlich am 28.11.2003. Der Begriff des Mikrozensus findet sich in dieser Verordnung im §6 genannt. Die Bundesanstalt Statistik Österreich wird darin unter dem Titel „Auswahl der Mikrozensus-Stichprobe" verpflichtet, eine Stichprobenerhebung entsprechend Art. 3 der Verordnung (EG) Nr. 577/98 über Arbeitskräfte in der Gemeinschaft in Privat- und Anstaltshaushalten durchzuführen. §8 der EWStV sieht dabei (analog zum Grundprogramm des „alten" Mikrozensus) eine Auskunftspflicht für alle volljährigen Angehörigen der Privathaushalte, die in die Stichprobe einbezogen sind, vor.

Mitte September 2003 lief das Umsetzungsprojekt für die dafür notwendige neue Erhebungsinfrastruktur an, und mit Beginn der 3. Kalenderwoche 2004 wurde der „neue" Mikro-

Brutto-Stichprobengröße (Private Haushalte) des Mikrozensus ab 2004

Bundesland	Pro Quartal			Pro Woche		
	Erst-befragung	Folge-befragung	insgesamt	Erst-befragung	Folge-befragung	insgesamt
Burgenland	350	1.400	1.750	27	108	135
Kärnten	505	2.020	2.525	39	156	195
Niederösterreich	583	2.332	2.915	45	180	225
Oberösterreich	490	1.960	2.450	38	152	190
Salzburg	490	1.960	2.450	38	152	190
Steiermark	552	2.208	2.760	42	168	210
Tirol	490	1.960	2.450	38	152	190
Vorarlberg	490	1.960	2.450	38	152	190
Wien	595	2.380	2.975	46	184	230
Österreich	**4.545**	**18.180**	**22.725**	**350**	**1.400**	**1.750**

Q: Mikrozensus

zensus mit dem Start der Erhebung für das 1. Quartal 2004 aus der Taufe gehoben. **Was ist nun konkret alles „neu"?**

1. Auswahlrahmen für die Stichprobe bilden diejenigen Wohnungen, in welchen jeweils zu Beginn des Vorquartals laut ZMR zumindest eine Person hauptwohnsitzgemeldet war (private Haushalte). Die Stichprobe ist nach Bundesländern geschichtet, aber nicht mehr geklumpt und umfasst pro Quartal österreichweit ca. 22.500 Wohnungen *(siehe Tabelle)*. Die Stichprobengröße orientiert sich an den entsprechenden Vorgaben in Art. 3 der Verordnung (EG) Nr. 577/98. Jedem Haushalt der Stichprobe wird eine Referenzwoche zugeordnet. Die Befragung findet in der Regel in der auf die Referenzwoche folgenden Kalenderwoche statt. Pro Kalenderwoche eines Jahres sind damit rund 1.700 Haushalte in der Stichprobe.
2. Jede Wohnung verbleibt für fünf Erhebungen (also für den Zeitraum eines Jahres) in der Stichprobe (Fünftel-Rotation). Der zeitliche Abstand zwischen zwei Befragungen (Referenzwochen) beträgt jeweils drei Monate.
3. Kommt ein Haushalt neu in die Stichprobe, so erfolgt die erste Befragung Face-to-Face, also durch persönliche Befragung durch einen Interviewer in der Wohnung des Haushalts. Der dafür notwendige flächendeckende Interviewerstab ist zahlenmäßig allerdings wesentlich kleiner (ca. 150 Interviewer) als im „alten" Mikrozensus und wird zentral von der STATISTIK AUSTRIA rekrutiert und geführt. Das Erhebungsinstrument bleibt bis auf weiteres ein Papierfragebogen (www.statistik.at/mikrozensus/stab.shtml), der aber völlig neu konzipiert wurde. Der Umstieg auf CAPI (Computer Assisted Personal Interviewing) wird aller Voraussicht nach in Form eines Pilotprojekts noch 2004 getestet werden.
4. Für die vier Folgebefragungen wurde in der STATISTIK AUSTRIA ein Telefonstudio mit 25 Plätzen eingerichtet. Hier werden die Befragungen in Form des Computer Assisted Telephone Interviewing (CATI) durchgeführt. Als Software kommt dabei das vom Nationalen Statistischen Institut der Niederlande entwickelte Programm BLAISE (www.cbs.nl/en/service/blaise/introduction.htm) zum Einsatz. Telefonstudio, Interviewer- und Respondentenbetreuung bilden zusammen einen eigenen organisatorischen Bereich innerhalb der Direktion Bevölkerung.

Es bleibt zu hoffen, dass sich der Mikrozensus in der neuen Form in ähnlicher Weise bewähren wird, wie dies beim „alten" Mikrozensus über Jahrzehnte hinweg der Fall war.

Die Arbeitskräfteerhebung in der Europäischen Union

Geschichte

Bereits im Jahr 1960 wurde von der damals noch aus sechs Mitgliedern bestehenden Europäischen Gemeinschaft die erste Arbeitskräfteerhebung durchgeführt.[2]) Hierbei handelte es sich vorerst um eine einmalige Erhebung. Beginnend mit dem Ende der 1960er-Jahre wurden in verschiedenen Mitgliedsländern jährliche oder zweijährliche Arbeitskräfteerhebungen organisiert, doch gab es bis 1982 keine einheitliche Erhebung in allen damaligen Mitgliedsländern. Ein wichtiger Schritt wurde durch eine 1982 von der Konferenz der Arbeitsstatistiker unter der Schirmherrschaft der Internationalen Arbeitsorganisation (ILO) verabschiedete Resolution gesetzt.[3]) Darin wurden verschiedene, von der Arbeitskräfteerhebung erfasste Gruppen, nämlich Aktive Bevölkerung, Erwerbstätige, Arbeitslose und Unterbeschäftigte exakt definiert. Ab 1983 wurde in der EG eine jährliche Arbeitskräfteerhebung organisiert. Im Jahr 1991 kam es zu einer Revision der Arbeitskräfteerhebung, und es wurden erstmals regionale Gliederungskriterien aufgenommen.

Im Zuge des Einigungsprozesses und dem Wandel der EU von einer reinen Wirtschaftsgemeinschaft zu einer politischen und sozialen Gemeinschaft haben vergleichbare Daten über die jeweiligen nationalen Arbeitsmärkte stark an Bedeutung gewonnen. Durch die laufende Entwicklung von international gültigen Klassifikationssystemen für Wirtschaftsklassen (NACE), Berufe (ISCO) und Bildungsgänge und -abschlüsse (ISCED) ist eine Basis für den Vergleich von Ergebnissen leichter herstellbar. Um auch vertiefende Analysen zu einzelnen aktuellen oder politisch besonders bedeutsamen Themen möglich zu machen, werden seit dem Jahr 2000 jährlich über das laufende Programm der Arbeitskräfteerhebung hinaus so genannte Ad-hoc-Module durchgeführt (Näheres vgl. unten).

Die EU legt für die nationalen Erhebungen (einschließlich der Ad-hoc-Module) zwar Konzepte und Ausprägungen fest, nicht aber die konkrete Frageformulierung. Zusätzlich ist zum Teil die Reihenfolge, in der die Fragen zu stellen sind, vorgegeben. Beispielsweise müssen die Fragen zur Erwerbs-

[2]) Vgl. The European Commission: The European Labour Force Survey. Methods and Defintions 2001, Luxembourg 2003 (www.eu-datashop.de/download/EN/spezial/lfs/methoden.pdf).
[3]) Das genannte Dokument findet sich unter: www.ilo.org/public/english/bureau/stat/res/ecacpop.htm.

Erwerbstätigkeit nach Labour-Force-Konzept

Übersicht 1

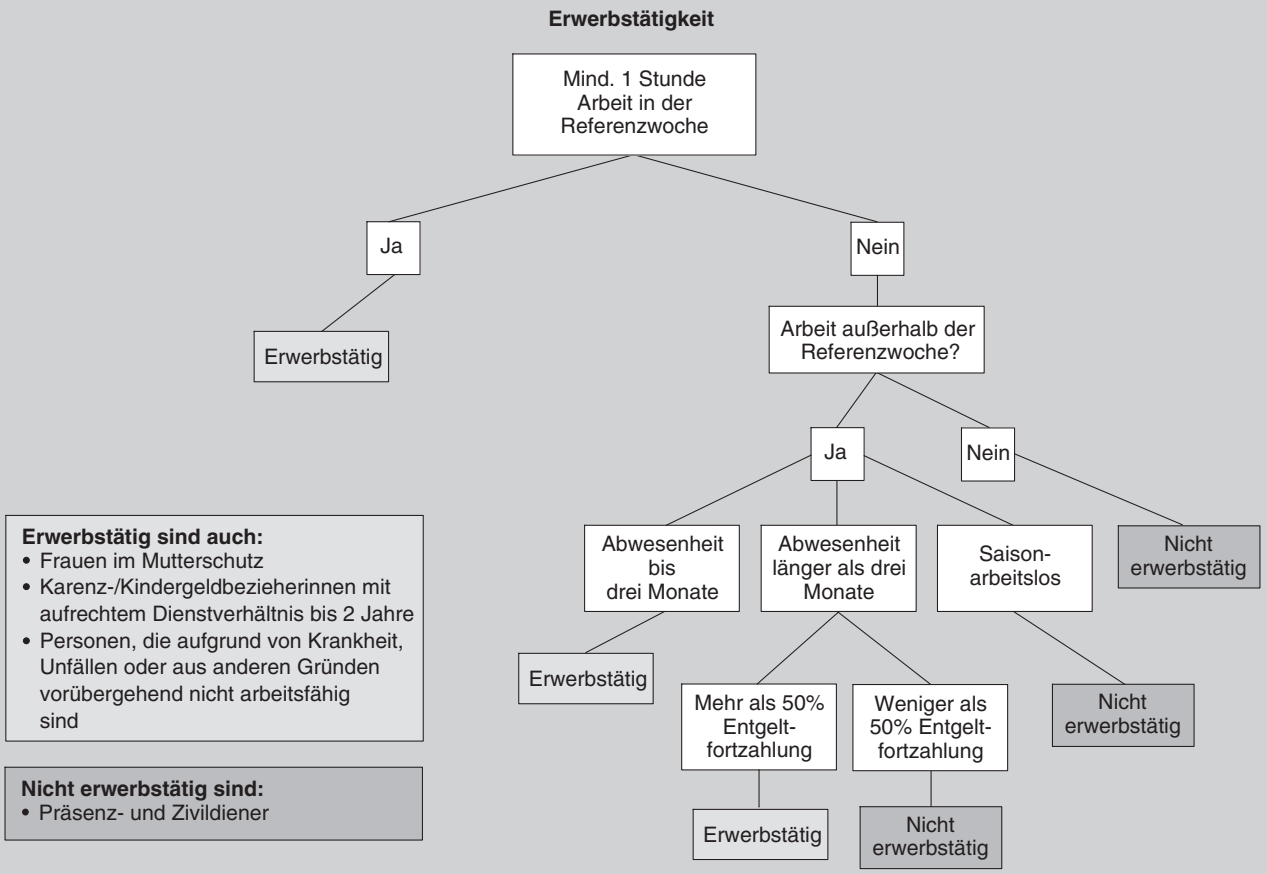

tätigkeit nach dem Labour-Force-Konzept (LFK) gleich nach den demographischen Fragen gestellt werden. Die Frage nach dem Lebensunterhalt darf erst nach den Fragen zur Erwerbstätigkeit nach LFK gestellt werden etc. Jedes Mitgliedsland ist schließlich verpflichtet, die erhobenen Daten eines Quartals spätestens drei Monate nach Quartalsende in Form eines sog. „Standard Recode Files" an EUROSTAT zu übermitteln.

Zentrale Konzepte und Definitionen der Arbeitskräfteerhebung

Die grundlegenden Konzepte der Arbeitskräfteerhebung wurden - wie bereits erwähnt - 1982 von der Konferenz der Arbeitsstatistiker im Rahmen der ILO beschlossen. Von der Europäischen Union wurden diese Definitionen adaptiert, in manchen Punkten genauer und in anderen Punkten im Vergleich zur Handhabung in einigen außereuropäischen OECD-Staaten etwas weniger restriktiv ausformuliert. Damit kam es auch zu einigen kleineren Abweichungen von den Definitionen der ILO. So werden Personen, die Güter und Dienstleistungen für den eigenen Haushalt produzieren, von der Europäischen Union nicht als erwerbstätig betrachtet.

Grundsätzlich werden alle Befragten, die in der Befragungswoche das 15. Lebensjahr erreichen, nach dem Labour-Force-Konzept einer der folgenden drei Gruppen zugeordnet: Erwerbstätige, Arbeitslose und Nicht-Erwerbspersonen. Auf die Definition dieser drei Gruppen wird im Folgenden näher eingegangen. Wichtig zu beachten ist, dass die Zuordnung zu den einzelnen Gruppen nicht der im Alltag verbreiteten Einschätzung und daher in manchen Fällen auch nicht der Selbsteinschätzung der Befragten entspricht, wie sie im Lebensunterhaltskonzept (LUK) abgefragt wird[4])

Übersicht 1 gibt das für die Arbeitskräfteerhebung von EUROSTAT verwendete Konzept von **Erwerbstätigkeit** wieder. Zentral ist hier die Frage, ob eine Person in der Referenzwoche gearbeitet hat. Mit Erwerbstätigkeit ist grundsätzlich Arbeit gegen Bezahlung als unselbständig oder selbständig Beschäftigter, aber auch Arbeit von mithelfenden Angehörigen bei Selbständigen gemeint.[5]) Wenn jemand in der Referenzwoche mindestens eine Stunde gegen Bezahlung oder als Mithelfender gearbeitet hat, oder zwar in der Referenzwoche nicht gearbeitet hat, aber sonst erwerbstätig ist, zählt die Person als erwerbstätig. Dauert die Abwesenheit vom Arbeitsplatz länger als drei Monate, wird

[4]) Eine entsprechende Frage wird im Rahmen der AKE ebenfalls gestellt.
[5]) Mithelfende Angehörige gibt es beispielsweise in bäuerlichen Betrieben in der Landwirtschaft oder bei Gewerbetreibenden.

eine Person nur mehr als erwerbstätig betrachtet, wenn sie mindestens 50% des Entgelts weiterbezahlt bekommt.[6]) Jedenfalls als erwerbstätig gelten Frauen in Mutterschutz und Personen in Elternkarenz[7]) sowie Personen, die aufgrund von Krankheit, Unfällen oder aus anderen Gründen nur vorübergehend nicht arbeitsfähig sind.

Arbeitslosigkeit wird definiert als nicht erwerbstätig (im Sinne der voranstehenden Definition), aktiv Arbeit suchend und für den Arbeitsmarkt (innerhalb der nächsten beiden Wochen) verfügbar. In *Übersicht 2* findet sich eine schematische Darstellung dieses Konzepts.

Konkret umfasst der ILO-Standard **drei Kriterien** für die Feststellung von Arbeitslosigkeit. Es wird gefragt, ob

- jemand in der Referenzwoche nicht gearbeitet hat, die Personen also weder (unselbständig, selbständig oder als Mithelfender) erwerbstätig war, noch sonst eine Stunde oder mehr einer bezahlten Beschäftigung nachgegangen ist,
- gegenwärtig für eine Beschäftigung verfügbar ist, d.h. entsprechend der EU-Vorgabe innerhalb der beiden auf die Referenzwoche folgenden Wochen eine selbständige oder unselbständige Tätigkeit aufnehmen könnte[8]) und
- aktive Schritte zur Arbeitsuche[9]) unternommen hat (die bloße Meldung beim Arbeitsmarktservice, um Arbeitslosengeld zu beantragen, reicht dabei nicht aus).

[6]) Um die Zahl der Erwerbstätigen außerhalb der Saison nicht künstlich zu erhöhen, werden Saisonarbeitslose, auch wenn sie weniger als drei Monate nicht an ihrem Arbeitsplatz sind (und sonst keiner Beschäftigung nachgehen), als nicht-erwerbstätig betrachtet.

[7]) In dieser Gruppe werden Personen gezählt, die Karenz- oder Kinderbetreuungsgeld beziehen, ein aufrechtes Dienstverhältnis haben und deren Abwesenheit vom Arbeitsplatz nicht länger als zwei Jahre dauert.

[8]) Im Gegensatz dazu wird in manchen außereuropäischen OECD-Ländern eine sofortige Verfügbarkeit verlangt.

[9]) Konkret ist mit aktiver Arbeitssuche eine der folgenden Aktivitäten gemeint:
- Kontakt mit dem Arbeitsmarktservice mit dem ausdrücklichen Ziel einen Arbeitsplatz zu finden;
- Kontakt mit privaten Stellenvermittlern;
- Bewerbung bei möglichen Arbeitgebern;
- Freunde, Bekannte, Interessensvertretungen usw. nach Stellen fragen;
- Stellenanzeigen aufgeben oder auf solche antworten;
- Studium von Stellenanzeigen;
- Bewerbungsgespräche führen oder Tests ablegen;
- Suche nach Geschäftsräumen oder Anschaffen von Ausrüstung für eine selbständige Tätigkeit;
- Bemühen um Genehmigungen, Konzessionen oder Geldmittel für eine selbständige Tätigkeit.

Arbeitslosigkeit nach Labour-Force-Konzept

Übersicht 2

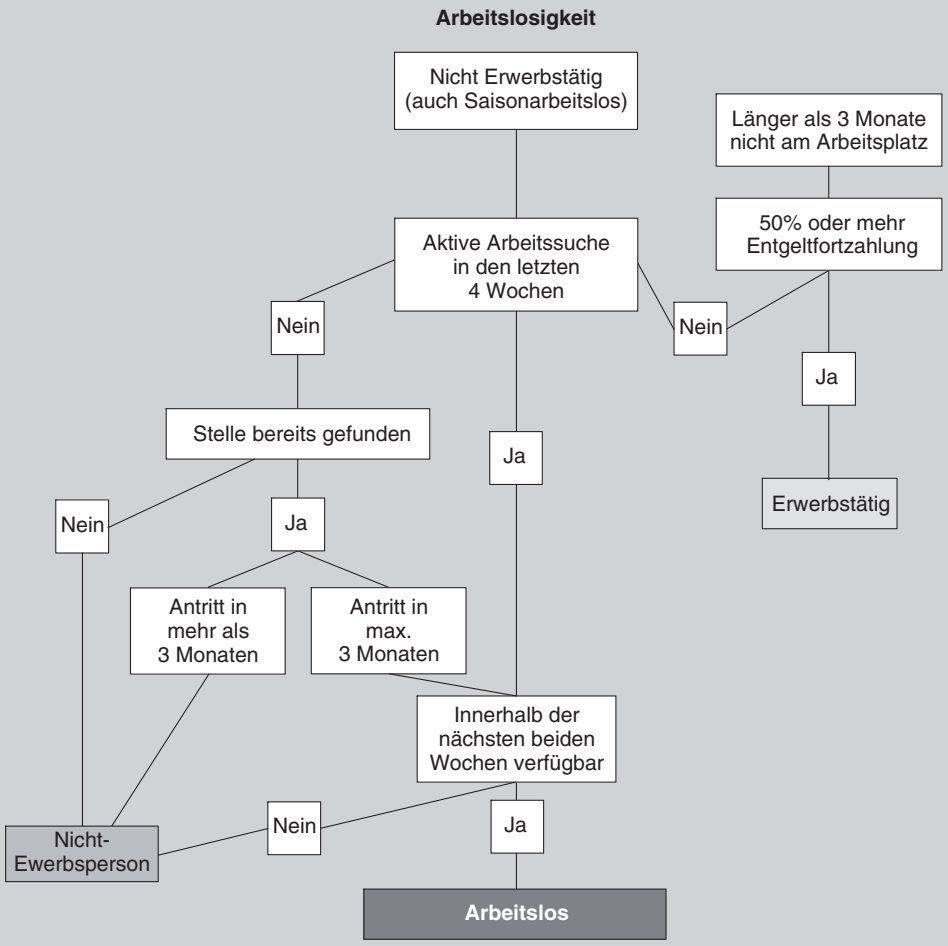

Nicht-Erwerbspersonen nach Labour-Force-Konzept

Übersicht 3

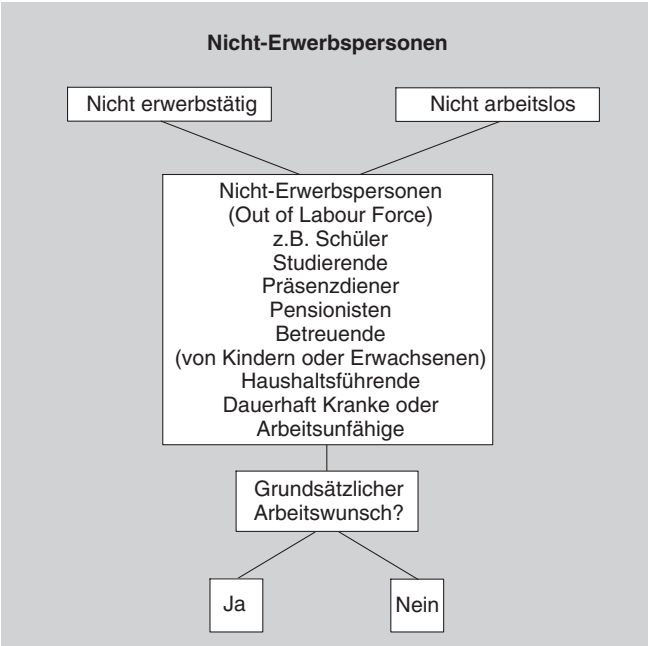

Personen, die keine aktiven Schritte zur Arbeitsuche gesetzt haben, weil sie bereits einen neuen Arbeitsplatz gefunden haben, gelten als arbeitslos, wenn sie diese Stelle in längstens drei Monaten antreten werden, (theoretisch) aber auch schon innerhalb der nächsten zwei Wochen verfügbar wären.[10])
Für Saisonarbeitslose gelten die gleichen Kriterien der Arbeitsuche wie für alle anderen Personen ohne Arbeit.
Im engeren Wortsinn wird nach der EU-Definition somit Arbeitslosigkeit mit aktiver Arbeitsuche gleichgesetzt, schließt also bestimmte Personenkreise, die man durchaus auch als arbeitslos betrachten könnte, nicht mit ein: Z.B. werden Menschen, die zwar grundsätzlich gerne arbeiten möchten, aber nicht aktiv auf Arbeitsuche sind, den Nicht-Erwerbspersonen zugeordnet.

Übersicht 3 bildet die dritte nach dem Labour-Force-Konzept festgelegte Gruppe ab: die **Nicht-Erwerbspersonen**. Hierbei handelt es sich um all jene, die weder als erwerbstätig noch als arbeitsuchend klassifiziert werden. Daraus folgt, dass sich hier sehr unterschiedliche Personen wieder finden. Dies reicht von Schülern über Haushaltsführende bis zu Pensionisten. Menschen, die wegen der Betreuung von Kindern oder Erwachsenen keine Arbeit suchen oder keine Arbeit aufnehmen können, die wegen Krankheit oder Arbeitsunfähigkeit keine aktiven Schritte unternehmen und die auf Ergebnisse von früheren aktiven Schritten warten, finden sich hier ebenso wie Personen, die glauben, dass es für sie keine geeignete Arbeit gibt („Entmutigte"), die also die aktive Arbeitsuche aufgegeben haben. Auch Personen, die schon eine Stelle gefunden haben oder auf ihren früheren Arbeitsplatz zurückkehren, ihre Arbeit aber nicht innerhalb von drei Monaten aufnehmen, werden den Nicht-Erwerbspersonen zugeordnet. Präsenz- und Zivildiener werden getrennt erfasst und zählen lt. EU-Konzept ebenfalls zu den Nicht-Erwerbspersonen

Allen diesen unterschiedlichen Personengruppen (mit Ausnahme derer, die in Zukunft eine Arbeit aufnehmen werden) wird die Frage gestellt, ob sie grundsätzlich gerne arbeiten wollen und innerhalb der nächsten beiden Wochen beginnen könnten. Daraus geht hervor, wie groß die „Stille Reserve" auf dem Arbeitsmarkt ist.

Mit Hilfe der so gebildeten **Kategorien** können in weiterer Folge verschiedenste Kennzahlen errechnet werden. Die wichtigsten werden hier kurz dargestellt:

Die **Erwerbsbevölkerung (Erwerbspersonen)** nach dem Labour-Force-Konzept besteht aus der Summe der Erwerbstätigen und der Arbeitslosen. Die so definierte Gruppe unterscheidet sich natürlich von der nach dem Lebensunterhaltskonzept (LUK), also auf Basis einer Selbsteinschätzungsfrage, gebildeten Erwerbsbevölkerung.

Die **Erwerbstätigenquote** ist der Anteil der Erwerbstätigen an allen Personen im erwerbsfähigen Alter. Die Altersgrenze kann hier nach verschiedenen Definitionen festgelegt werden. Für Berechnungen von EUROSTAT wird meist die Altersgruppe von 15 bis 64 Jahren herangezogen. Die Erwerbstätigenquote wird von Schwankungen der Zahl der Arbeitslosen nicht beeinflusst und ist somit ein stabilerer Wert. Sie gibt Auskunft über den Anteil der Angehörigen einer Altersgruppe, die tatsächlich erwerbstätig sind.

Mit der **Erwerbsquote** wird der Anteil der Erwerbsbevölkerung (Erwerbstätige und Arbeitslose) an der Bevölkerung im erwerbsfähigen Alter abgebildet. Hierbei handelt es sich um eine in letzter Zeit international weniger gebräuchliche Messzahl. In Österreich werden beide Werte parallel verwendet. Im Gegensatz zur Erwerbstätigenquote wird die Erwerbsquote von einem Anstieg bzw. einem Rückgang der Arbeitslosigkeit beeinflusst. Die Erwerbsquote informiert darüber, welcher Anteil der Personen im erwerbsfähigen Alter aktiv ist oder zu sein anstrebt.

Die **Arbeitslosenquote nach EU-Berechnung** ist der Anteil der Arbeitslosen an der Erwerbsbevölkerung. Hier gibt es eine Alterseinschränkung auf die Bevölkerung im Alter von 15 bis 74 Jahren.

Im Gegensatz dazu wird für die **Arbeitslosigkeit nach nationaler Berechnungsmethode** als arbeitslos angesehen, wer beim Arbeitsmarktservice vorgemerkt ist. Zur Berechnung der Arbeitslosenquote wird die Zahl der vorgemerkten Arbeitslosen mit dem Arbeitskräftepotential in Beziehung gesetzt. Das Arbeitskräftepotential ist die Summe aus den arbeitslos Gemeldeten und den unselbständig Beschäftigten laut Hauptverband der Sozialversicherungsträger. Somit unterscheiden sich die beiden Berechnungsmethoden so-

[10]) Wer z.B. aufgrund einer Krankheit erst später zu arbeiten beginnen kann, wird nicht als arbeitslos betrachtet.

Arbeitslosenquote: Vergleich nach EU-Berechnung und nationaler Berechnung

Übersicht 4

Definitionen	EU-Berechnung	AMS-Berechnung
Definition Erwerbstätige	**Erwerbstätige nach Labour-Force-Konzept:** Unselbständig Beschäftigte, Selbständige, Freie Dienstnehmer, Mithelfende Familienangehörige, Geringfügig Beschäftigte	**Unselbständig Erwerbstätige lt. Hauptverband der Sozialversicherungsträger:** Arbeiter, Angestellte und Beamte
		Nicht enthalten sind: Selbständige, Freie Dienstnehmer, Mithelfende Familienangehörige, Geringfügig Beschäftigte
Definition Arbeitslose	**Arbeitslose nach Labour-Force-Konzept:** Nicht Erwerbstätige, die in den letzten vier Wochen aktiv Arbeit gesucht haben und innerhalb von zwei Wochen für eine Arbeitsaufnahme verfügbar sind	**Beim AMS als arbeitsuchend vorgemerkte Personen**, die nicht in Beschäftigung oder Ausbildung (Schulung) stehen

Q: Mikrozensus

wohl hinsichtlich des Nenners als auch des Zählers. Dies wird in der *Übersicht 4* nochmals verdeutlicht.

Es gibt **zwei Gründe, warum sich die nationale Arbeitslosenquote auf einem anderen Niveau bewegt als die Arbeitslosenquote nach EU-Definition.** Erstens erfasst die nationale Berechnung als arbeitslos Gemeldete, die nach EU-Definition nicht (mehr) aktiv Arbeit suchen, sowie solche, die gleichzeitig geringfügig erwerbstätig sind. Nicht enthalten sind andererseits aktiv Arbeitsuchende, die nicht beim Arbeitsmarktservice vorstellig werden. Zweitens ist die Referenzgruppe (der „Nenner") nach nationaler Berechnung kleiner. Selbständige, geringfügig Beschäftigte und freie Dienstnehmer sind nicht in der nationalen Definition der Erwerbstätigen lt. Hauptverband der Sozialversicherungsträger enthalten. Im Gegensatz dazu werden für die EU-Berechnung auch Menschen, die nur gelegentlich[11]) oder nur in geringem Umfang erwerbstätig sind, mit einbezogen. Was die Abbildung der Arbeitslosigkeit betrifft, unterliegen somit beide Konzepte bestimmten Restriktionen.

Neben der Berechnung der zentralen Kennwerte werden mit der **Arbeitskräfteerhebung viele weitere Aspekte des Arbeitslebens abgedeckt.** Dies beginnt mit der genauen Beschreibung der Art, des Umfangs und der Branche der Erwerbstätigkeit. Alle Arbeitsuchenden, jene, die derzeit einer Beschäftigung nachgehen, und jene, die zum Zeitpunkt der Befragung nicht erwerbstätig sind, werden genauer nach der gesuchten Stelle, nach der Dauer der Arbeitsuche, nach den zur Arbeitsuche unternommenen Schritten, nach der Einschreibung beim Arbeitsmarktservice und dem Erhalt von Leistungen durch das AMS gefragt. Personen, die keine Arbeit suchen, werden nach dem Grund dafür gefragt. Schrittweise an Bedeutung gewonnen haben Fragen nach der Ausbildung, sei es nun im regulären Schulwesen oder als (Fort-)Bildung in anderer Form. Menschen, die nicht (mehr) erwerbstätig sind, werden ersucht, über eventuell vorhandene frühere Beschäftigungen Auskunft zu geben. Schließlich wird noch auf die Erwerbssituation vor einem Jahr zurückgeblickt. Den Hintergrund für Analysen liefern detaillierte soziodemographische Merkmale.

[11]) Menschen, die nur selten arbeiten, aber in der Referenzwoche gearbeitet haben, werden zu den Erwerbstätigen gezählt, auch wenn sie sonst nicht arbeiten.

Inhaltliche Erweiterungen in Österreich ab 2004

In den letzten Jahrzehnten sind die für einige Zeit sehr stabilen Arbeitsmärkte in Bewegung geraten. Zu den sog. „Normalarbeitsverhältnissen" kamen unterschiedlichste neue Arbeitsformen hinzu. Der Wandel der Rollen von Männern und Frauen in der Gesellschaft spiegelt sich auch auf den Arbeitsmärkten wieder, und die durchschnittliche Dauer von Beschäftigungsverhältnissen sinkt zunehmend. Aufgrund dieser Veränderungen muss auch das Frageprogramm der Arbeitskräfteerhebung immer wieder an neue Entwicklungen angepasst, d.h. neue Fragen aufgenommen, werden.

Die wichtigsten mit 2004 in Österreich **neu hinzukommenden Fragen** aus dem Programm von EUROSTAT sind folgende:[12])

- Beteiligung des Arbeitsmarktservice beim Finden einer neuen Stelle: Personen, die erst kürzlich (d.h. maximal vor einem Jahr) eine neue Stelle gefunden haben, werden gefragt, ob sie diese mit Unterstützung des AMS gefunden haben. So kann die Bedeutung der Vermittlungstätigkeit des Arbeitsmarktservice eingeschätzt oder untersucht werden, in welchen Branchen oder Berufen diese Form der Unterstützung von großer bzw. von geringer Bedeutung ist.
- Eines der politischen Ziele der Europäischen Union ist es, die Erwerbsbeteiligung von Frauen zu erhöhen. Um in diesem Zusammenhang mehr Informationen über den Bedarf an Betreuungseinrichtungen zu gewinnen, werden Nicht-Erwerbspersonen und Teilzeitbeschäftigte (Männer und Frauen) gefragt, ob sie bei Vorhandensein von Betreuungseinrichtungen grundsätzlich arbeiten bzw. mehr arbeiten möchten.
- Anstellung bei einer Leih- oder Zeitarbeitsfirma: Da diese Form der Beschäftigung in manchen Branchen zunehmend an Bedeutung gewinnt, wird eine entspre-

[12]) Die Darstellung orientiert sich hier an der Umsetzung in Österreich. Mit der Umstrukturierung des Mikrozensus und der Arbeitskräfteerhebung werden Fragen hier erst mit Verzögerung eingeführt; teilweise werden erst später vorgeschriebene Änderungen vorgezogen. Die im Folgenden beschriebenen Änderungen sind zwar schon in einer gültigen Rechtsverordnung festgelegt, es fehlt aber noch eine Durchführungsverordnung der Europäischen Kommission.

chende Frage nun auch in das Programm der Arbeitskräfteerhebung aufgenommen.

- Bisher wurde nach der Anzahl der normalerweise geleisteten Überstunden gefragt. Durch das Konzept der gleichmäßig auf das Jahr verteilten Referenzwochen kann jetzt nach den in diesem Zeitraum tatsächlich gearbeiteten Überstunden gefragt werden. Daraus können in weiterer Folge exaktere Schlüsse über die Anzahl der im Jahresverlauf anfallenden Überstunden gezogen werden.
- Leitungsfunktion: Alle unselbständig Erwerbstätigen werden gefragt, ob sie im Rahmen ihrer Tätigkeit Leitungsfunktionen ausüben. Damit ist nicht nur eine konkrete Managementposition gemeint, sondern die dauerhafte Anleitung von Mitarbeitern.

Zu den Fragen nach der normalen Arbeitszeit und der konkreten Arbeitszeit in der Referenzwoche kommt eine Selbsteinschätzungsfrage, ob jemand **Vollzeit oder Teilzeit** arbeitet, hinzu. Der Grund für diese Erweiterung ist, dass die Wahrnehmung, ob jemand vollzeit- oder teilzeitbeschäftigt ist, je nach Branche und Tätigkeit unterschiedlich sein kann. So gibt es Kollektivverträge oder Betriebsvereinbarungen, nach denen 35 Stunden pro Woche die Normalarbeitszeit darstellen, was in anderen Bereichen als Teilzeitbeschäftigung angesehen würde.

Anlässlich der Neustrukturierung der Erhebung wurden Anstrengungen unternommen, um einige für Österreich wichtige Themen besser abzubilden.
Die stark an Bedeutung gewinnenden **atypischen Beschäftigungsformen** werden nun viel genauer erhoben. So wurden die Ausprägungen der Stellung im Beruf um „freie Dienstnehmer“ erweitert. Bei den Selbständigen wurden die Kategorien „Neue Selbständige“ und „Gewerbescheinbesitzer“ aufgenommen. Dadurch wird es in Zukunft möglich, die Entwicklung in diesem boomenden Bereich genau zu beobachten.

Seit der Einführung des **Kinderbetreuungsgeldes** mit Beginn 2002 ist es für Personen, die nicht in einem aufrechten Beschäftigungsverhältnis stehen, möglich, nach der Geburt eines Kindes Geldleistungen zu beziehen. Dies können jetzt z.B. auch Studierende sein. Bis zu diesem Zeitpunkt war der Erhalt von Karenzgeld an vorhergehende Erwerbstätigkeit gebunden. Diese Änderung im österreichischen Recht macht es notwendig, bei der Befragung genauer zu unterscheiden, ob die Bezieherinnen von Kinderbetreuungsgeld von einem Beschäftigungsverhältnis karenziert sind. Alle Bezieher von Kindergeld zu den Erwerbstätigen zu zählen, würde deren Zahl künstlich erhöhen.

Ad-hoc-Module

Wie schon bisher besteht die Arbeitskräfteerhebung aus einem Grundprogramm und einem jährlich wechselnden, jeweils im 2. Quartal eines Jahres in allen Ländern der EU auf Basis einer entsprechenden Verordnung der Europäischen Kommission durchgeführten Sonderteil (dem sog. „Ad-hoc-Modul“). Diese Module konzentrieren sich stets auf einzelne aktuelle Themen. Im Jahr 2004 sind dies Sonderformen der Arbeitszeit. Hier werden die Befragten ersucht, genauer zu berichten, wie weit sie ihre Arbeitszeit frei gestalten können, ob sie Formen von variabler Arbeitszeit in Anspruch nehmen und wie eventuell vorhandene Teilzeitbeschäftigungen geregelt sind. Im Ad-hoc-Modul des Jahres 2005 geht es um das Thema Vereinbarkeit von Beruf und Familie, und das Ad-hoc-Modul des Jahres 2006 ist Fragen des Übergangs vom Erwerbsleben in den Ruhestand gewidmet.

Die Fragen des Ad-hoc-Moduls „Arbeitszeit“ werden im 2. Quartal 2004 in Österreich aufgrund der Vorgaben der EU hinsichtlich der Stichprobengröße nicht an alle Personen der Stichprobe, sondern nur an die mittels CATI (also telefonisch) befragten Haushalte gestellt. Die Beantwortung der Fragen des Ad-hoc-Moduls ist den Befragten überdies freigestellt.

Nationales Publikationskonzept

Die neue Organisation der Erhebung macht es möglich, sehr schnell nach Ende der Referenzperiode Ergebnisse zu veröffentlichen. Nach wie vor bestehende Verzögerungen entstehen durch Rücklauf- und Erfassungszeiten der persönlichen Interviews und die notwendigen Qualitätskontrollen.
Beginnend mit Ende Juni 2004 werden vierteljährlich Quartalsberichte mit den Daten des Vorquartals veröffentlicht. Diese Berichte können dann von der Homepage der STATISTIK AUSTRIA herunter geladen werden. Zusätzlich werden ab Herbst 2004 rasch verfügbare Monatsberichte mit den wichtigsten Kennzahlen zur Verfügung stehen. Diese werden ebenfalls zum Download angeboten.

Summary

Since the early 1970ies STATISTIK AUSTRIA has been conducting its micro-census. To meet the requirements of the European Union labour force survey the micro census had to be completely reorganized. On the one hand it had to be put on a new legal footing - namely the “Erwerbs- und Wohnungsstatistikverordnung 2003” 2003 regulation on employment and housing statistics. On the other hand the organisation of the survey had to be changed. Therefore in January 2004 the new micro-census was initiated. In its first part this article describes the new survey design. Subsequently the history, main concepts and definitions of the labour force survey are presented. Finally the future publication concept of the new labour force survey is lined out.

Stichprobendesign, Stichprobenziehung und Hochrechnung des Mikrozensus ab 2004

ALOIS HASLINGER
JOSEF KYTIR

Mit Anfang des Jahres 2004 wurde der Mikrozensus grundlegend umgestaltet. Der vorliegende Artikel gibt einen Überblick über methodische und praktische Aspekte des Stichprobendesigns, der Stichprobenziehung und Hochrechnung des „neuen" Mikrozensus. Dem Mikrozensus liegt eine einfach geschichtete (Bundesländer) Zufallsstichprobe zugrunde. Als Auswahlrahmen für die Ziehung der Stichprobeneinheiten (private Haushalte) dient ein quartalsweise aktualisierter Datenabzug aller hauptwohnsitzgemeldeten Personen aus dem Zentralen Melderegister. Die Ausschöpfung der Stichprobe lag 2005 bei rund 90%. Die Hochrechung wird an die Bevölkerungsstände des Bevölkerungsregisters der STATISTIK AUSTRIA und an die Haushaltsprognose gebunden und erfolgt technisch mittels des Verfahrens der iterativen proportionalen Anpassung. Zur Abschätzung des relativen Stichprobenfehlers von absoluten Personen- und Wohnungshäufigkeiten werden Näherungsverfahren vorgestellt. Für einige zentrale Schätzwerte des Mikrozensus (z.B. Zahl der Arbeitslosen) wurde eine genauere Fehlerrechnung durchgeführt, die zeigt, dass das Design des Mikrozensus die von der EU geforderten Genauigkeitsvorgaben erfüllt.

Aus formalen (rechtlichen) Gründen, aber auch aus Qualitätsüberlegungen heraus, war es notwendig geworden, Österreichs größte Stichprobenerhebung, den Mikrozensus, mit Jahresbeginn 2004 vollständig neu zu gestalten.[1]) Die Umstellungen betrafen auch das Stichprobendesign und die Stichprobenziehung sowie die Hochrechnung der erhobenen Daten. Der vorliegende Beitrag dokumentiert diese Veränderungen.

Generell dient der Mikrozensus ab dem 1. Quartal 2004 im Wesentlichen zwei Zwecken: zum einen zur Durchführung der Europäischen Arbeitskräfteerhebung in kontinuierlicher Form, also mit einer auf alle Wochen eines Jahres gleichmäßig verteilten Stichprobe, und zum anderen als Grundlage für die Abschätzung der Entwicklung der Wohnungsausgaben im Rahmen der monatlichen Verbraucherpreisindizes.

Rechtliche Rahmenbedingungen

Nationale Rechtsgrundlage für den „neuen" Mikrozensus ist die Erwerbs- und Wohnungsstatistik-Verordnung (EWStV; www.statistik.at/mikrozensus/verordnung.pdf) des Bundesministeriums für Wirtschaft und Arbeit vom 28. November 2003. Hier finden sich auch die entsprechenden Verweise auf die relevanten Rechtsgrundlagen auf europäischer Ebene, insbesondere die Verordnung (EG) Nr. 577/98 zur Durchführung einer Stichprobenerhebung über Arbeitskräfte in der Gemeinschaft sowie die Verordnung (EG) Nr. 2494/95 über harmonisierte Verbraucherpreisindizes.

Der Begriff des Mikrozensus findet sich in der EWStV im §6 genannt. Die Bundesanstalt Statistik Österreich wird hier unter dem Titel „Auswahl der Mikrozensus-Stichprobe" verpflichtet, eine Stichprobenerhebung entsprechend der Verordnung (EG) Nr. 577/98 über Arbeitskräfte in der Gemeinschaft durchzuführen. Im Art. 2 dieser Verordnung heißt es wiederum: „Die Erhebung wird in jedem Mitgliedstaat bei einer Stichprobe von Haushalten oder Einzelpersonen, die zum Zeitpunkt der Erhebung ihren Wohnsitz im Wirtschaftsgebiet des jeweiligen Staates haben, durchgeführt.", sowie in weiterer Folge: „Die Grundgesamtheit der Erhebung besteht in erster Linie aus den Personen in Privathaushalten im Wirtschaftsgebiet jedes Mitgliedstaates.". Art. 3 regelt dann die Repräsentativität der Stichprobe: „Für eine Gruppe von Arbeitslosen, die 5% der Bevölkerung im erwerbsfähigen Alter ausmacht, darf der relative Standardfehler der Schätzungen von Jahresdurchschnittswerten … auf der Ebene NUTS II (Bundesländer) höchstens 8% der betreffenden Bevölkerungsgruppe betragen.", wobei Regionen mit weniger als 300.000 Einwohnern von dieser Bestimmung ausgenommen werden. Als zweites Kriterium der Repräsentativität wird festgelegt, dass für Merkmale, die 5% der Be-

[1]) Siehe dazu die Beiträge „Die kontinuierliche Arbeitskräfteerhebung im Rahmen des neuen Mikrozensus", Heft 6/2004, S. 511 ff. und „Das Datenmanagement im neuen Mikrozensus. Eine Prozessbeschreibung", Heft 3/2006, S. 156 ff.

völkerung im erwerbsfähigen Alter betreffen, „der … Standardfehler für die Schätzung von Veränderungen dieser Merkmale zwischen zwei aufeinander folgenden Quartalen auf nationaler Ebene höchstens 3% der betreffenden Bevölkerungsgruppe betragen darf."

Erhebungsmethoden und Stichprobendesign

Die organisatorischen Änderungen des Mikrozensus an der Jahreswende 2003/2004 betrafen insbesondere auch die Erhebungsmethode. Im „alten" Mikrozensus vor 2004 gab es eine Stichprobe mit Achtel-Rotation, d.h., jeder Haushalt verblieb insgesamt acht Quartale lang in der Stichprobe, und jede der acht Befragungen sollte vom Interviewerstab Face-to-Face durchgeführt werden. Für den „neuen" Mikrozensus wurde u.a. aus Gründen der Respondentenentlastung dem Modell einer Fünftel-Rotation der Vorzug gegeben, und es wurde eine Erhebungsinfrastruktur für einen gemischten Erhebungsmodus aufgebaut. Befragungen in Form von Face-to-Face-Interviews sind nun im Prinzip nur für sog. „Erstbefragungen" vorgesehen, also bei jenem Fünftel der Haushalte, die jedes Quartal neu in die Stichprobe gezogen werden. Die vier „Folgebefragungen" erfolgen telefonisch, in Form des sog. „Computer Assisted Telephone Interviewing" (CATI).[2]) Zu diesem Zweck wurde in der STATISTIK AUSTRIA mit Jahresbeginn 2004 ein Telefonstudio eingerichtet.

Dieser gemischte Erhebungsmodus ermöglichte gegenüber der Situation vor 2004 eine starke Verkleinerung des Interviewerstabs im Face-to-Face-Bereich von rund 800 auf 145 Personen, die im Gegensatz zur dezentralen Betreuung durch die Landesstatistiken nun zentral von der STATISTIK AUSTRIA geführt werden. In weiterer Folge fiel damit auch die bis dahin gegebene Klumpung auf rund 1.100 Gemeinden, also die Zweistufigkeit der Stichprobe, weg. Um den voranstehend zitierten Vorgaben der EU-Verordnung für die Repräsentativität der Ergebnisse gerecht zu werden, ist allerdings weiterhin eine Schichtung der Stichprobe nach NUTS-II-Regionen (Bundesländern) notwendig. Die Mikrozensus-Stichprobe ist damit eine geschichtete uneingeschränkte Zufallsauswahl von Wohnungen bzw. eine geschichtete Klumpenauswahl von Personen. Einen Überblick über die Brutto-Stichproben sowie die Auswahlsätze nach Bundesländern bietet *Tabelle 1*.

Die Brutto-Stichprobengröße beträgt österreichweit 22.740 Haushalte pro Quartal (4.548 Erst- und 18.192 Folgebefragungshaushalte). Bezogen auf die Zahl der Privathaushalte zum Zeitpunkt der Volkszählung 2001 entspricht das einem Auswahlsatz von 0,68%. Diese Österreich-Werte ergeben sich dabei als Summe der Stichproben für die Bundesländer (Schichten), wobei in den Bundesländern Kärnten, Oberösterreich, Salzburg, Tirol und Vorarlberg die Bruttostichprobe bei jeweils 2.450 Haushalten liegt. Für das Burgenland wurde aufgrund der unter dem Wert von 300.000 liegenden Einwohnerzahl eine etwas kleinere Stichprobe (1.750 Haushalte), für Wien wegen der erfahrungsgemäß geringeren Ausschöpfung und der großen Zahl von Einpersonen-Haushalten eine etwas größere Bruttostichprobe (3.530 Haushalte) festgelegt. In Niederösterreich und in der Steiermark wurde der Auswahlsatz in einzelnen sehr dünn besiedelten Bezirken verdoppelt, um eine für die Aufrechterhaltung eines Interviewerstabs notwendige Zahl an Stichprobenhaushalten zu erzielen. Die Stichprobengrößen betragen damit für Niederösterreich 2.645 und für die Steiermark 2.560 Haushalte. Die Auswahlsätze bewegen sich damit zwischen 0,42% in Niederösterreich und 1,82% in Vorarlberg.

[2]) Tatsächlich werden rund 30% der (erfolgreichen) Interviews eines Quartals Face-to-Face und 70% telefonisch durchgeführt, da eine Reihe von Haushalten über kein Telefon verfügt oder keine Telefonnummer angeben möchte. Zudem gibt es die Möglichkeit des Methodenwechsels während der Erhebungsphase (von Face-to-Face-Interviews zu telefonischer Befragung oder umgekehrt), was optimale Voraussetzungen hinsichtlich hoher Ausschöpfung bei guter Qualität bietet.

Brutto-Quartalsstichprobe des Mikrozensus 2005

Tabelle 1

Bundesland	Privathaushalte			
	Erstbefragung	Folgebefragung	insgesamt	
	absolut		absolut	Auswahlsatz [1]) in %
Burgenland	351	1.404	1.755	*1,65*
Kärnten	490	1.960	2.450	*1,09*
Niederösterreich	529	2.116	2.645	*0,42*
Oberösterreich	490	1.960	2.450	*0,45*
Salzburg	490	1.960	2.450	*1,18*
Steiermark	512	2.048	2.560	*0,55*
Tirol	490	1.960	2.450	*0,94*
Vorarlberg	490	1.960	2.450	*1,82*
Wien	706	2.824	3.530	*0,46*
Österreich	**4.548**	**18.192**	**22.740**	***0,68***

1) Auswahlsatz bezogen auf die Zahl der Privathaushalte bei der Volkszählung 2001.

Das ZMR als Auswahlrahmen

Das seit dem Jahr 2002 aktive Zentrale Melderegister (ZMR) schafft nicht nur für die Bevölkerungsstatistik neue Voraussetzungen und Möglichkeiten,[3]) es kann gleichzeitig auch als Auswahlrahmen für Haushalts- und Personenstichproben genutzt werden. Die grundsätzliche Möglichkeit der Verwendung der Daten des ZMR durch die amtliche Statistik ist dabei im § 16b Abs. 8 Meldegesetz rechtlich verankert. („Die im Zentralen Melderegister gespeicherten Daten dürfen für statistische Zwecke nach dem Bundesstatistikgesetz 2000 an Organe der Bundesstatistik … übermittelt werden.")

Die Vorteile der Nutzung des ZMR als Auswahlrahmen für Stichprobenerhebungen liegen dabei vor allem in der Vollständigkeit (alle mit Hauptwohnsitz in Österreich gemeldeten Personen) und Aktualität der Daten. Dem stehen bei Haushaltsstichproben allerdings als Nachteil die Qualitätsmängel des ZMR im Bereich der korrekten Zuordnung der

[3]) Siehe Heft 3/2005, S. 203 ff.

gemeldeten Personen zu den einzelnen Wohnungen (= Haushalten) eines Gebäudes gegenüber. Die rund 2.400 Meldebehörden (= Gemeinden) sind von diesem Problem in quantitativ sehr unterschiedlicher Weise betroffen; erhebliche Qualitätsmängel weisen in dieser Hinsicht etwa die Meldedaten der Städte Klagenfurt und Salzburg auf. (Zu den Konsequenzen der Unschärfe der Wohnungsabgrenzung für die Hochrechnung siehe die nachstehenden Ausführungen.)

Die EWStV präzisiert die Verwendung des ZMR als Auswahlrahmen für den Mikrozensus, indem auf die im Meldegesetz § 16b Abs. 1 für die Zwecke der Wanderungsstatistik ohnehin laufend vorgesehenen Datenlieferungen an die STATISTIK AUSTRIA verwiesen wird. Diese Datenlieferungen erfolgen quartalsweise und umfassen u.a. den indirekt personenbezogenen Meldedatenbestand der hauptwohnsitzgemeldeten Personen zum Stichzeitpunkt Quartalsbeginn, 0 Uhr. Vor der Stichprobenziehung werden Adressen ausgeschieden, die entweder als Anstaltshaushalte identifiziert wurden oder die bereits in früheren Quartalen in die Stichprobe gewählt wurden. Auswahlrahmen der Mikrozensus-Stichprobe bilden damit alle übrigen Wohnungen (= Privathaushalte) mit zumindest einer hauptwohnsitzgemeldeten Person, bezogen auf den Beginn jenes Quartals, das unmittelbar vor dem jeweiligen Referenzquartal liegt.

Auf Ebene der Personen orientiert sich der Mikrozensus allerdings nicht an den an einer Adresse im ZMR hauptwohnsitzgemeldeten Personen („Melderealität"). Den Interviewern wird diese Information bewusst nicht kommuniziert. Sie sollen vielmehr ohne Kenntnis der „Melderealität" in den Haushalten direkt erfragen und dokumentieren, welche Personen im Haushalt leben („Befragungsrealität").

Stichprobenziehung

Die Stichprobenziehung selbst erfolgt pro Politischen Bezirk durch das Aufbringen einer gleichverteilten Zufallszahl auf alle Wohnungen der Grundgesamtheit. Anschließend werden die Wohnungen bezirksweise nach dieser Zufallszahl sortiert. Dem vorgegebenen Auswahlsatz des Bundeslands entsprechend, in dem der jeweilige Bezirk liegt, ergeben dann die n ersten Wohnungen eines Bezirks jene Adressen, die neu in die Stichprobe rotieren.

Den in die Stichprobe gewählten Haushalten muss anschließend ein Interviewersprengel und eine Referenzwoche (jene Woche, auf die sich die erfragten Angaben in der Regel beziehen) zugewiesen werden. Auf Basis der rund 22.000 (bewohnten) Ortschaften Österreichs wurden 116 Interviewersprengel gebildet, deren Abgrenzungen im Wesentlichen unverändert bleiben. Die Zuweisung der Referenzwochen erfolgt jedes Quartal automatisiert unter Verwendung einer eigens dafür entwickelten Applikation im Rahmen eines Geographischen Informationssystems (GIS). Der verwendete Algorithmus sorgt dafür, dass - unter Beachtung der Prämisse einer gleichmäßigen Verteilung der Stichprobenhaushalte über alle Wochen eines Quartals - die Zuteilung der Referenzwochen in räumlicher Hinsicht für die Interviewer optimiert (räumliche Nähe von Haushalten mit gleicher Referenzwoche innerhalb eines Interviewersprengels, insbesondere in jenen mit mehr als einem Interviewer) vorgenommen wird.

Da die Ausgangsdaten für die Stichprobenziehung nur einen indirekten Personenbezug aufweisen, ist parallel dazu ein weiterer Schritt notwendig. Wie im § 7 Abs. 1 EWStV vorgesehen, werden die ZMR-Zahlen der an den gezogenen Adressen gemeldeten Personen elektronisch an das Zentrale Melderegister übermittelt. Das Zentrale Melderegister gibt daraufhin die Namen der diesen ZMR-Zahlen zugeordneten Personen bekannt. Die Namen dienen in weiterer Folge dazu, den ausgewählten Haushalten ca. eine Woche vor dem vorgesehenen Befragungstermin (die der Referenzwoche unmittelbar folgende Kalenderwoche) ein personalisiertes Ankündigungsschreiben einschließlich eines Informationsfolders über den Mikrozensus zuschicken zu können.

Ausschöpfung

Durch die optimalen organisatorischen Rahmenbedingungen und die in der EWStV verankerte Auskunftspflicht erreicht der Mikrozensus Ausschöpfungsquoten, die weit über jenen liegen, die in sozialwissenschaftlichen Stichprobenerhebungen üblicherweise erzielbar sind. Für das Jahr 2005 konnten von den insgesamt 90.949 in der Stichprobe befindlichen Haushalten insgesamt 81.122 komplett, also jeweils alle Haushaltsmitglieder, befragt werden. Die Ausschöpfungsquote (ohne neutrale Ausfälle wie z.B. zum Interviewzeitpunkt nicht (mehr) bewohnte Wohnungen) lag damit bei 96,7% *(Tabelle 2)*.

Brutto- und Nettostichprobe (Haushalte) des Mikrozensus 2005 nach Bundesländern Tabelle 2

	Österreich	Burgenland	Kärnten	Niederösterreich	Oberösterreich	Salzburg	Steiermark	Tirol	Vorarlberg	Wien
Brutto/Bruttostichprobe [1])	90.949	7.020	9.940	11.110	9.800	9.820	10.669	9.780	9.800	13.010
Neutrale Ausfälle	6.932	307	546	824	591	879	858	625	567	1.735
Bruttostichprobe [2])	84.017	6.713	9.394	10.286	9.209	8.941	9.811	9.155	9.233	11.275
Verweigerungen	102	3	12	11	17	6	20	6	7	20
Keine Information verfügbar	2.693	104	191	324	214	283	338	167	204	868
Nettostichprobe [3])	81.222	6.606	9.191	9.951	8.978	8.652	9.453	8.982	9.022	10.387
Ausschöpfungsquote (%)	*96,7*	*98,4*	*97,8*	*96,7*	*97,5*	*96,8*	*96,4*	*98,1*	*97,7*	*92,1*

1) Inklusive neutraler Ausfälle. - 2) Ohne neutrale Ausfälle. - 3) Erfolgreiche Befragung aller Haushaltsmitglieder.

Erwartungsgemäß liegt Wien hinsichtlich der Ausschöpfung mit 92% deutlich unter den Flächenbundesländern. Eine Ausschöpfung von mehr als 97% erreichte der Mikrozensus im Jahr 2005 im Burgenland, in Kärnten, in Oberösterreich sowie in Tirol und Vorarlberg.

Hochrechnung und Hochrechnungsvorgaben

Bei einer zufallsgesteuerten Stichprobenauswahl wird ein verkleinertes, aber sonst im Schnitt wirklichkeitsgetreues Abbild des Merkmalskörpers der Grundgesamtheit geschaffen. Bei der Berechnung der statistischen Ergebnisse muss diese Verkleinerungsprozedur wieder rückgängig gemacht werden. Dieser Vorgang heißt Hochrechnung. Dabei werden die mit Hilfe der Stichprobe erhobenen Merkmalswerte zur Schätzung der interessierenden, aber unbekannten Parameter der Grundgesamtheit herangezogen.

Dem Mikrozensus liegt eine geschichtete Stichprobe mit unterschiedlichen Auswahlsätzen pro Bundesland zugrunde. Hinzu kommt, dass Stichprobenadressen schichtspezifisch verschieden stark ausfallen. Das Abbild der Gesamtheit in der Stichprobe ist also in einem unterschiedlichen Ausmaß verkleinert. Um aus den Erhebungsdaten der Stichprobe wieder ein verzerrungsfreies Gesamtbild zu erzeugen, müssen die Erhebungswerte nach Schichten getrennt hochgerechnet werden, im einfachsten Fall durch Multiplikation mit dem Kehrwert des jeweiligen Auswahlsatzes. Diese Hochrechnungsgewichte oder -faktoren werden auf den Datensätzen gespeichert. Bei der Tabellierung der Mikrozensusergebnisse wird jeder einzelne Merkmalswert vor der Addition mit dem Hochrechnungsfaktor multipliziert.

Tatsächlich wird die Hochrechnung an die Bevölkerungsstände des Bevölkerungsregisters der STATISTIK AUSTRIA gebunden, d.h., die Hochrechnungsgewichte werden so bestimmt, dass die aus dem Mikrozensus resultierenden Verteilungen von Personenmassen nach Bundesland, Alter und Geschlecht sowie nach Bundesland und Nationalität mit den entsprechenden Werten des Bevölkerungsregisters übereinstimmen.

Wirklich neu an der Hochrechnung des Mikrozensus ab 2004 ist nur, dass die Hochrechnungsgewichte so bestimmt werden, dass auch die sich aus dem Mikrozensus ergebenden Verteilungen der Wohnungen (= Haushalte) nach der Zahl der Bewohner mit den entsprechenden Verteilungen der Haushaltsprognose der STATISTIK AUSTRIA übereinstimmen. Diese zusätzliche Restriktion wurde eingeführt, weil einerseits die Wohnungsabgrenzung im Zentralen Melderegister mit einer gewissen Unschärfe behaftet ist und weil andererseits die Antwortausfälle im Mikrozensus umso höher sind, je weniger Personen in einer Wohnung leben.

Folgende Vorgaben der STATISTIK AUSTRIA werden für die Hochrechnung herangezogen:

N_{bag} ... Gesamtzahl der Personen in Privathaushalten (laut Bevölkerungsregister) im Bundesland b (= 1 ... 9), Alter a (in Jahren; 1= 0-2, 2= 3-5, 3= 6-9, 4= 10-14, ... 18= 80-84, 19= 85 und älter) und Geschlecht g (= 1, 2) im jeweiligen Quartal.

N_{bs} ... Gesamtzahl der Personen in Privathaushalten (laut Bevölkerungsregister) im Bundesland b (= 1 ... 9) und Staatsbürgerschaft s (1= Österreich, 2= EU-15 ohne Österreich, 3= Ex-Jugoslawien, 4= Türkei, 5= sonstiges Ausland) im jeweiligen Quartal.

M_{bh} ... Gesamtzahl an bewohnten Wohnungen (= Privathaushalte laut Haushaltsprognose der STATISTIK AUSTRIA) im Bundesland b (= 1 ... 9) mit h Bewohnern (Haushaltsgröße h= 1, 2, 3, 4, 5, 6+) im jeweiligen Quartal.

Die Ermittlung der endgültigen Hochrechnungsgewichte erfolgt in einem iterativen Prozess ausgehend von den Gewichten bei freier Hochrechnung. Letztere berechnen sich in der Regel für alle Personen und Wohnungen eines Bundeslands b als der Quotient

$$\frac{M_b}{m_b} \qquad (1)$$

Dabei bezeichnet M_b die Anzahl der bewohnten Wohnungen in der Grundgesamtheit im Bundesland b und m_b die Anzahl der Wohnungen der Nettostichprobe im Bundesland b.

Bei der Stichprobenauswahl für das Jahr 2004 wurde in 13 Bezirken der Auswahlsatz im Vergleich zu den übrigen Bezirken des jeweiligen Bundeslands verdoppelt, um auch in diesen relativ dünn besiedelten Bezirken eine genügend hohe Auslastung der Interviewer zu erzielen. Ab dem Jahr 2005 wird diese Erhöhung des Auswahlsatzes nur mehr in fünf Bezirken durchgeführt. In den von dieser Verdoppelung des Auswahlsatzes betroffenen Bundesländern ergibt sich das Hochrechnungsgewicht bei freier Hochrechnung als

$$\frac{M_b}{m_{b1} + m_{b2}/2} \qquad (2)$$

für Personen und Wohnungen aus Bezirken mit normalem Auswahlsatz und als die Hälfte dieses Quotienten für Bezirke mit doppeltem Auswahlsatz. m_{b1} bezeichnet die Anzahl der Wohnungen der Nettostichprobe in den Bezirken des Bundeslands b mit normalem Auswahlsatz und m_{b2} bezeichnet die Anzahl der Wohnungen der Nettostichprobe in den Bezirken des Bundeslands b mit doppeltem Auswahlsatz.

Anpassung an vorgegebene Bevölkerungsstrukturen: Die mittels der Gewichte (1) und (2) errechneten Bevölkerungszahlen weichen hinsichtlich der Verteilung nach Alter, Geschlecht

und Nationalität in der Regel von den entsprechenden Zahlen des Bevölkerungsregisters ab.

Viele Auswertungen des Mikrozensus haben die Berechnung von Umfängen von speziellen Personengesamtheiten zum Ziel. Diese Schätzwerte korrelieren sehr eng mit der Bevölkerungszahl. Es lässt sich daher die Genauigkeit dieser Schätzwerte erhöhen, indem man die aus der Stichprobe errechneten Bevölkerungszahlen an die aus dem Bevölkerungsregister bekannten Eckzahlen anpasst. Dies wird erreicht, indem man die Hochrechnungsgewichte aus den Formeln (1) und (2) in einem iterativen Verfahren so abändert, dass die hernach errechneten Mikrozensusergebnisse mit den vorgegebenen Bevölkerungsstrukturen übereinstimmen.

Für die Zwecke der **Iteration** werden für jede Person i die Merkmalsausprägungen für das Bundesland b (= 1, ..., 9), das Alter a (= 1, ..., 19), das Geschlecht g (= 1, 2), die fortlaufende Wohnungsnummer j (Kombination aus Pol. Bezirk und Wohnungskennzahl), die Staatsbürgerschaft s (= 1, …, 5) und das vorläufige Hochrechnungsgewicht aus (1) und (2) benötigt. Wir bezeichnen dieses Gewicht mit w_i^0.
Die Iteration besteht aus vier sich ständig wiederholenden Schritten. Zum Start wird der Laufindex k= 0 gesetzt.

Schritt 1: Das nach Formel (1) und (2) errechnete Gewicht jeder Person wird durch Multiplikation mit einem Faktor so abgeändert, dass die mit den abgeänderten Gewichten hochgerechnete Verteilung der Bevölkerung nach Bundesland, Alter und Geschlecht mit den Vorgaben N_{bag} übereinstimmt.

$$w_i^{4k+1} = w_i^{4k} \frac{N_{b_i a_i g_i}}{\sum_l w_l^{4k}} \text{ für alle i}$$

Die Summierung erstreckt sich dabei über alle Datensätze l von Personen mit denselben Ausprägungen hinsichtlich der Merkmale Bundesland, Alter und Geschlecht wie der Satz i. Falls der Quotient $w_i^{4k+1} / w_i^0 > 4$ ist, wird $w_i^{4k+1} = 4w_i^0$ gesetzt, und falls $w_i^{4k+1} / w_i^0 < 1/4$ ist, wird $w_i^{4k+1} = w_i^0/4$ gesetzt.[4])

Schritt 2: Die im Schritt 1 erzielten Gewichte werden multiplikativ so abgeändert, dass die mit den entstehenden Gewichten hochgerechnete Verteilung der Bevölkerung nach Bundesland und Staatsbürgerschaft mit der Vorgabe N_{bs} übereinstimmt. Die Veränderung der ursprünglichen Gewichte w_i^0 soll wieder das Vierfache nicht überschreiten bzw. ein Viertel nicht unterschreiten. Es gilt

$$w_i^{4k+2} = w_i^{4k+1} \frac{N_{b_i s_i}}{\sum_l w_l^{4k+1}} \text{ für alle i}$$

Die Summierung erstreckt sich dabei über alle Datensätze l von Personen mit denselben Ausprägungen hinsichtlich der Merkmale Bundesland und Staatsbürgerschaft wie der Satz i. Falls der Quotient $w_i^{4k+2} / w_i^0 > 4$ ist, wird $w_i^{4k+2} = 4w_i^0$ gesetzt, und falls $w_i^{4k+2} / w_i^0 < 1/4$ ist, wird $w_i^{4k+2} = w_i^0 / 4$ gesetzt. Durch diese Anpassung geht diejenige hinsichtlich Alter und Geschlecht aus Schritt 1 im Allgemeinen wieder verloren.

Schritt 3: Durch die in den Schritten 1 und 2 vorgenommenen Anpassungen kommt es dazu, dass das ursprünglich für alle Personen einer Wohnung einheitliche Gewicht nun von Person zu Person differiert, sofern nicht zufällig alle Personen einer Wohnung dem gleichen Geschlecht, der gleichen Altersklasse und der gleichen Staatsbürgerschaft angehören. Solche Gewichte haben den Nachteil, dass damit hochgerechnete Tabellen mit der Darstellungseinheit Wohnung mit entsprechenden Personentabellen inkonsistent werden. Daher besteht das Bestreben, alle Personen einer Wohnung mit dem gleichen Gewicht zu versehen. Dies wird erreicht, indem im 3. Schritt alle Personen einer Wohnung als neues Gewicht den Durchschnitt ihrer Gewichte nach Abschluss des 2. Schrittes erhalten.

$$w_i^{4k+3} = \frac{\sum_l w_l^{4k+2}}{N_j} \text{ für alle i}$$

Die Summierung erstreckt sich über alle Personen l der Wohnung j, in der sich die Person i befindet. N_j bezeichnet die Anzahl dieser Personen. Dadurch geht möglicherweise die Anpassung an die Bevölkerungsstruktur wieder verloren.

Schritt 4: Die im Schritt 3 erzielten Gewichte werden multiplikativ so abgeändert, dass die mit den entstehenden Gewichten hochgerechnete Verteilung der Wohnungen nach Bundesland und Zahl der Bewohner mit der Vorgabe M_{bh} annähernd übereinstimmt. Eine exakte Übereinstimmung wird bezüglich der Wohnungszahlen nicht angestrebt, weil die Vorgaben selbst mit einer gewissen Unschärfe behaftet sind. Die Unschärfe wird für die Zahl der Wohnungen je Bundesland und Haushaltsgröße h mit 5‰ (p_h=0,005 für h=1, …, 4) angenommen. Die Zahl der Wohnungen mit fünf Bewohnern wird je Bundesland mit einer Unschärfe von 5% (p_5= 0,05) angenommen, die Zahl der Wohnungen mit sechs und mehr Bewohnern wird je Bundesland mit einer Unschärfe von 15% (p_6= 0,15) angenommen. Die Veränderung der ursprünglichen Gewichte w_i^0 soll wieder

[4]) Die Wahl dieser Schranken hat sich in der Vergangenheit im Rahmen des Mikrozensus bewährt. Eine Einschränkung der Veränderung der Basisgewichte ist auch in anderen Ländern üblich. Vgl. hiezu den Artikel von A. Afentakis u. W. Bihler „Das Hochrechnungsverfahren beim unterjährigen Mikrozensus ab 2005“ in Wirtschaft und Statistik, Heft 10/2005, S. 1039 ff.

das Vierfache nicht überschreiten bzw. ein Viertel nicht unterschreiten. Es gilt

$$w_i^{4k+4} = \begin{cases} w_i^{4k+3} \dfrac{M_{b_i h_i}}{\sum_l w_l^{4k+3}}, & \text{falls } \sum_l w_l^{4k+3} \notin \left((1-p_h)\, M_{b_i h_i}, (1+p_h)\, M_{b_i h_i}\right) \\ w_i^{4k+3}, & \text{sonst} \end{cases}$$

Die Summierung erstreckt sich dabei über alle Datensätze l von Wohnungen mit denselben Ausprägungen hinsichtlich der Merkmale Bundesland und Bewohneranzahl wie der Datensatz i. Falls der Quotient $w_i^{4k+4} / w_i^0 > 4$ ist, wird $w_i^{4k+4} = 4\, w_i^0$ gesetzt, und falls $w_i^{4k+4} / w_i^0 < 1/4$ ist, wird $w_i^{4k+4} = w_i^0 / 4$ gesetzt.

Schritt 5: Es erfolgt nun eine Abfrage, ob die mit den neuen Gewichten errechnete Bevölkerungsstruktur noch in irgendeiner Zelle von der vorgegebenen Struktur um mehr als einen festgelegten Wert (0,01%) abweicht.

$$\max_{bag} \left| \frac{\sum_l w_l^{4k+4} - N_{bag}}{N_{bag}} \right| > 0{,}0001 \qquad \max_{bs} \left| \frac{\sum_l w_l^{4k+4} - N_{bs}}{N_{bs}} \right| > 0{,}0001$$

Die Summierung erstreckt sich dabei in der ersten Ungleichung über alle Personen mit denselben Ausprägungen der Merkmale b, a und g und in der zweiten Ungleichung über alle Personen mit denselben Ausprägungen der Merkmale b und s.
Falls wenigstens eine der beiden Bedingungen erfüllt ist, wird k um 1 erhöht und das Verfahren beginnt wieder mit Schritt 1. Dies wird bei den ersten Durchläufen der Iteration noch der Fall sein, weil ja in den Schritten 2 und 3 etwa die Anpassung an die Altersverteilung wieder zerstört wird. Das Verfahren beginnt also wieder mit Schritt 1, wobei anstatt des Gewichts aus Formel (1) und (2) nun das nach Durchlaufen des 4. Schrittes erzeugte Gewicht verwendet wird. Ist keine der beiden Bedingungen erfüllt, so ist das definitive Hochrechnungsgewicht mit w_i^{4k+4} gefunden und damit das Ziel der Iteration erreicht.

Obiges Verfahren wird nach den bisherigen Erfahrungen etwa 50- bis 100-mal durchlaufen, bis die so definierte Konvergenz erreicht ist. Nach 100 Iterationen wird auf jeden Fall abgebrochen. Die in die Iteration eingebaute Sicherheitsschranke bewirkt, dass die Gewichte nach Formel (1) und (2) durch die Iteration um nicht mehr als das Vierfache erhöht werden. Nach Abschluss der Iteration wird jeder Datensatz mit dem definitiven Hochrechnungsgewicht angereichert, wie es sich für die Privathaushalte aufgrund der Iteration ergibt.

Verwendung der Hochrechnungsgewichte bei Quartals- und Jahresauswertungen: Die quartalsweise Berechnung des Umfangs bestimmter Haushalts- oder Personenmassen in der Grundgesamtheit geschieht durch Addition der endgültigen Gewichte aller Elemente der entsprechenden Stichprobenmasse. Die Totalwerte quantitativer Merkmale ergeben sich durch Multiplikation mit den Hochrechnungsgewichten und anschließende Addition, die Quotienten durch Division von Totalwerten bzw. Summen.

Die vierteljährlich stattfindenden Befragungen im Rahmen des Mikrozensus werden für manche Themenkreise zur Erstellung von Jahresreihen benützt. Die Jahresfiles ergeben sich als Vereinigungsmenge der vier Quartalsfiles, wobei die Hochrechnungsgewichte der Quartalsfiles geviertelt werden. Die Berechnung von Jahreswerten geschieht analog zur Berechnung von Quartalswerten allerdings mit der vierfachen Datenmasse, in der jeder Datensatz ein auf ein Viertel reduziertes Gewicht aufweist.

Genauigkeit und Fehlerrechnung

Die bei der Arbeitskräfteerhebung erhobenen Merkmale sind großteils qualitativer bzw. diskreter Natur. Die Auswertung dieser Merkmale erfolgt vorwiegend durch Berechnung von absoluten bzw. relativen Häufigkeitstabellen, die für jede Ausprägungskombination der tabellenerzeugenden Merkmale die darauf entfallende hochgerechnete Fallzahl angeben. Diese hochgerechneten Werte sind mit einer gewissen Unschärfe behaftet, da ihre Berechnung nicht auf Basis einer Vollerhebung, sondern einer Stichprobe erfolgt. Diese Unschärfe wird hier mit dem relativen Stichprobenfehler bei 95-prozentiger Sicherheit (das 1,96-fache des Quotienten aus Standardfehler dividiert durch die geschätzte Häufigkeit) bzw. mit dem Variationskoeffizienten (= relativer Stichprobenfehler bei 68-prozentiger Sicherheit und entspricht dem Quotienten aus Standardfehler dividiert durch die geschätzte Häufigkeit) gemessen.

Der relative Stichprobenfehler für solche Häufigkeitstabellen lässt sich sowohl für Wohnungsmassen als auch für Personenmassen unter der Annahme einer einfachen Zufallsauswahl von Wohnungen bzw. Personen mit Hilfe des Binomialansatzes[5]) abschätzen. Bei diesem Verfahren werden also die Effekte der komplexen Hochrechnung (iterative Anpassung an vorgegebene Verteilungen der Personen und Wohnungen) und der geklumpten Auswahl von Personen ausgeklammert (bei der Schätzung des Stichprobenfehlers für Personenhäufigkeiten beide Effekte, bei Wohnungen nur der Effekt der komplexen Hochrechnung).

Berücksichtigt werden hingegen die pro Bundesland unterschiedlichen Auswahlsätze. Nach diesem Ansatz ergibt sich näherungsweise der geschätzte relative Stichprobenfehler in Prozent bei 95-prozentiger statistischer Sicherheit für eine hochgerechnete Fallzahl x (Wohnungen oder Personen) nach der Formel

$$200\sqrt{\frac{(N_b - n_b)\,(N_b - x)}{N_b\, n_b\, x}}$$ für Bundeslandergebnisse und

$$200\sqrt{\sum_b \frac{(N_b - n_b)\,(N - x)\,N_b}{n_b\, N^2\, x}}$$ für österreichbezogene Häufigkeiten x

Dabei bezeichnen N_b die Grundgesamtheit im Bundesland b, n_b den Stichprobenumfang im Bundesland b und N die Grundgesamtheit in Österreich.

Im Falle der Wohnungen sind in den obigen Formeln die Größen N, N_b, n und n_b durch M, M_b, m und m_b zu ersetzen. Bei der Herleitung der zweiten Formel wird vorausgesetzt, dass die Beiträge der einzelnen Bundesländer zum Wert von x proportional zur Größe der einzelnen Bundesländer sind.

Die mittels obiger Formeln errechneten relativen Stichprobenfehler für hochgerechnete Häufigkeiten von Personen bzw. Wohnungen sind in den *Tabellen 3 und 4* dargestellt. Daraus lässt sich der Zusammenhang zwischen Merkmalshäufigkeit und Stichprobenfehler für Bundesland- und Österreichergebnisse näherungsweise abschätzen. Hierbei bezieht sich die *Tabelle 3* auf die Grundgesamtheit der bewohnten Wohnungen und die *Tabelle 4* auf 8 Mio. Personen. Für ein Merkmal, das in der österreichischen Bevölkerung auf 20.000 Personen zutrifft, ergibt sich also

[5]) Streng genommen sind die absoluten Häufigkeiten bei einem Ziehungsvorgang ohne Zurücklegen hypergeometrisch verteilt; da aber der Auswahlsatz sehr klein ist, ist die Verwendung der Binomialverteilung gerechtfertigt.

Relativer Stichprobenfehler hochgerechneter Wohnungszahlen bei 95% statistischer Sicherheit

Tabelle 3

Wohnungen in 1.000	Österreich	Burgenland	Kärnten	Nieder-österreich	Ober-österreich	Salzburg	Steiermark	Tirol	Vorarlberg	Wien
	Relativer Stichprobenfehler in Prozent									
1	52,3	65,5	100,0	100,0	64,1	91,1	71,6	50,0	117,9	94,9
2	36,8	46,2	70,7	70,7	45,3	64,4	50,5	35,3	83,3	67,1
3	29,9	37,7	57,7	57,7	36,9	52,5	41,2	28,7	68,0	54,8
4	25,8	32,6	49,9	49,9	31,8	45,4	35,6	24,7	58,9	47,4
5	22,9	29,1	44,6	44,6	28,4	40,6	31,8	22,1	52,6	42,4
6	20,8	26,5	40,7	40,7	25,9	37,0	28,9	20,1	48,0	38,7
7	19,2	24,4	37,6	37,6	23,9	34,2	26,7	18,5	44,4	35,9
8	17,9	22,8	35,2	35,1	22,3	32,0	25,0	17,2	41,5	33,5
9	16,8	21,5	33,1	33,1	21,0	30,1	23,5	16,2	39,1	31,6
10	15,8	20,3	31,4	31,4	19,9	28,5	22,2	15,3	37,1	30,0
20	10,6	14,0	22,0	22,0	13,7	20,0	15,4	10,4	26,1	21,2
30	8,2	11,2	17,8	17,8	10,9	16,1	12,3	8,1	21,1	17,3
40	6,6	9,4	15,3	15,3	9,2	13,8	10,5	6,7	18,2	14,9
50	5,4	8,2	13,6	13,5	8,0	12,2	9,2	5,7	16,2	13,3
60	4,5	7,3	12,3	12,2	7,0	11,0	8,2	4,9	14,6	12,2
70	3,7	6,5	11,3	11,2	6,3	10,1	7,4	4,2	13,5	11,2
80	3,0	5,9	10,5	10,4	5,7	9,3	6,7	3,7	12,5	10,5
90	2,3	5,4	9,8	9,7	5,2	8,7	6,2	3,2	11,7	9,9
100	1,4	4,9	9,2	9,1	4,7	8,1	5,7	2,7	11,0	9,4
200		1,7	5,9	5,7	1,2	4,9	2,6		7,2	6,5
300			4,2	3,9		3,2			5,4	5,2
400			3,0	2,7		1,9			4,2	4,5
500			2,1	1,4					3,2	3,9
600			0,9						2,4	3,5
700									1,5	3,2
800										2,9
900										2,7
1.000										2,5
2.000										1,4
3.000										0,6

Relativer Stichprobenfehler hochgerechneter Personenzahlen bei 95% statistischer Sicherheit

Tabelle 4

Personen in 1.000	Österreich	Burgenland	Kärnten	Nieder-österreich	Ober-österreich	Salzburg	Steiermark	Tirol	Vorarlberg	Wien
	Relativer Stichprobenfehler in Prozent									
2	36,2	45,0	67,8	68,6	44,0	62,2	49,2	34,3	82,3	64,5
3	29,5	36,7	55,4	56,0	35,9	50,8	40,1	28,0	67,2	52,6
4	25,5	31,8	47,9	48,5	31,0	44,0	34,7	24,2	58,1	45,6
5	22,8	28,4	42,9	43,4	27,7	39,3	31,0	21,6	52,0	40,8
6	20,7	25,9	39,1	39,6	25,3	35,9	28,3	19,7	47,4	37,2
7	19,2	23,9	36,2	36,6	23,4	33,2	26,2	18,2	43,9	34,4
8	17,9	22,4	33,8	34,2	21,9	31,0	24,5	17,0	41,1	32,2
9	16,8	21,1	31,9	32,3	20,6	29,2	23,1	16,0	38,7	30,4
10	15,9	20,0	30,3	30,6	19,5	27,7	21,9	15,2	36,7	28,8
20	11,1	14,0	21,3	21,6	13,7	19,5	15,3	10,6	25,9	20,4
30	8,9	11,3	17,4	17,5	11,0	15,9	12,4	8,5	21,1	16,6
40	7,5	9,7	15,0	15,1	9,5	13,7	10,7	7,2	18,2	14,4
50	6,6	8,6	13,4	13,5	8,4	12,2	9,5	6,4	16,2	12,9
60	5,9	7,8	12,1	12,3	7,6	11,1	8,6	5,7	14,7	11,7
70	5,3	7,1	11,2	11,3	6,9	10,2	7,9	5,2	13,6	10,9
80	4,8	6,6	10,4	10,5	6,4	9,5	7,3	4,8	12,7	10,1
90	4,4	6,1	9,8	9,9	6,0	8,9	6,8	4,4	11,9	9,6
100	4,1	5,8	9,3	9,4	5,6	8,4	6,4	4,1	11,3	9,1
200	1,9	3,6	6,3	6,3	3,4	5,7	4,1	2,3	7,7	6,4
300		2,5	5,0	5,0	2,3	4,4	3,0	1,1	6,1	5,2
400		1,7	4,1	4,1	1,5	3,6	2,2		5,0	4,4
500		0,9	3,5	3,5	0,5	3,0	1,6		4,3	3,9
600			3,1	3,0		2,5	1,0		3,8	3,6
700			2,7	2,6		2,1			3,3	3,3
800			2,4	2,2		1,8			2,9	3,1
900			2,1	1,9		1,4			2,6	2,9
1.000			1,8	1,6		1,1			2,3	2,7
2.000										1,8
3.000										1,3
4.000										1,0
5.000										0,8
6.000										0,6
7.000										0,4
8.000										0,1

unter den genannten Bedingungen ein Unsicherheitsbereich von etwa ±20%. Für kleinere Personengruppen wird der Stichprobenfehler entsprechend höher. Die Vertrauensbereiche sind derart angegeben, dass der Stichprobenfehler mit 95% Sicherheit innerhalb der angegebenen Grenzen liegt, sofern die Effekte der geklumpten Auswahl von Personen und der gebundenen Hochrechnung vernachlässigbar klein sind.

Zwei Beispiele sollen den **Gebrauch dieser Tabellen** demonstrieren: Bei einer Mikrozensuserhebung wurden in Österreich 57.000 Eigentumswohnungen mit einem Baujahr zwischen 1961 und 1970 festgestellt. Durch Interpolation ergibt sich aus *Tabelle 3*, dass der relative Stichprobenfehler etwa 12,5% oder 57.000*0,125= 7.125 Wohnungen ausmacht. Mit einer Wahrscheinlichkeit von 95% würde sich also die bei einer Vollerhebung ermittelte Zahl von Wohnungen dieses Typs um höchstens 7.125 Wohnungen von den 57.000 Wohnungen unterscheiden.
Bei der gleichen Mikrozensuserhebung wurden im Burgenland 14.200 Selbständige gezählt. Aus *Tabelle 4* folgt, dass der relative Stichprobenfehler etwa 13% oder 14.200*0,13= 1.846 Personen ausmacht. Die wahre Anzahl der Selbständigen im Burgenland liegt demnach mit einer Sicherheit von (höchstens)[6]) 95% zwischen 12.354 und 16.046 Personen.

Auch für die Berechnung des Stichprobenfehlers der hochgerechneten Häufigkeiten anderer Untersuchungsobjekte wie etwa von Haushalten oder Familien ist näherungsweise die Tabelle 3 heranzuziehen.

Es wird nochmals darauf hingewiesen, dass die Tabellen nur einen Hinweis auf die **Größenordnung des Fehlers** und nicht den exakten Wert angeben. Bei der Berechnung der Tabellen wurde beispielsweise die Anpassung an die fortgeschriebene Wohnbevölkerung nicht berücksichtigt. Häufigkeiten, die Umfänge von Massen repräsentieren, die dieser Anpassung zugrunde liegen, weisen natürlich keinen Zufallsfehler auf (z.B. die Bevölkerungszahl gewisser Altersklassen). Auch sind die Fehler vergrößernden Effekte der Klumpung nicht berücksichtigt, weil dazu kaum generelle Aussagen möglich sind. Diese Elemente des Stichprobenplans

[6]) Höchstens 95%, weil der Stichprobenfehler für Personenhäufigkeiten mit diesem Verfahren tendenziell unterschätzt wird.

wirken sich auf jedes Merkmal und jede Untergliederung einer Tabelle unterschiedlich aus.
Will man den Stichprobenfehler genauer abschätzen, indem man alle Aspekte der Stichprobenziehung und Hochrechnung berücksichtigt und/oder nichtlineare Schätzfunktionen z.B. für Quotienten verwendet, muss man aufgrund der Komplexität des Designs auf andere Methoden (Taylorlinearisierung, Bootstrapverfahren) zugreifen.

Dabei ergab sich für einige wichtige **Kennziffern der Arbeitskräfteerhebung im 4. Quartal 2004** folgende Schätzung der relativen Stichprobenfehler in Prozent (bei 95-prozentiger statistischer Sicherheit):[7])

Übersicht 1

Kennziffer	Anzahl/Anteil	Relativer Stichprobenfehler in %
Erwerbstätige	3,771.400	*1,2*
Teilzeit-Erwerbstätige	805.700	*3*
Arbeitslose	195.800	*7,7*
Arbeitslosenquote in Prozent	*4,9*	*7,6*
Durchschnittliche Arbeitszeit in Stunden	34,8	*0,8*

Für die hochgerechnete Zahl an **Arbeitslosen** betrug der relative Stichprobenfehler im Jahr **2004** je Bundesland:

Übersicht 2

Bundesland	Arbeitslose im 4. Quartal 2004	Relativer Stichprobenfehler in % bei 95% statistischer Sicherheit	Arbeitslose im Jahresdurchschnitt 2004	Relativer Stichprobenfehler in % bei 68% statistischer Sicherheit
Burgenland	7.800	*19,6*	7.300	*6,9*
Kärnten	11.200	*19,1*	11.900	*6,2*
Niederösterreich	29.700	*21,4*	32.000	*6,8*
Oberösterreich	22.300	*25,6*	25.000	*7,2*
Salzburg	9.500	*24,6*	9.600	*7,7*
Steiermark	22.000	*21,2*	20.900	*7,9*
Tirol	12.100	*21,8*	11.100	*7,8*
Vorarlberg	7.700	*20,1*	7.400	*7,3*
Wien	73.400	*14,2*	69.300	*5,3*

Durch den Vergleich des relativen Stichprobenfehlers von hochgerechneten Häufigkeiten von Personen aus den obigen Übersichten mit den grob geschätzten Werten gemäß Tabelle 4 ergibt sich, dass bei einer genaueren Fehlerrechnung von Quartalswerten der relative Fehler bei den betrachteten Merkmalen um 10% bis 20% höher ausfällt als bei einer groben Schätzung mit Hilfe der Tabelle 4.

[7]) Für die Schätzung wurde sowohl ein in der STATISTIK AUSTRIA erstelltes SAS-Programm verwendet, das methodisch auf V. Verma: The Estimation and Presentation of Sampling Errors, UN World Fertility Survey, Technical Bulletins No. 11, New York 1982 beruht als auch das von Statistics Sweden entwickelte Programm CLAN 97.

Für **Jahresdurchschnittswerte** errechnet sich der relative Stichprobenfehler $\varepsilon(x_J)$ aus dem relativen Stichprobenfehler eines Quartalswerts $\varepsilon(x_Q)$ näherungsweise nach der Formel:

$$\varepsilon(X_J) = \varepsilon(X_Q)\sqrt{\frac{4 + 2\sum_{i>j} P_{ij}\,R_{ij}}{16}}$$

Dabei bezeichnet P_{ij} die Überschneidung der Stichproben der Quartale i und j und R_{ij} die Korrelation der Merkmalswerte zwischen den Quartalen i und j. Unter der Annahme, dass die R_{ij} nicht allzu unterschiedlich sind, und da die P_{ij} bei einer Fünftelrotation von Quartal zu Quartal feststehen, vereinfacht sich die Formel zu:

$$\varepsilon(x_J) = \varepsilon(x_Q)\sqrt{\frac{4 + 8\bar{R}}{16}}$$

Für $\bar{R} = 1$ gilt daher $\varepsilon(x_J) = \varepsilon(x_Q)\sqrt{0{,}75}$

(siehe hiezu L. Kish (1965), Survey Sampling, S. 466 ff.).

Den relativen Stichprobenfehler von Jahresdurchschnittswerten hochgerechneter Wohnungs- und Personenzahlen kann man also näherungsweise bestimmen, indem man die Werte der *Tabellen 3 und 4* mit dem Faktor $\sqrt{0{,}75} \approx 0{,}85$ multipliziert. Bei diesem Vorgehen liegt man zumindest bei Wohnungsmerkmalen auf der sicheren Seite, d.h. die mit diesen Werten berechneten Vertrauensbereiche schließen den wahren Wert mit mindestens 95% statistischer Sicherheit ein.

In der Übersicht 2 sind die aus dem Mikrozensus hochgerechneten Arbeitslosen je Bundesland im 4. Quartal und im Jahresdurchschnitt 2004 mit ihrem Stichprobenfehler ausgewiesen. Der Stichprobenfehler ist für die Quartalswerte für eine statistische Sicherheit von 95% ausgewiesen (wie in den Publikationen der STATISTIK AUSTRIA üblich) und für die Jahresdurchschnitte für eine statistische Sicherheit von 68% (wie meist von EUROSTAT publiziert). Der relative Stichprobenfehler der Arbeitslosenzahlen (bei 68% statistischer Sicherheit) liegt im Jahresdurchschnitt in jedem Bundesland unter den in der Verordnung (EG) Nr. 577/98 verlangten 8%.

Das derzeitige Design des österreichischen Mikrozensus erfüllt auch die zweite von der EU festgelegte Genauigkeitsanforderung, dass nämlich die Ungenauigkeit der Schätzung einer Veränderung zwischen zwei Quartalen auf nationaler Ebene höchstens 3% betragen darf, sofern es sich um Bevölkerungsgruppen handelt, die 5% der Bevölkerung im erwerbsfähigen Alter entsprechen (für Österreich sind dies ca. 275.000 Personen). Eine Bevölkerungsgruppe dieses Umfangs ist etwa die Masse der selbständig Erwerbstätigen ohne Arbeitnehmer. Die Veränderung dieser Gruppe zwischen zwei benachbarten Quartalen wird für Österreich insgesamt mit einer Fehlermarge von 2,4% geschätzt.

Summary

Starting with 2004 the Austrian micro-census was completely reorganized. The present article deals with methodological and practical aspects of the sample design, of sample selection and of grossing up and variance estimation of the "new" micro-census. The sample design is regionally stratified and within each stratum a given number of private households is randomly selected. Each quarter the most recent copy of the Austrian central registration register is used as frame of selection (each quarter rotates one fifth of the total sample size in and out). The response rate was about 90% in 2005. For the estimation of the results weights are used which are calibrated with the population counts of the register of residents and with household forecasts of STATISTICS AUSTRIA. Calibration is done by iterative proportional fitting. For variance estimation for totals of persons and households some simple methods are presented. For some main results of the micro-census (e.g. number of unemployed) a more exact variance estimation was done, which proves that the Austrian micro-census fulfills the requirements for the relative standard error stipulated in the EU regulation Nr. 577/98.

AUSTRIAN JOURNAL OF STATISTICS
Volume 34 (2005), Number 4, 327–343

Das Datenmanagement im neuen Mikrozensus – Eine Prozessbeschreibung

Winfried Moser
Statistik Austria, Vienna

Abstract: The Austrian microcencus, by now existing for more than thirty years, has been redesigned completely at the beginning of the year 2004. This article gives an overview about the rearrangement in the area of data-editing and describes the basic structures of relevant subprocesses (data-transformation, plausibility-checks, imputation). The implementation of these processes had to meet input requirements concerning automation, transparency and expandability. This article also deals with the implications of these basic preconditions for the configuration of the data-editing.

Zusammenfassung: Mit Anfang des Jahres 2004 wurde der seit nunmehr über dreißig Jahren bestehende Mikrozensus grundlegend umgestaltet. Der vorliegende Artikel gibt einen Überblick über die Neugestaltung im Bereich des Datenmanagements. Es werden die Grundstrukturen der verschiedenen für die Aufarbeitung notwendigen Teilprozesse (Datentransformation, Plausibilitätsprüfungen, Imputation) beschrieben. Die Umsetzung dieser Prozesse erfolgte unter den Vorgaben Automatisierbarkeit, Transparenz und Ausbaufähigkeit. In dem Artikel wird auch auf die prozesstechnischen Implikationen eingegangen, die diese Grundvoraussetzungen auf die Gestaltung des Datenmanagements haben.

Keywords: Mikrozensus, Imputation, Datenmanagement, SPSS.

1 Einleitung

Die Statistik Austria führt seit nunmehr über dreißig Jahren die größte Stichprobenerhebung Österreichs durch, in der jedes Quartal die Mitglieder von etwa 20.000 Haushalten befragt werden: den Mikrozensus. Mit Anfang des Jahres 2004 wurde diese Erhebung grundlegend umgestaltet. Ein wichtiger Grund dafür liegt in der Vorgabe, die Mikrozensus-Stichprobe gleichmäßig auf die Kalenderwochen eines Jahres zu verteilen (EU-Verordnung Nr. 577/98, Erwerbs- und Wohnungsstatistik-Verordnung – EWStV) – die Organisation des alten Mikrozensus war für die Anforderungen einer kontinuierlichen Erhebung nicht geeignet.

Zu den wichtigsten Neuerungen zählen:

(a) Auswahl für die Stichprobe bildet ab 2004 das Zentrale Melderegister (ZMR) und nicht mehr die Volkszählungsdaten. Dieses Register bietet auf längere Sicht eine bessere Voraussetzung für Stichprobenziehungen. Pro Kalenderwoche kommen rund 1700 Haushalte in die Stichprobe.

(b) Jeder Haushalt bleibt fünf Quartale lang in der Stichprobe (vor 2004: acht Quartale). Die Erstbefragung erfolgt face-to-face, Erhebungsinstrument bleibt weiterhin ein Papierfragebogen, der aber völlig neu konzipiert wurde. Für die Folgebefragung wurde ein

Telefonstudio eingerichtet, als Software kommt dabei das vom Nationalen Statistischen Institut der Niederlande entwickelte Programm BLAISE zum Einsatz.

(c) Erhebung und Aufarbeitung des alten Mikrozensus stammen konzeptuell im Wesentlichen aus den 1970er-Jahren. So wurde die Datenerfassung mittels scannerfähiger Papierbelege bewerkstelligt, die Datenaufarbeitung wurde am Großrechner durchgeführt. Die technische Entwicklung machte hier eine Neukonzeption dringend notwendig. Ab 2006 wird bei den face-to-face-Interviews CAPI eingesetzt werden, für das Datenmanagement wurde eine PC-basierte Lösung geschaffen[1].

Ich möchte hier *einen* der genannten Punkte näher beleuchten – das neue Datenmanagement. Der Prozess war von Grund auf neu aufzubauen und bei der Entwicklung musste – neben der Beschäftigung mit vielen Detailproblemen – eine Reihe von Basislösungen gefunden werden. Ziel des Artikels ist es, diese Problemstellungen und Basislösungen in einer möglichst verallgemeinerten Form vorzustellen.

Unter Datenmanagement wird hier die *strukturelle Grundlage* verstanden, innerhalb der alle notwendigen Prozessschritte durchgeführt werden können, um aus vorliegenden Rohdaten ein auslieferbares Datenfile zu erstellen. Zu den notwendigen Prozessschritten gehören insbesondere Plausibilisierung und Imputation – eine Thematik, auf die in der Statistik Austria schon immer besonderes Augenmerk gelegt wurde. Der Artikel wird sich allerdings nur am Rande mit diesbezüglichen methodischen Aspekten befassen, das Hauptaugenmerk soll auf der Beschreibung der Gesamtprozessstruktur des Datenmanagements liegen, in die Plausibilisierung und Imputation eingebettet sind.

Ein wichtiger Grundsatz bei der Konzeption des Datenmanagements war: Es soll mit dem gesamten System ein solider Standard für den Mikrozensus geschaffen werden, der einen möglichst großen Spielraum für Weiterentwicklung und Weiterausbau offen lässt. Eine besondere Schwierigkeit bei der Entwicklung war der Umstand, dass der Prozess der Datenaufarbeitung für eine große Zahl von Variablen weitestgehend automatisiert ablaufen muss. Das ist schon allein deshalb notwendig, weil EUROSTAT für den Mikrozensus eine Lieferfrist von drei Monaten nach Quartalsende vorschreibt – das sind nur sechs Wochen nach Eingang der letzten Interviews. Für die Variablen des *Grundprogramms* im alten Mikrozensus gab es schon vor 2004 eine solche Prozessautomatisierung. Das betraf damals jedoch nur einen Satz von 24 Variablen, der über die Jahre hinweg weitgehend stabil geblieben ist (im Wesentlichen seit 1967 mit einer einzigen größeren Änderung im Jahr 1994)[2]. Das Frageprogramm im neuen Mikrozensus ist demgegenüber deutlich größer – es umfasst derzeit über 150 Variablen, die durch eine komplexe Fragebogenstruktur miteinander in Verbindung stehen.

Darüber hinaus unterliegt der neue Variablensatz von Quartal zu Quartal stärkeren Änderungen als das einstige Grundprogramm. Diese änderungen müssen *vor* einer Prozessautomatisierung abgefangen werden. Wie dabei vorgegangen wurde, wird im Folgenden beschrieben.

[1] Eine detaillierte Beschreibung der strukturellen Änderungen liefern Kytir and Stadler (2004, S. 511 ff.)

[2] Seit 1994 wurde die Arbeitskräfteerhebung, die seit 2004 in das Grundprogramm des Mikrozensus eingebunden ist, einmal jährlich (im Frühjahr) durchgeführt. Vgl. dazu Bartunek (1994, S. 905 ff.)

2 Beschreibung der Programm- und Prozessstruktur

Die Programmierung des Datenmanagements erfolgte in der Syntaxsprache des Statistikpaketes SPSS. Es wurde damit – aufgrund der besseren Integration von Datenaufarbeitung und Analyse – eine PC-basierte Lösung geschaffen, die die Aufarbeitung am Großrechner ersetzt.

Die wichtigsten Elemente des Gesamtprozesses sind in Abbildung 1 dargestellt. Die Beschreibung der Programm- und Prozessstruktur wird sich weitestgehend an der dort dargestellten Struktur orientieren. Die Elemente sind (1) die Erstellung eines internen Standardrecode-Files („Extraktion“), (2) der Plausibilisierungsblock, (3) der Imputationsblock (mit nach Variablen verschiedenen Imputationsmethoden) und (4) die Erstellung der verschiedenen User-Files, in dem zum Einen standardmäßig zusätzlich generierte Variablen wie Hochrechnung, sozialgeographische Informationen und sonstige abgeleitete Variablen eingebaut werden und zum Anderen bestimmte Informationen wieder verschlüsselt oder ausgeblendet werden (für externe Nutzer).

Es sollte anhand der Darstellung deutlich werden, dass die gesamte Datenmanagementprogrammierung in einer Art „Containerbauweise“ erstellt ist, sodass bestimmte Änderungen oder Erweiterungen, die im Wesentlichen die Prozessschritte Extraktion, Plausibilisierung und Imputation betreffen, gut möglich sind.

2.1 Generelle Namens- und Programmierkonventionen

Innerhalb der dargestellten Strukturen sind die derzeit etwa 450 Syntaxdateien des Systems angeordnet. Um den Überblick zu bewahren, wurden sowohl auf Syntax- als auch auf Variablenebene spezielle Namenskonventionen erarbeitet. Auf der *obersten Strukturierungsebene* gibt es die fünf unterschiedlichen Präfixe meta., proz., var., pla., und imp., die auf die Position rückschließen lassen, die die jeweilige Syntaxdatei in der dargestellten Struktur einnimmt. meta.- und proz.-Dateien gehören zur Prozesssteuerung, var.-, pla.- und imp.-Dateien referenzieren auf Variablenextraktion, Plausibilisierung und Imputation einzelner Variablen.

Tabelle 1: Systematisierung der Syntax durch Syntaxpräfixe

meta.	Globale Prozeduren und Variablen, Strukturelle Syntax
proz.	Produktionssyntax
var.	Variablenselektion
pla.	Plausibilisierung
imp.	Imputation

2.1.1 Die Datengenerationen

Um später nachvollziehen zu können, was in welchem Schritt passiert, werden Zwischenergebnisse des Prozesses in unterschiedlichen Files mit einer generalisierten Benennung

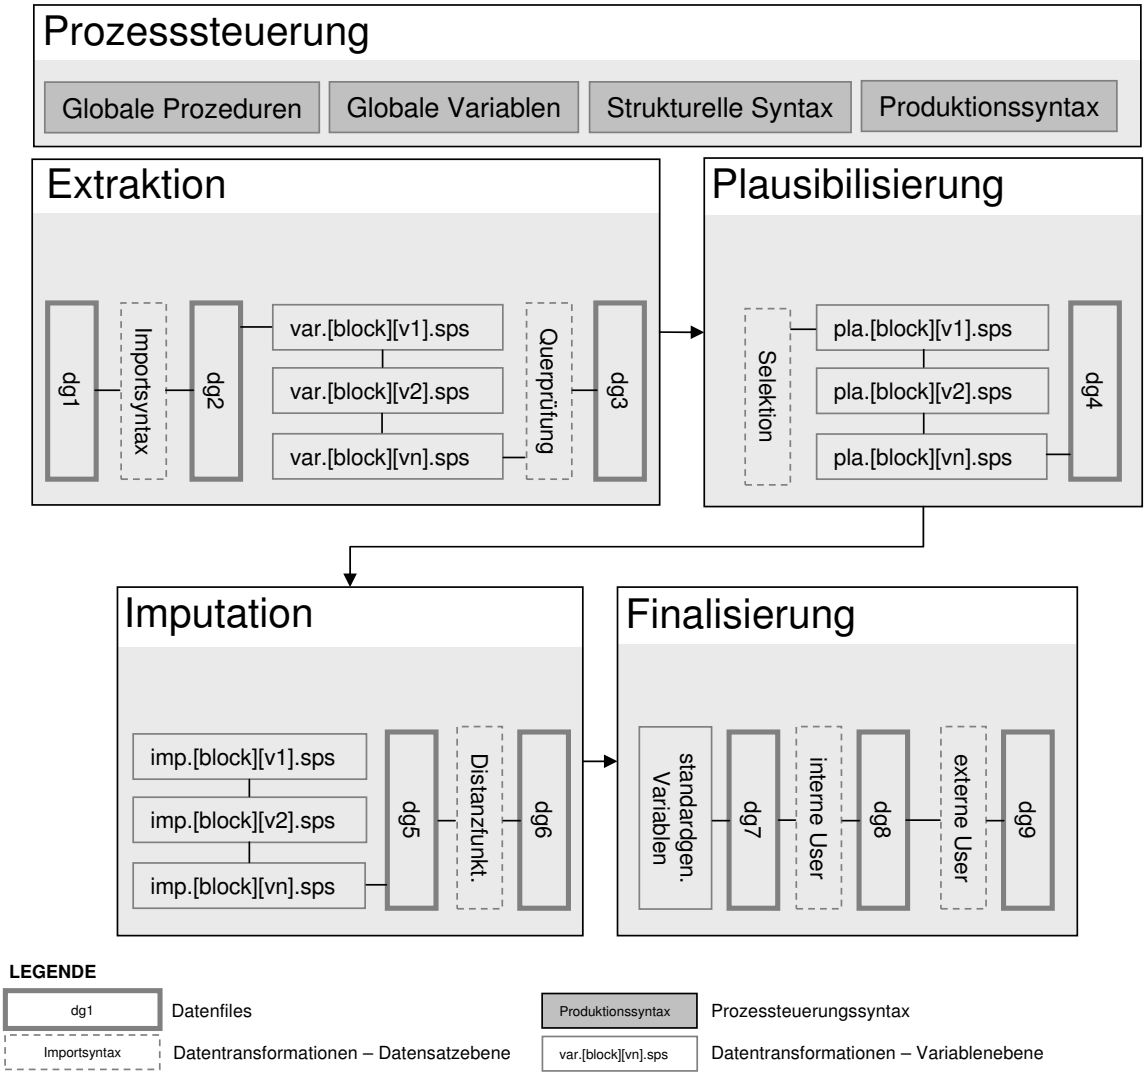

Abbildung 1: Darstellung der Prozessstruktur des Datenmanagements für den neuen Mikrozensus

abgelegt: Ein Präfix (dg1 bis dg9) kennzeichnet die Position im Prozess, an der das jeweilige File erstellt wurde, daran anschließend wird im Dateinamen Jahr und Quartal der jeweiligen Erhebung indiziert. Das Kürzel „dg“ steht für „Datengeneration“. Die angesprochenen Namenskonventionen haben sich mittlerweile etabliert und ersetzen umständliche Benennungen der unterschiedlichen Datenbestände. Als Beispiel: Die geplausten und nicht imputierten Daten des zweiten Quartals des Jahres 2004 finden sich in der Datei *dg4.mz2004q2.sav.* Die verschiedenen Datengenerationen sind folgendermaßen definiert:

Datengeneration 1 enthält das rohe Flatfile, das von der Exportschnittstelle der CATI-Software (Blaise) erstellt wird. Es entspricht in seiner Struktur nicht mehr der ursprünglichen Blaise-Datenbank, in der die Informationen auf Haushaltsebene verspeichert sind. Antworten auf *eine* bestimmte Frage werden damit zum Beispiel im Fall eines Drei-Personen-Haushalt in der Zeile des gegebenen Haushalts drei mal getrennt verspeichert. Mittels einer Prozedur, die im Blaise eigens erstellt werden muss, werden diese Informa-

tionen in der dg1 auf Personenebene gebracht.

Datengeneration 2: Mit „Camäleon“, einem Blaise-Modul, wird automatisch eine SPSS-Einlesesyntax generiert, mit der die dg1 in die SPSS-lesbare und gelabelte dg2 überführt wird. Dieses File umfasst etwa 700 Variablen, der größte Teil davon sind Systeminformationen. Die Datengenerationen eins und zwei werden automatisiert einmal wöchentlich erzeugt. Sie beinhalten neben den bei der Befragung erhobenen Daten auch Grundinformationen über Haushalte, die im Zuge der Befragung nicht erreicht wurden (Alter und Geschlecht der Haushaltsmitglieder aus dem zentralen Melderegister). Die in dem vorliegenden Artikel beschriebenen Prozesse setzen auf die dg2 auf.

In **Datengeneration 3** erfolgt der erste starke Eingriff in die Daten: Die Variablenextraktion. Im Wesentlichen werden hier Variablenstrukturierung und Missingsystematisierung durchgeführt. Eine genauere Beschreibung der entsprechenden Vorgänge finden sich im Abschnitt 2.3 „Die Basis des Systems: Die Transformation der Rohdaten“.

Datengeneration 4 wird erstellt, nachdem alle Plausibilisierungsvorgänge abgeschlossen sind. Am Beginn des entsprechenden Prozessschrittes erfolgt auch die Auswahl der relevanten Datensätze. Ausgeschlossen werden Datenzeilen von (1) nicht befragten Haushalten, (2) von nicht mehr vorhandenen Personen, die noch in der Stichprobe sind und (3) von Personen, deren Daten bestimmte Qualitätskriterien nicht erfüllen.

Diese Datengeneration stellt das wichtigste Zwischenergebnis im Aufarbeitungsprozess dar. Zum Einen enthält es die plausiblen transformierten Rohdaten und zum Anderen sind hier auch sämtliche fehlenden Werte klassifiziert (siehe dazu Kapitel 2.3.2 „Missingsystematisierung: Die Standardisierung von Missing-Codes“). Dieses File ist für jene interessant, die mit den Daten Längsschnittanalysen durchführen wollen oder aus anderen Gründen unimputierte Daten brauchen. Aus diesem Grund wird es auch gemeinsam mit dem endgültigen Datenbestand *(Datengeneration 8)* veröffentlicht. Vor der Veröffentlichung werden sensible Informationen (z.B. genaues Geburtsdatum, Wohngemeinde) gelöscht bzw. vergröbert.

Datengenerationen 5 und 6 sind die ersten „vollständigen“ Files, in denen fehlende Werte mittels verschiedener Imputationsprozeduren durch plausible Werte ersetzt sind (logische Imputation, Hot-Deck und nachgelagert die Distanzfunktion).

In **Datengeneration 7** ist das fertige *interne* Datenfile. Hier werden verschiedene systemexterne Variablen eingebunden (z.B. geographische Informationen, Hochrechnung, etc.). Die Files bis zu dieser Datengeneration befinden sich im Datenmanagementordner und sind aus Sicherheitsgründen nur einem sehr kleinen Nutzerkreis zugänglich (derzeit sieben Personen).

In **Datengeneration 8** schließlich werden aus datenschutzrechtlichen Gründen bestimmte Informationen wieder entfernt bzw. vergröbert. Dieses File wird auf einem externen Ordner einem größeren Nutzerkreis zugänglich gemacht.

2.1.2 Programmierung auf Variablenebene

Ein zentraler Bestandteil der Prozessprogrammierung ist auch, dass es für jede einzelne der Variablen des internen Standardrecodefiles getrennt nach den Prozessschritte Extraktion, Plausibilisierung und Imputation eigene Files mit *wohldefinierten Namenskonventionen* gibt (Prozesspräfix-Variablenname). Diese Files werden dann durch eine übergeord-

nete Syntax sequenziell abgearbeitet. Dieses Vorgehen ist aus zwei Gründen nützlich: Einerseits, wenn man nachvollziehen will, was bei einer bestimmten Variable passiert ist und andererseits, wenn man Änderungen oder Weiterentwicklungen einbauen will.

Diese Nachvollziehbarkeit ist auch historisch gegeben. Der Mikrozensus ist ein lebendes System, das sich jedes Quartal ein wenig verändert, manchmal stärker, manchmal weniger stark. Die Syntax wird in jedem Quartal gemeinsam mit den Datenfiles abgelegt, und es kann später nachvollzogen werden, was in welchem Quartal mit den Daten passiert ist.

Dieses System der Syntax-Organisation hat übrigens auch einen Nachteil: Es muss deutlich extensiver programmiert werden. Prozessschritte, die sonst vereinfacht über mehrere Variablen hinweg programmiert werden können, müssen hier Variable für Variable extra erstellt werden. Der bisherigen Erfahrung nach überwiegen die genannten Vorteile jedoch diesen Nachteil deutlich. Letztlich soll es ja möglich sein, das ganze System im Falle eines Personalwechsels in andere Hände weiterzugeben, und dafür ist eine größtmögliche Transparenz der Programmierung nötig.

2.2 Der Kopf des Systems: Die Prozesssteuerung

Über allem steht die Prozesssteuerung, in der einerseits eine Reihe von Prozeduren und Programmvariablen definiert sind, auf die im allgemeinen Ablauf immer wieder zurückgegriffen wird (globale Prozeduren und Parameter) und in der andererseits der Ablauf der Prozedur zentral geregelt wird (strukturelle Syntax). Darüber hinaus befinden sich im Rahmen der Prozesssteuerung noch die verschiedenen Produktionssyntaxdateien, mittels derer Spezialauswertungen produziert werden.

Um diese doch sehr theoretische Beschreibung mit Inhalt zu füllen, einige Beispiele:

(1) *Globale Prozeduren:* Im Zuge des Aufarbeitungsprozesses ist es sehr oft notwendig, bestimmte Subgruppen im Datensatz zu aggregieren und das Ergebnis dieser Aggregierung wieder den Individuen der jeweiligen Subgruppen zuzuordnen (etwa: jedem Mitglied eines Haushalts das Durchschnittsalter dieses Haushalts zuordnen). Eine derartige Prozedur gibt es im SPSS bislang nicht. Deshalb wurde für diesen speziellen Zweck eine Prozedur erstellt, die in der Datei meta.deklarationen.sps abgelegt wird (eine Sammeldatei für zahlreiche solcher Prozeduren). Bevor die Aufarbeitung gestartet wird, muss diese Datei geladen werden, und im Bedarfsfall wird mit einem deutlich vereinfachten Befehl auf die jeweilige Prozedur zurückgegriffen.

(2) *Globale Parameter:* Bei jedem Quartalswechsel wird ein neuer Ordner erstellt, der sich auf das jeweilige Quartal bezieht. Damit ändern sich jedes Quartal auch die Pfade, unter denen bestimmte Dateien abzulegen sind. Aus diesem Grund werden in der Datei meta.pfade.sps alle vom Programm benötigten Pfade zentral definiert. In der Prozessprogrammierung selbst greifen generalisierte Pfadvariablen dann auf die jeweils aktuellen Pfade in der genannten Datei zurück. Das selbe gilt für die Dateinamen.

(3) *Struktursyntax:* Aus Gründen, auf die ich später noch eingehen werde, sind Prozeduren, die Extraktion, Plausibilisierung oder Imputation von Variablen betreffen, „auf Variablenebene“ programmiert. Das heißt, es gibt für jede einzelne Variable und für jeden der genannten drei Prozessschritte eigene Syntaxfiles. Strukturelle Syntaxdateien fassen diese Einzeldateien wieder zusammen und definieren den sequenziellen Ablauf der Ab-

arbeitung dieser Dateien. Eine Datei dieser Art (meta.steuerungszentrum.sps) steuert den Gesamtablauf der Prozeduren.

(4) *Produktionssyntax:* Es gibt eine Vielzahl denkbarer Spezialauswertungen, die in einem Aufarbeitungsprozess notwendig sind. Eine solche Syntax-Datei etwa erstellt automatisch eine Liste von Personen, bei denen das Geschlecht offensichtlich falsch eingetragen war, auf die Erhebungsseitig zugegriffen werden kann. Eine andere produziert eine Spezialauswertung der Daten, die zur Berechnung des Verbraucherpreisindex benötigt wird. Eine dritte erstellt durch eine spezielle Aggregierung der Daten einen Überblick die verschiedenen Arten von fehlenden Werten. Die jeweiligen Dateien werden von der Struktursyntax an den geeigneten Positionen im Datenproduktionsprozess aufgerufen.

2.3 Die Basis des Systems: Die Transformation der Rohdaten (Extraktion)

2.3.1 Standardisierung der Variablennamen und -inhalte

Die wichtigste strukturelle Vorbedingung für ein automatisiertes Datenmanagement sind standardisierte und stabile Variablennamen und Codierungen. Es ist ein Hauptzweck der Extraktion der Rohdaten, diese Vorbedingung zu erfüllen. Es war eine sehr grundsätzliche Entscheidung, nicht mit den Rohdatenvariablen direkt zu arbeiten, sondern als ersten Schritt ein *internes Standardrecodefile* zu erstellen. Bei der Erstellung dieser Datei werden *standardisierte Variablennamen* mit bestimmten Namenskonventionen vergeben und gleichzeitig *Variableninhalte standardisiert*.

Dazu ein konkretes Beispiel: Die Mikrozensusfrage nach dem Wohnort vor einem Jahr besteht aus fragebogentechnischen Gründen aus vier verschiedenen Fragen: (1) „Haben Sie vor einem Jahr an der gleichen Adresse wie jetzt gewohnt?“, (2) wenn nein: „Haben Sie damals im gleichen Bundesland gewohnt?“, (3) wenn nein: „In welchem Bundesland haben Sie gewohnt?“ und (4) wenn kein Bundesland: „In welchem Staat haben Sie gewohnt?“. Diese Art der Fragestellung soll erhebungsseitig die Respondentenbelastung vermindern und auch die Interviewtätigkeit erleichtern – komplexe Fragen werden nur gestellt, wenn es unbedingt notwendig ist.

Es werden hier zwar vier Fragen gestellt, deren Antworten in den Rohdaten auch in vier verschiedenen Variablen verspeichert werden, es geht jedoch im Grunde nur um eine einzige Information: den Wohnort vor einem Jahr. Bei der Erstellung des internen Standardrecodefiles werden also die vier aus diesen Fragen resultierenden Variablen zu einer einzigen zusammengeführt. Im derzeitigen Mikrozensusfragebogen gibt es zahlreiche solcher Fälle; es geht hier darum, redundante Information zu minimieren. Der Schritt ist aus verschiedenen Gründen notwendig beziehungsweise vorteilhaft:

(1) Durch Änderungen der Fragebogenstruktur kann es – bedingt durch Programmkonventionen des Blaise (das Programm für die Erstellung des Cati-Fragebogens) – zu Verschiebungen der Variablennamen in den Rohdaten kommen. Wenn etwa an einer bestimmten Stelle im Fragebogen eine neue Frage eingefügt wird, verschieben sich die Variablennamen aller darauf folgenden Variablen des jeweiligen Fragenblocks. Auf dieser Grundlage ist keine standardisierte Plausibilitätsprüfung und Imputation möglich.

(2) Bestimmte Filterführungen im Fragebogen, bei denen es ausschließlich um die Re-

spondentenentlastung geht – wie etwa bei der vorhin vorgestellten Frage nach dem Wohnort vor einem Jahr – werden an dieser Stelle bereits abgefangen und müssen so bei Plausibilitätsprüfung und Imputation nicht mehr berücksichtigt werden. Die Durchführung dieser beiden Prozesse wird damit über weite Strecken erleichtert.

(3) Nachdem die Standardisierung der Variablen sich an Inhalten orientiert und damit Fragebogenkomplexitäten ausblendet, ist der Datensatz für jene die ihn analysieren, einfacher handhabbar. Es bleiben nach Abschluss der Prozedur auch deutlich weniger Variablen übrig.

Im alten Mikrozensus waren die Variablen nummeriert, was zwar programmiertechnisch praktikabel ist, aber auch einen großen Nachteil mit sich bringt: Neu hinzukommende Variablen bringen das Nummerierungssystem durcheinander, und es muss dann erst wieder zu alphanumerischen Bezeichnungen übergegangen werden. Eine inhaltliche Sortierung der Variablen ist auch schwer möglich. Deshalb wurde zu einem System mit folgender Namenskonvention übergegangen: [Blockbuchstabe][Variablenbezeichner]. Der Blockbuchstabe besteht aus einem Zeichen, der Variablenbezeichner sollte ein sprechendes Kürzel sein. Als Beispiel: bwov1j steht für die Variable „**W**ohn**o**rt **v**or **1** **J**ahr“ aus dem **B**-Block. Die derzeit bestehenden Blocks sind in Tabelle 2 dargestellt.

Tabelle 2: Blocks im neuen Mikrozensus

(a)	Stichprobeninformation
(w)	Wohnungserhebung
(b)	demographische Informationen
(c)	Bestimmung der Erwerbstätigkeit
(d)	derzeitige berufliche Tätigkeit
(e)	Zweittätigkeit
(h)	Arbeitssuche
(k)	Ausbildung
(j)	frühere Tätigkeit
(l)	Situation vor einem Jahr
(x)	wichtige Systemvariablen, nicht zuordenbare abgeleitete Variablen
(z)	Zusatzerhebung

2.3.2 Missingsystematisierung: Die Standardisierung von Missing-Codes

Als zweiter wichtiger Schritt werden in der Extraktion die Missings standardisiert und systematisiert. Die Missingsystematisierung ist die wichtigste Grundvoraussetzung für Plausibilitätsprüfung und Imputation. Letztlich ist dieser Schritt auch so etwas wie eine „Grundplausibilisierung“. Bezogen auf eine bestimmte Zelle im Datensatz geht es hier um die Fragen: „Warum steht hier kein gültiger Wert?“ bzw. „Warum steht hier ein Wert, obwohl per definitionem keiner hier stehen soll?“.

Die Missingsystematisierung gibt darauf eine Antwort. Grundsätzlich werden für fehlende Werte negative Codes vergeben. Nachdem negative Werte im Datensatz nicht vorkommen, wird damit auf einfache Weise verhindert, dass eine bestehende Codierung gleichzeitig als Missingcode verwendet wird.

Konkret geschehen an dieser Stelle folgende Prozesse: Zum einen werden die Blaise-Missingcodes standardisiert – im Blaise werden diese automatisiert vergeben. Sie können sich somit von Variable zu Variable unterscheiden, was für ein automatisiertes Datenmanagement wenig brauchbar ist.

Für die restlichen Zellen wird die Filterführung systematisch überprüft. Die Systematik unterscheidet zwischen befüllten und leeren Zellen und überprüft, ob der jeweilige Zustand (befüllt/leer) im Einklang mit den Routingregeln ist oder nicht. Auf Ebene der Routingregeln wird noch unterschieden, ob aufgrund eines regulären Werts aus der Befragung geroutet wurde oder aufgrund eines fehlenden Werts. Die Systematik ist übersichtlich in Tabelle 3 dargestellt, die Missingcodes, die sich daraus ergeben, sehen Sie in Tabelle 4.

Tabelle 3: Systematik der Missingkategorien

	In der Zeile steht ...	
Mit Routingregeln ...	ein Wert	ein Missing
übereinstimmend (normales Routing)	gültiger Wert	-3
nicht übereinstimmend (normales Routing)	-4	-5
übereinstimmend (Missingrouting)	gültiger Wert	-6
nicht übereinstimmend (Missingrouting)	-10	-5

Tabelle 4: Systematisierung der fehlenden Werte

Code	Label	Inhalt
-1	Verweigert	aus CATI oder Papierfragebogen
-2	Weiß nicht	aus CATI oder Papierfragebogen
-3	Filter	fehlende, die per definitionem fehlen müssen
-4	Filter gelöscht	Werte, die per definitionem Filter sein müssen
-5	Unbekannt (System)	nicht zuordenbare fehlende Werte
-6	Filter Missingrouting	gefiltert aufgrund eines fehlenden Werts
-7	Teilmissing	aus einer zusammengeführten Variable fehlt ein Wert
-9	Unplausibel	wird bei der Plausibilitätsprüfung zugeordnet
-10	Filter gelöscht Missingrouting	Werte, die aufgrund eines Missingroutings Filter sein müssen

Die Kategorisierungen mögen teilweise komplex erscheinen, sie sind jedoch nur ein Zwischenergebnis auf dem Weg zum authentischen Datenbestand, das die Analyse der Daten und das Zusammenspiel der verschiedenen beteiligten Programmierer erleichtert. Vor allem der letztere Punkt ist wichtig: Blaise- und SPSS-Programmierung erfolgen unabhängig voneinander, müssen jedoch möglichst gut zusammenspielen.

2.4 Damit alles seine Richtigkeit hat: Die Plausibilitäts-Prozeduren

Die Prozeduren im Einzelnen zu beschreiben würde wohl den Rahmen dieses Artikels sprengen, darum wird die Beschreibung hier eher kursorisch bleiben. Bei Plausibilitätsprüfungen ist ein axiomatisches Grundproblem zu berücksichtigen: *Ist das Ergebnis einer*

Plausibilitätsprüfung, in die zwei oder mehr Variablen einbezogen sind, negativ, so ist daraus nicht ableitbar, welche der Variablen den falschen Wert beinhaltet.

Dieses Problem könnte man – relativ aufwändig – lösen, indem man jede der geprüften Variablen mit einem Satz weiterer Variablen plausibilisiert. Jene Variable, bei der eine größere Anzahl von Prüfungen negativ ausgeht, wird dann mit größerer Wahrscheinlichkeit den falschen Wert beinhalten. Das würde bedeuten, dass von Fall zu Fall entschieden wird, welcher Wert zu löschen ist. Man könnte in den entsprechenden Fällen auch nachtelefonieren, wie das bei manchen Surveys auch passiert. Weil es beim neuen Mikrozensus jedoch – neben einer möglichst weitgehenden Richtigkeit der Einzelinformationen – auch darum geht, dass der Datensatz in sehr kurzer Zeit auslieferbar ist, haben wir uns für eine einfachere Lösung entschieden, und zwar aus mehreren Gründen:

(1) Die oben genannten Möglichkeiten wären für den neuen Mikrozensus in der Phase des Systemaufbaus technisch schwer umsetzbar gewesen.

(2) Grundlegend lösbar ist diese Problemstellung nur im Zuge der Erhebung: Baut man die Plausanweisungen direkt in die Erhebungssoftware ein, ist es möglich, durch Nachfragen in der Befragungssituation den „richtigen falschen Wert“ zu bestimmen. Ist es der zeitlich früher erhobene Wert, muss der Fragebogen von der entsprechenden Stelle an ein weiteres Mal durchlaufen werden – die Befragten werden in so einem Fall also zurückgeroutet. Es gibt bereits sehr viele Plausibilitäts-Checks im Blaise. Kommen im Zuge der Aufarbeitung größere Ungereimtheiten in der Datensatzstruktur zum Vorschein, werden die Blaise-Checks entsprechend erweitert.

(3) Solange der Anteil der unplausiblen Werte relativ niedrig ist, ist es statistisch irrelevant, welcher Wert gelöscht wird. Ist der Anteil aber hoch, deutet das meist auf grundlegendere Probleme bei der Erhebung hin, etwa auf eine schlecht umgesetzte Fragestellung. Auch eine noch so durchdachte Plausibilitätsprüfung kann hier nur wenig helfen.

Ein wichtiger Teil der Plausprüfungen – jener, der mit der Filterführung zu tun hat – wird schon bei der Variablenextraktion durchgeführt (siehe Kapitel 2.3.2 „Missingsystematisierung“). Bei diesem Teil wird hierarchisch vorgegangen. Das heißt, wichtige Variablen, aufgrund derer gefiltert wird (Alter, Präsenzdienst, Erwerbstätigkeit u. ä.), werden mit Ausnahme ein paar kleinerer Checks grundsätzlich als richtig angenommen. Das ist anders als im alten Mikrozensus, wo zum Beispiel bei Altersplausprüfungen aufgrund bestimmter Regeln manchmal auch die zweite Information als richtig angenommen und das Alter gelöscht wurde. Ein so komplexes Vorgehen ist beim neuen Mikrozensus nicht notwendig. Da durch die CATI-Struktur die Daten sequenziell verspeichert werden, kann – zumindest auf Ebene der Filterführung – auch die Überprüfung sequenziell geschehen.

Der zweite Plausibilisierungsschritt – die Prüfung auf konsistentes Antwortverhalten der Respondenten hinsichtlich unterschiedlichster Aspekte bzw. automatische Umcodierungen bestimmter Variablen – erfolgt erst im Anschluss an den vorhin beschriebenen Schritt. Hier werden gemeinsam mit den Fachleuten für die jeweiligen Themen laufend Plausanweisungen entwickelt und in den Prozess eingebaut. Die Plausibilitätsprüfungen werden so sukzessive genauer. Durch die Programmierung auf Variablenebene ist auch der nachträgliche Ein- und Weiterausbau von Plausprozeduren leicht möglich und durch das Abspeichern der Syntax mit den Datenbeständen des jeweiligen Quartals können Änderungen und Weiterentwicklungen relativ einfach nachvollzogen werden.

Derzeit erfolgt die Plausibilisierung nur Datensatzintern. Möglichkeiten für eine Wei-

terentwicklung der Plausprüfungen bieten vor allem die Einbindung von Administrativdaten und quartalsübergreifende Prüfungen.

2.5 Der Imputationsblock: Automatisierung und Kohärenz

2.5.1 Einleitung

Die Imputation von Werten kann von zwei Seiten beleuchtet werden – von einer wissenschaftlich-statistischen und von einer praktischen. Erstere soll hier jedoch soweit wie möglich ausgeblendet bleiben, da es Zweck des Artikels ist, die *praktischen* Erfordernisse des Datenmanagements eines großen Surveys zu beschreiben. Nicht zuletzt ergeben sich aus diesen praktischen Erfordernissen oft auch Restriktionen für die Umsetzung wissenschaftlicher Ansprüche.

Es gibt zwei wichtige Gründe für eine Imputation. Aus wissenschaftlicher Sicht geht es um die Verbesserung der Schätzung von Messgrößen – durch Imputation kann, wenn sie gut gemacht ist, Bias ausgeglichen werden. Aus Sicht des Datenhandlings ist es für den Nutzer angenehm, wenn er bei seinen Berechnungen mit stabilen Eckzahlen operieren kann – das ist ohne Imputation nicht möglich.

Man muss sich natürlich auch dessen bewusst sein, dass durch die Imputation Zusammenhänge zwischen Variablen verfälscht werden können. Dieses Problem ist aber nicht gravierend, da der Anteil der imputierten Variablen kaum jemals über 5 Prozent hinausgeht. Interessiert man sich explizit für Zusammenhänge zwischen Variablen, ist auch die dg4 – also der Datensatz mit den plausibilisierten und nicht-imputierten Werten – eine gute Option.

Aus praktischer Sicht gibt es für eine Imputationsprozedur zwei wichtige Kriterien: Zum Einen muss ihre Durchführung *in einen automatisierten Prozessablauf* eingebunden werden können und zum Anderen muss dabei *die logische Kohärenz der Datensätze* gewahrt bleiben.

Die *Automatisierung* der Imputation ist aus Sicht des Mikrozensus unabdingbar, weil hier regelmäßig etwa 150 verschiedene Variablen zu imputieren sind. Das Postulat der *logischen Kohärenz der Datensätze* bedeutet, dass bei den Imputationsprozeduren wie bei den Plausprüfungen eine relativ komplexe Fragebogenstruktur sowie wichtige Interdependenzen zwischen Variablen zu berücksichtigen sind. (1) Das bedeutet – im einfachsten Fall – dass beispielsweise einem Präsenzdiener im Zuge der Imputation nur Werte zugewiesen werden dürfen, die er bei der Befragung aufgrund der Fragebogenroutings *theoretisch* auch bekommen könnte[3]. (2) Und es heißt auch, dass einer Person nur *ein*

[3]Es gibt deutlich kompliziertere Fälle, wie etwa die Imputation des Jahres, in dem die jeweils höchste Bildungsstufe abgeschlossen wurde (kjahr). Kohärenz bedeutet hier, dass das Jahr, in dem diese Ausbildung abgeschlossen wurde, in einem sinnvollen Zusammenhang mit dem Geburtsjahr und der Art der Ausbildung der betreffenden Person stehen muss. Ein Hotdecking, in das Geburtsjahr und Art der Ausbildung als Stratumsvariablen einfließen ist hier nicht möglich, da sich zu viele Stratumgsgruppen ergeben (ca. 80 Geburtsjahrgänge $\times$ 7 Ausbildungsarten = ca. 560 Strata). Aus diesem Grund wird aus den bestehenden Daten erst das Alter bei Abschluss der Ausbildung berechnet, dieses Alter wird danach mit Hotdeck imputiert, mit der Ausbildungsart als Stratumsvariable. Danach wird aus dem imputierten Alter wieder der Jahrgang berechnet.

bestimmter Wert zugewiesen werden darf, obwohl unter Umständen mehrere Werte plausibel und wahrscheinlich sind.

Ginge es nur um Parameterschätzung, wäre diese Vorgabe nicht unbedingt notwendig. Sie könnte in manchen Fällen – im Sinne der Schätzgenauigkeit – sogar kontraproduktiv sein. Für eine Parameterschätzung ist eine genaue Schätzung auf Ebene des Individualdatensatzes weniger wichtig als eine genaue Schätzung auf Aggregatebene. Darüber hinaus liefern bestimmte Schätzmethoden – wie etwa die multiple Imputation[4] – auf individueller Ebene gar keine eindeutigen Werte, dafür aber auf Aggregatebene stabilere Schätzungen[5].

Es wird jedoch trotzdem nicht auf dieses Postulat verzichtet, vor allem weil neben der Veröffentlichung von Schätzungen aus dem Mikrozensus auch anonymisierte Individualdaten weitergegeben werden – sowohl an EUROSTAT als auch an andere private und öffentliche Datennutzer. Die Nutzer sollen die veröffentlichten Schätzungen möglichst leicht nachvollziehen können. Eine Reproduktion von Schätzergebnissen unter Einbeziehung multipler Imputationstechniken wäre aber dem Nutzer kaum zumutbar. Ohne Reproduktionsmöglichkeit ist es aber deutlich schwieriger, Vertrauen in die Daten aufzubauen – ein Aspekt, der nicht unterschätzt werden sollte.

2.5.2 Grundsätzliches Vorgehen

Die wichtigste Entscheidung hinsichtlich der Imputation war, die Unit-Non-Response nicht durch Imputation auszugleichen, sondern durch Gewichtung. Die verbleibende Item-Non-Response wird zum größten Teil mit Hot-Deck[6] (siehe Kapitel 2.5.4) imputiert. Im Folgenden wird die Vorgangsweise kurz beschrieben:

(a) Als erstes verschaffen wir uns einen Überblick über die Non-Response-Situation. Dieser Schritt erfolgt, nachdem die Missingsystematisierung abgeschlossen ist, mittels einer eigens produzierten Überblickstabelle. In den Zeilen dieser Tabelle sind alle Mikrozensus-Variablen verzeichnet und in den Spalten die vorhin beschriebenen verschiedenen Typen von Missings. Anhand der Tabelle kann man dann die Häufigkeiten der verschiedenen Missingkategorien für einzelne Variablen ablesen und damit auch den Anteil der zu imputierenden Werte abschätzen. Genau bestimmen kann man diesen Anteil erst im Nachhinein, da vor der Imputation nicht bekannt ist, wie viele Werte gefiltert werden und damit nicht direkt ins Hot-Deck fallen.

(b) Danach wird imputiert: Durch ein sequenzielles Vorgehen wird sichergestellt, dass nur Werte imputiert werden, die im Einklang mit der Fragebogenstruktur (Filterführung) stehen. Es wird dabei sequenziell vorgegangen, weil *vor* der eigentlichen Imputation entschieden werden muss, ob ein fehlender Wert einen Filter bekommt oder nicht. Dafür müssen alle vorangehenden Informationen bereits vorhanden sein.

[4]Barnard et al. (1998, S. 2772 ff.)

[5]Das selbe gilt übrigens auch für die Hochrechnung: Aus arbeitstechnischen Gründen wird im Mikrozensus nur mit einem einzigen Gewicht gerechnet, obwohl es sich durchaus als sinnvoll erweisen könnte, für einzelne, wichtige Variablen eigene Gewichte zu berechnen.

[6]Lessler and Kalsbeck (1992, S. 213 ff.)

2.5.3 Abbildung der Filterführung in der Imputationsprozedur

Die Abbildung der Filterführung ist direkt in die Imputationsprozedur eingebunden. Letztlich ist sie ja selbst schon eine Art Imputation und eine nötige Grundvoraussetzung für das Hot-Decking, das mittels einer SPSS-Prozedur mit einem sehr einfachen Benutzerinterface durchgeführt wird (Abbildung 2). Ich werde dessen wichtigste Elemente kurz erklären:

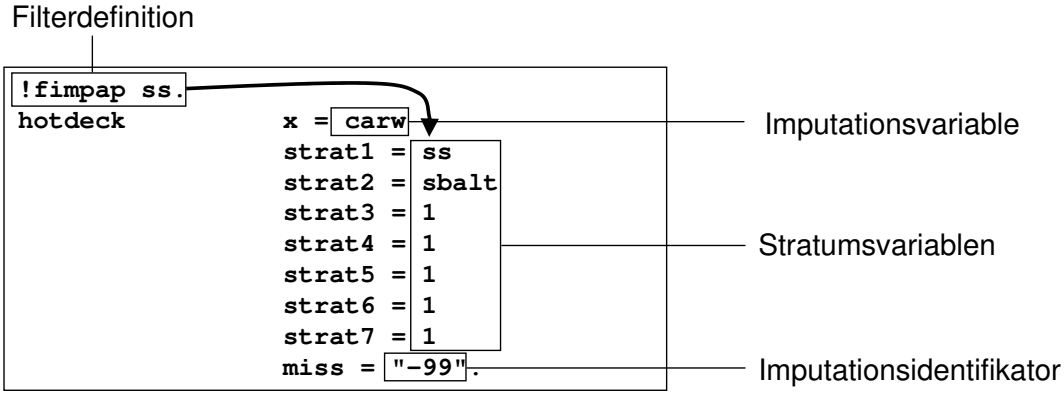

Abbildung 2: Das User-Interface für die SPSS-Hot-Deck-Prozedur

„x“ kennzeichnet die Variable, die man imputieren möchte. Unter „strat1“ bis „strat7“ legt man potenziell sieben Stratumsvariablen an und „miss“ definiert einen Identifikator für die Fälle, die man imputieren möchte. Dieser muss natürlich vorher in den Daten definiert werden. Die Filterführung wird direkt in diesem Prozeduraufruf in die Imputation eingebaut. In dem konkreten Fall werden mit dem Befehl „!fimpap“ unter 15-Jährige und Präsenzdiener angesprochen, die hier einen Filter bekommen. Diese Personen kommen in die eine Subgruppe, alle anderen in die zweite, und die resultierende Variable wird selbst als Stratumsvariable verwendet.

Danach folgt die Imputationsprozedur. Nachdem alle unter 15-Jährigen mit *gültigen* Werten einen Filter haben, bekommen auch die unter 15-Jährigen mit *fehlenden* Werten automatisch einen Filter. Auf der anderen Seite wird durch dieses Vorgehen verhindert, dass Non-Response-Fälle, die gültige Werte bekommen sollten, einen Filter imputiert bekommen. Man schlägt also programmtechnisch zwei Fliegen mit einer Klappe. Dieses Vorgehen hat den Vorteil, dass die „Plaus-Imputations-Schleife“[7] vermieden werden kann.

Die Filterführung ist übrigens für die wichtigsten Gruppen zentral definiert. Das heißt, sollte sie einmal geändert werden, muss man in der Syntax nicht Variable für Variable umprogrammieren, sondern kann das an zentraler Stelle tun.

[7] Alternierendes Durchführen von Plausibilitätsprozedur und Imputationsprozedur, um Fehlzuordnungen sequenziell zu verringern.

2.5.4 Die verschiedenen Imputationsprozeduren

Es wird im Moment mittels dreier verschiedener Verfahren imputiert:

Hot-Deck

Der größte Teil der Variablen wird mittels **Hot-Deck** imputiert. Ein kritischer Punkt beim Hot-Deck ist die Bestimmung der Stratumsvariablen. Im neuen Mikrozensus wurde mit der Deklaration von Sortiervariablen äußerst sparsam umgegangen. Der Grund dafür ist folgender: Grundvoraussetzung für eine sinnvolle Stratifizierung ist, dass zwischen der Sortiervariable und der zu imputierenden Variable ein Zusammenhang besteht. Es wurde also jede einzelne Variable des Datensatzes auf Zusammenhänge mit einem bestimmten Set von Sortiervariablen überprüft. Für eine Imputation wurden dann nur jene Merkmalskombinationen herangezogen, für die sich deutliche Zusammenhänge ergaben. Die entsprechenden Auswertungen wurden in dem Statistikpaket R vorgenommen, weil dieses Programm gegenüber dem SPSS deutlich breitere Möglichkeiten zur Metaanalyse von Daten bietet.

Es wurde dabei folgende Vorgangsweise gewählt: (a) Vorab wurden Geschlecht, Alter (in verschiedenen Kategorisierungen), Haushaltsgröße, Stellung zur Referenzperson, Größe der Wohnung, höchste abgeschlossene Ausbildung, Wirtschaftszweig, Beruf und Bundesland als Stratumsvariablen festgelegt. (b) Die genannten Stratumsvariablen wurden daraufhin überprüft ob sie mit der Imputationsvariable korrelieren und/oder ob diese Variablen in einen Zusammenhang mit dem Response/Missing-Verhalten stehen.

Die Bedingungen für die Auswahl einer Stratumsvariable waren: (a) Zellbesetzungen größer fünf für mindestens 80% der Schichten der Stratumsvariablen und (b) ein Cramers-V größer 0.2 in mindestens einer der beiden überprüften Zusammenhänge. Die verbleibenden Stratumsvariablen wurden dann „händisch“ und nach Sinnhaftigkeit ausgewählt.

Abschließend ist zu diesem Punkt zu sagen, dass es hier noch zahlreiche Ausbaumöglichkeiten gibt. Unser Vorgehen mag einfach erscheinen, es sind jedoch zwei Dinge zu bedenken: Einerseits mussten wir in einem relativ kurzen Zeitraum zu passablen Ergebnissen für eine große Zahl von Variablen kommen. Das heißt, die Entwicklung komplexer Imputationsprozeduren für einzelne Variablen war schwer möglich und wurde nur dort durchgeführt, wo mit Hot-Deck keine befriedigenden Ergebnisse zu erzielen waren (Haushaltsrelationsvariablen). Andererseits gibt es nach unseren Recherchen auch in der statistischen Fachliteratur keine Vorschläge für ein standardisiertes Vorgehen bei der Auswahl von Stratumsvariablen für Hot-Deck-Prozeduren. Hier scheint es also auch an Grundlagenforschung zu mangeln.

Imputation von Haushaltszusammenhängen

Für die Imputation von Haushaltszusammenhängen eignet sich Hot-Deck nicht. Hier wird mittels eines **logischen Verfahrens** imputiert: Anhand der Grundparameter Alter, Geschlecht und Stellung zur Referenzperson jener Person, für die imputiert wird, und jener Personen, zu denen diese potenziell in Relation stehen kann, wird mittels unterschiedlicher Regeln versucht, bestimmte wichtige Relationen zuzuweisen. Als erstes wird geprüft, ob die betreffende Person einer anderen Person im Haushalt als Partner zuordenbar ist, danach, ob sie als Kind in Frage kommt, und als letztes, ob sie Elternteil von einer anderen Person sein könnte. Das Vorgehen ist ziemlich komplex und wird in einem eigenen Artikel zur Methodologie der Imputation und Ableitung von Haushalts- und

Familienrelationen gesondert beschrieben werden.

Distanzfunktion

Für einige wenige Fälle haben wir uns dafür entschieden, per **Distanzfunktion** vollständige Fälle zu ersetzen. In diesen Fällen, in denen einige wichtige Variablen nicht beantwortet sind bzw. die Beantwortungsrate deutlich unter dem Durchschnitt liegt, wurde so vorgegangen, weil hier eine sequenzielle Imputation über weite Strecken reine Artefakte produzieren würde und weil aufgrund der mangelnden Informationen die komplexe Struktur des Fragebogens durch die gewöhnliche Imputation wohl nur schlecht abgebildet werden könnte – es würde zu Inkonsistenzen kommen.

Die Distanzfunktion funktioniert folgendermaßen: Bestimmte Grundinformationen sind über jeden Befragten schon aus der Stichprobe vorhanden. Konkret verwenden wir Alter, Geschlecht, Wohnort und Staatsbürgerschaft. Aus dem Wohnort kann man zwei weitere wichtige Informationen generieren: (1) die räumliche Distanz, in der zwei Personen aus dem Datensatz zueinander leben und (2) eine aus verschiedenen Informationen über den Wohnort generierte ordinale Information über diesen Ort. Das ist eine Art spezieller „Verstädterungsgrad“, der aus den Variablen Einwohnerzahl, Erwerbstätigenzahl und Besiedlungsdichte errechnet wird. Die Distanzfunktion bestimmt für jede einzelne der betreffenden Personen jene Person im Datensatz, die ihr hinsichtlich der oben genannten Variablen am nächsten ist und übernimmt den kompletten Datensatz dieser Person. Im Idealfall werden hier – weil ja die Geo-Koordinaten der Haushalte verfügbar sind – die Daten des Nachbarn übernommen.

Dass durch die Koordinaten räumliche Distanzen berechnet werden können, ist für eine Distanzfunktions-Imputation sehr gut brauchbar. Auf diese Weise können regionale Besonderheiten in die Imputation eingehen, auf die sonst kaum eingegangen werden kann, weil die regionale Gliederung auf Gemeindeebene wegen des hohen Diffenenzierungsgrads kaum für die Hot-Deck-Imputation taugt. Gerade für Phänomene des Arbeitsmarkts ist aber die Wichtigkeit der regionalen Komponente nicht zu unterschätzen.

Das beschriebene Vorgehen war vor allem im ersten Quartal notwendig, weil der Mikrozensus zu diesem Zeitpunkt noch mit Umstellungsschwierigkeiten und demgemäß auch mit der Datenqualität zu kämpfen hatte. Im ersten Quartal gab es noch etwa 2300 Distanzfunktionsfälle. Wie man in Abbildung 3 sieht, ist diese Zahl jedoch im Laufe des Jahres stark zurückgegangen: im dritten Quartal waren es nur noch 700 und ab dem vierten Quartal nur mehr etwa 350. An Höhe und Entwicklung dieser Zahlen sind sowohl Umstellungsschwierigkeiten als auch positive Entwicklung der Erhebungs- und Datenqualität in der ersten Zeit nach der Umstellung ablesbar.

(d) Im Moment wird gerade an der Entwicklung und Implementierung von **Cross-Wave-Methoden** für die Imputation gearbeitet[8]: Da diese Methoden prozesstechnisch schwierig umzusetzen sind, werden sie nur bei wichtigen Variablen (Arbeitssuche, Erwerbstätigkeit, Bildung) oder bei Variablen mit hohen Non-Response-Raten (Wohnungskosten) zum Einsatz kommen. Grundsätzlich geht es dabei um die Nutzung von Werten aus anderen Erhebungswellen für die Imputation.

Im einfachsten Fall werden die entsprechenden Werte des Vorquartals direkt übernommen. In einer komplexeren Spielart, die gerade entwickelt wird und auch zum Einsatz

[8]Eine Einführung liefert Kalton and Lepkowsky (1983, S. 171 ff.)

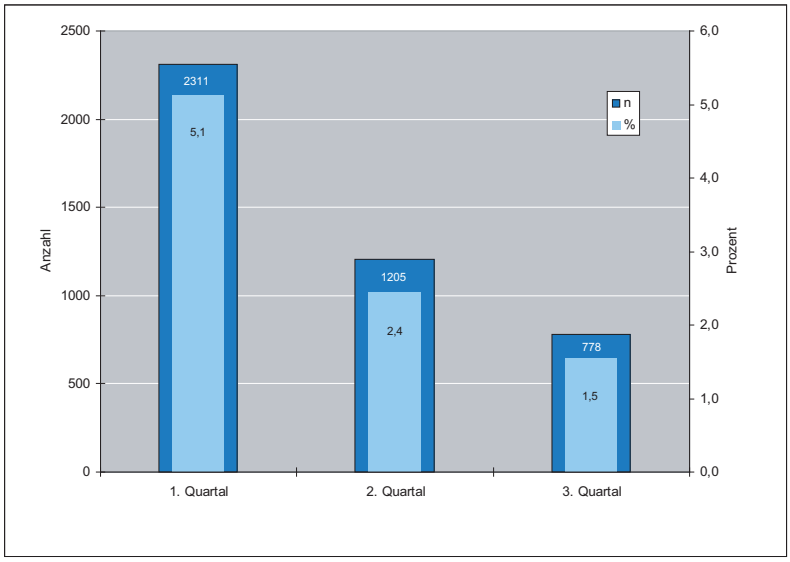

Abbildung 3: Distanzfunktionsfälle in den ersten drei Quartalen des Jahres 2004

kommen soll, werden die Vorquartalswerte als Stratum für eine Hot-Deck-Imputation benutzt. Es handelt sich damit um ein *stochastisches Cross-Wave-Verfahren*; die Wahrscheinlichkeit, mit der ein Wert sich über ein Quartal hinweg verändert, wird in der Imputation berücksichtigt. Die Implementierung dieser Imputationsmethoden in einen automatischen Datenaufarbeitungsprozess erfordert eine strikt organisierte und gut funktionierende Ablaufstruktur des gesamten Datenproduktionsprozesses. Aus diesem Grund muss mit der Einbindung dieser Methoden auch gewartet werden, bis die Datensätze einiger Quartale vorliegen.

2.6 Die abschließenden Prozeduren

Nachdem die beschriebenen Prozeduren abgeschlossen sind, werden in einem letzten Arbeitsschritt noch die Gewichte eingebunden, die verschiedenen abgeleiteten Variablen erstellt und diverse User-Files erzeugt. Bei diesem Prozessschritt muss im Moment noch manchmal händisch eingegriffen werden. Seine vollständige Automatisierung erfordert die erst teilweise vorliegende Spezifikation der internen und externen Bedarfsstrukturen.

3 Resumee

Der Mikrozensus ist mit seinen 30 Jahren Laufzeit ein Survey mit großer Tradition. Er ist aber wohl auch ein wenig in die Jahre gekommen. Aller Veränderungsresistenz von Tradition zum Trotz wurde Anfang vorigen Jahres die Chance einer grundlegenden Neuorientierung ergriffen – mit allen Vorteilen und Problemen, die das mit sich bringt.

Zu den großen strukturellen Neuerungen auf Ebene des Datenmanagements zählt, dass die Programmierung der Datenaufarbeitung, wie auch die laufende Wartung und Verbesserung, nicht mehr am Großrechner durchgeführt werden, sondern in dem weit verbreiteten Statistikpaket SPSS am PC. Auf diese Weise kommt es zu einer direkteren

Zusammenarbeit zwischen Datenmanagement und Datenanalyse; das beeinflusst die Datenqualität und die Produktivität langfristig positiv. Syntax für Plausanweisungen oder Variablenableitungen kann nun zum Beispiel in vielen Fällen von den jeweiligen Fachstatistikern selbst geschrieben werden. Das ist Angesichts der deutlichen Erweiterung des Grundprogramms auch notwendig.

Die auffälligste – und anfangs sicher ein wenig ungewöhnliche – Neuerung für den Nutzer ist die neue Struktur der Variablen, die eine einfachere Handhabung des Datensatzes ermöglicht. Im internen Standardrecodefile – das mit bestimmten Einschränkungen auch der Öffentlichkeit zugänglich gemacht wird – ist für eine größtmögliche Kontinuität und Klarheit der Datenstruktur gesorgt. Es ist damit auch eine wichtige Grundlage für Längsschnittanalysen vorhanden.

Mit mittlerweile sechs abgeschlossenen Quartalen ist der neue Mikrozensus relativ jung. Erhebung und Aufarbeitung weitestgehend sehr modern organisiert und auf dem letzten Stand der Technik. Die Vorgaben Automatisierbarkeit, Transparenz und Ausbaufähigkeit konnten umgesetzt werden. Man kann aber noch nicht davon ausgehen, dass schon alle erdenklichen Probleme beseitigt sind. Durch die transparente Struktur des Datenmanagements und seine enge Einbindung in den Bereich der fachstatistischen Datenanalyse ist aber eine Grundlage für eine kontinuierliche Weiterentwicklung und Verbesserung der Datenaufarbeitung und damit der Daten selbst geschaffen.

Literatur

Barnard, J., Rubin, D. B., and Schenker, N. (1998). Multiple Imputation Methods. In P. Armitage and T. Colton (Eds.), *Encyclopedia of Biostatistics.* New York: Wiley.

Bartunek, E. (1994). Die Arbeitskräfteerhebung von EUROSTAT. *Statistische Nachrichten*, *11*.

Kalton, G., and Lepkowsky, J. M. (1983). Cross-Wave Item Imputation. In M. David (Ed.), *Lessons of the Income Survey Development Program (ISDP).* New York: Social Science Research Council.

Kytir, J., and Stadler, B. (2004). Die kontinuierliche Arbeitskräfteerhebung im Rahmen des neuen Mikrozensus. vom „alten“ zum „neuen“ Mikrozensus. *Statistische Nachrichten*, *6*.

Lessler, J. T., and Kalsbeck, W. D. (1992). *Nonsampling Errors in Surveys*. New York: Wiley.

Author's address:

Mag. Winfried Moser
Statistik Austria
Direktion Bevölkerung - Analyse und Prognose
Guglgasse 13
A-1110 Wien

Tel. +43 (01)71128 7039
Fax +43(01)71128 7455
E-mail: winfried.moser@statistik.gv.at