Pseudonymisierungsplan: Qualitative Interviews im Rahmen von T3.4 (EOSC-Pillar)

Beschreibung des Forschungsprojekts:

Als H2020-Projekt koordiniert EOSC-Pillar nationale Initiativen in Frankreich, Italien, Belgien, Deutschland und Österreich, um den Aufbau der European Open Science Cloud (EOSC) zu unterstützen. Innerhalb des Tasks 3.4 (als Teil von Workpackage 3: National Initiatives Survey) wurden semi-strukturierte, qualitative Interviews mit Forschenden verschiedener Disziplinen und Karrierestufen durchgeführt. Alle Forschenden arbeiten in einem der fünf EOSC-Pillar-Länder. Ziel ist es, zu verstehen, wie Forschende Daten nachnutzen, welche Herausforderungen die Datennachnutzung mit sich bringt, welche Tools und Services hilfreich sein könnten und wie die EOSC nutzer*innenfreundlich gestaltet werden kann.

Der grobe Leitfaden der Interviews lässt sich wie folgt beschreiben: Die Forschenden sprechen knapp über ihre Forschung und die Daten, mit welchen sie am häufigsten arbeiten. Anschließend wird unter Bezugnahme auf die FAIR-Prinzipien gefragt, wie nach Daten gesucht und wo diese gefunden werden, wie sich der Zugang zu den Daten gestaltet, welche Herausforderungen es bei der Interoperabilität gibt (z.B. wenn verschiedene Datenformate zusammengeführt werden sollen) und nach welchen Kriterien Forschende entscheiden, welche Daten sie nachnutzen. Zum Abschluss werden die Forschenden gefragt, ob sie schon einmal von der EOSC gehört haben.

Pseudonymisierung:

Für die Gewährleistung der Pseudonymisierung der Interviewteilnehmer*innen wird auf verschiedenen Pseudonymisierungsstrategien zurückgegriffen. Alle Pseudonymisierung werden als solche gekennzeichnet: [Pseudonym]. Das Forschungsteam dokumentiert nachvollziehbar alle Pseudonymisierungen.

Namen

Die Transkripte der Interviews enthalten keine Namen. Diese müssen also nicht ersetzt werden. Der Einheitlichkeit halber wird für interviewte Personen [P] (participant) und für interviewende Personen [I] (interviewer) verwendet. Das Kürzel [P] wird entsprechend der Reihenfolge der Interviews durchnummeriert, also [P] aus Interview 1 heißt [P1], [P] aus Interview 2 heißt [P2] etc.

Art der Anstellung

Die Art der Anstellung (z.B. Professur) der interviewten Personen kann in Kombination mit dem Land, in dem sie arbeitet, sowie ihrer wissenschaftlichen Disziplin zur Identifikation der Person führen (personenbeziehbare Merkmale). Deshalb wird die Art der Anstellung durch die im European Research Career Framework der Europäischen Kommission vorgeschlagenen Kategorien ersetzt.

The Framework describes four broad profiles, with the following working titles:

- R1 First Stage Researcher (up to the point of PhD)
- R2 Recognised Researcher (PhD holders or equivalent who are not yet fully independent)
- R3 Established Researcher (researchers who have developed a level of independence.)
- R4 Leading Researcher (researchers leading their research area or field)

Ortsangaben

Angaben zum Land, in dem eine interviewte Person arbeitet, werden beibehalten, da diese Information für die Nachnutzung der Daten von Interesse ist. Alle darüber hinaus gehenden Ortsangaben (z.B. der Name einer Stadt) werden durch die Begriffsbestimmung der Internationalen Statistikkonferenz von 1887 ersetzt. Diese heute noch gültige Definition der amtlichen Statistik kategorisiert Städte nach ihrer Einwohnerzahl wie folgt:

- Großstadt: mindestens 100.000 Einwohner*innen
- Mittelstadt (20.000 bis unter 100.000 Einwohner*innen)
- Kleinstadt (5.000 bis unter 20.000 Einwohner*innen)

Begründung: In Kombination mit der Disziplin oder der Art der Anstellung kann diese Information zur Re-Identifizierung führen.

Disziplin/ Forschungsfeld

Angaben zur Disziplin, in der die Forschenden arbeiten, sollen grundsätzlich erhalten bleiben, da diese Information für die Nachnutzung der Daten von Interesse ist. Allerdings können diese Angaben in Kombination mit weiteren Informationen, die in den Interviewtranskripten enthalten sind und die im Hinblick auf eine sinnvolle Nachnutzung nicht gelöscht oder ersetzt werden, eine Re-Identifizierung ermöglichen. Deshalb wird zur Recodierung der Forschungsdisziplin auf die auf die Klassifikation der Felder in Forschung und Entwicklung des Frascati Manuals 2015 (S. 61, pdf-Seite 59) zurückgegriffen. Diese bildet Haupt- und Unterkategorien. Für die Pseudonymisierung im vorliegenden Forschungsprojekt kommen die Unterkategorien des Manuals zum Einsatz. Diese erlauben es, einer Re-Identifizierung vorzubeugen, da sie keine allzu spezifischen Informationen zur Forschungsdisziplin (beispielsweise Subdisziplinen) enthalten. Gleichzeitig bleiben aber ausreichend Informationen erhalten, die für die Nachnutzung der Daten notwendig sind.

Macht eine interviewte Person dagegen Angaben zum *Forschungsfeld*, aber nicht zur konkreten Forschungsdisziplin, so werden diese Informationen nicht ersetzt, sondern beibehalten. Dies gilt insbesondere dann, wenn keine weiteren Angaben im Transkript enthalten sind, die eine Re-Identifizierung ermöglichen.

Institution

Die Institution, an der die interviewte Person arbeitet, wird durch die Angabe ersetzt, um welche Art Institution es sich handelt:

- Universität
- Außeruniversitäre Forschungseinrichtung
- Staatliche Einrichtungen auf Bundes-, Landes- oder Gemeindeebene mit Forschungsauftrag
- Unternehmen mit firmeneigener Forschung

Ergänzt wird diese Angabe durch die Anzahl der Mitarbeiter*innen, die an der Institution beschäftigt sind. Dabei wird aber nicht die exakte Zahl angegeben. Stattdessen werden dafür folgende Kategorien gebildet:

- < 100 Mitarbeiter*innen

- 101-500 Mitarbeiter*innen
- 500-1000 Mitarbeiter*innen
- > 1000 Mitarbeiter*innen

Dies gibt Aufschluss darüber, wie groß die Institution ist. Das Land, in dem sich die Institution befindet, wird beibehalten, weil diese Information für die Nachnutzung der Daten von Interesse ist.

Begründung: Die Angabe der Institution ist sensibel, weil wissenschaftliche Karrieren öffentlich einsehbar sind (CVs sind online abrufbar). Die Gefahr der Identifikation ist hier also gegeben. Gleichzeitig ist es inhaltlich potenziell wichtig zu wissen, welche Art und Größe der Institution gegeben ist, da dies eine Auswirkung auf die zur Verfügung stehende Infrastruktur und Support-Services haben könnte.

Forschungsvorhaben und Forschungsprojekte

Wenn eine interviewte Person über ein Forschungsvorhaben oder -projekt bzw. ein Infrastrukturvorhaben oder -projekt spricht, an dem sie beteiligt ist oder war, wird der Name dieses Vorhabens oder Projekts immer ersetzt durch folgendes Pseudonym: [Name des Projekts] bzw. [Name des Vorhabens].

Um nicht alle Informationen zu den Vorhaben und Projekten löschen zu müssen – denn diese Informationen können für die Nachnutzung der Interviews relevant sein – werden Kategorien gebildet, in die sie sich einordnen lassen:

- Forschungsprojekt oder -vorhaben auf institutioneller
- Forschungsprojekt oder -vorhaben auf nationaler Ebene
- Forschungsprojekt oder -vorhaben auf europäischer Ebene
- Forschungsprojekt oder -vorhaben auf internationaler Ebene

bzw.

- Infrastrukturprojekt oder -vorhaben auf institutioneller
- Infrastrukturprojekt oder -vorhaben auf nationaler Ebene
- Infrastrukturprojekt oder -vorhaben auf europäischer Ebene
- Infrastrukturprojekt oder -vorhaben auf internationaler Ebene

Begründung: Die Kombination aus Forschungsvorhaben/- projekt und Angabe des Landes könnte als spezifische Kontextinformation zur Re-Identifizierung genutzt werden.

Muttersprache

Alle Interviews des vorliegenden Forschungsprojekts wurden auf Englisch geführt. Verwendet jedoch eine interviewte Person einen Ausdruck in ihrer Muttersprache, weil ihr das englische Pendant nicht einfällt oder sie nicht sicher ist, welches englische Wort am besten passt, so wird der nicht-englische Ausdruck ersetzt durch: *[the participant uses an expression in their native language]*. Dies geschieht, um die persönlichen Informationen zur interviewten Person möglichst gering zu halten. Auch wenn die Muttersprache per se kein direkter Identifikator ist, so kann sie doch in Kombination mit weiteren Kontextinformationen zur Re-Identifizierung der Person führen.

Quelle: Meyermann, Alexia, und Maike Porzelt. 2014. „Hinweise zur Anonymisierung von qualitativen Daten“ herausgegeben von Forschungsdatenzentrum (FDZ) Bildung am DIPF. forschungsdaten bildung informiert (1).