Gewichtung SSÖ2016

Johann Bacher / Dimitri Prandner Linz, April 2017

1. Problemstellung

Die bisherige Gewichtungsvariablen GEWICHT führt zu einer deutlichen Abweichung in der Haushaltsgröße (siehe Abbildung 1). Die Größe der Haushalte wird unterschätzt. Ursache hierfür ist, dass IFES die Stichprobenziehung auf der Basis von Haushalten geschichtet nach Bundesländer und Gemeindegröße durchführt und damit Personen in größeren Haushalten eine geringere Auswahlwahrscheinlichkeit haben.

Die Auswahlwahrscheinlichkeit nimmt einen Wert von 1/H an, wobei H die Zahl der im Haushalt lebenden Personen, die 16 Jahre oder älter sind, ist. Es ist daher eine Designgewichtung mit dem normierten reziproken Wert der Auswahlwahrscheinlichkeit erforderlich.

Abbildung 1: Haushaltsgröße entsprechend MZ und SSÖ mit dem ursprünglichen Gewicht.

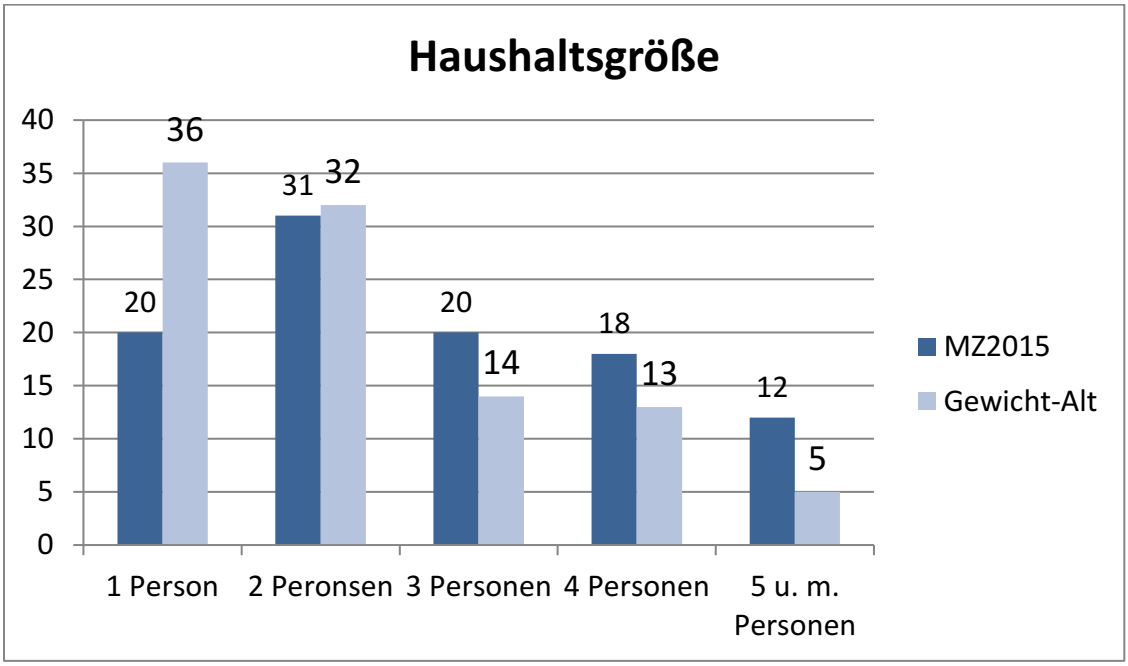

2. Lösungsansatz

Daher wurde bei IFES nachgefragt, inwiefern Designgewichte verfügbar sind. Die Anfrage führte dazu, dass nach Absprache drei zusätzliche Gewichtungsvariablen nachgereicht wurden:

- Die Variable GEWICHT_DESIGN, die die Designgewichtung erhält. In sie gingen das Bundesland und die Haushaltsgröße ein.
- Die Variable GEWICHT_POS, die die Nachgewichtung hinsichtlich Alter, Geschlecht und Bildung enthält.

- Die Variable GEWICHT_GES, die das Gesamtgewicht enthält, in das die Designgewichtung und die Nachgewichtung eingingen.

Wird das neue Gesamtgewicht verwendet, wird eine relativ gute Anpassung an die Bundesländer, die kombinierte Alter-Geschlecht-Variable und das Bildungsniveau sowie an die Haushaltsgröße erreicht (siehe Tabelle 1 sowie Tabelle A1 im Anhang A). In der Tabelle ist jeweils die Summe der absoluten Abweichungen der relativen Häufigkeiten (Randverteilungen) zur Mikrozensusverteilung eingetragen. Die Summe der absoluten Abweichungen $A_{g,i}$ in einer Variablen i bei Verwendung der Gewichtungsvariablen ist definiert als:

$$A_{g,i} = \sum_{j=1}^{m_i} \left| p_{MZ,i,j} - p_{g,i,j} \right|$$

mit

$p_{MZ,i,j}$ = Anteil der Kategorie j der Variablen i im Mikrozensus

$p_{g,i,j}$ = Anteil der Kategorie j der Variablen i bei Verwendung der Gewichtungsvariablen g

Der maximale Wert ist 1 bzw. 100%.

Für die neue Gewichtungsvariablen ergeben sich Abweichungssummen von 0 bis 2%. Der Defekt des alten Gewichts zeigt sich in der hohen Abweichungssumme von 35% für die Haushaltsgröße.

Tabelle 1: Abweichungen der relativen Häufigkeitsverteilungen in den vier Variablen der Gesamtgewichtung zum Mikrozensus 2015 in %

	Un-gewichtet	Gewicht-Alt	Design-gewicht	Post-gewicht	Gesamt-gewicht
Bundesland	5	0	1	1	1
Alter * Geschlecht	13	2	24	1	1
Bildung	6	2	8	0	0
Haushaltsgröße	32	35	13	35	2

3. Validierung der Gewichtung

Die gute Übereinstimmung der neuen Gewichtungsvariablen mit den in die Gewichtung einbezogenen Variablen ist wenig überraschend. In einem weiteren Schritt wurde daher untersucht, ob durch die Gewichtung auch eine bessere Annäherung an die Randverteilungen des MZ in Variablen, die nicht in die Gewichtung eingingen, erzielt wird. Über die Ergebnisse berichtet Tabelle 2 (Details siehe Tabelle A2 im Anhang).

Tabelle 2: Abweichungen der relativen Häufigkeitsverteilungen von weiteren Variablen, die nicht in die Gewichtung eingingen, zum Mikrozensus 2015 in %

	Un-gewichtet	Gewicht-Alt	Design-gewicht	Post-gewicht	Gesamt-gewicht
Erwerbstatus	10	5	19	6	3
Arbeitszeit	22	24	15	24	16
Geburtsland	20	20	18	20	18
Einwohnergröße	7	7	4	7	3
Familienstand	12	17	14	17	8
Kind unter 17 Jahren im Haushalt	12	16	18	16	2

Auch für weitere Variablen erbringt die Gesamtgewichtung eine bessere Annäherung an den Mikrozensus. Deutliche Abweichungen von über 10% treten bei der Arbeitszeit und dem Geburtsland auf. Die Differenzen beim Geburtsland sind auf die Untererfassung von Befragten im SSÖ zurückzuführen. Die Abweichungen bei der durchschnittlichen Arbeitszeit sind auf eine Unterschätzung der Teilzeittätigkeit im Sozialen Survey im Vergleich zum Mikrozensus zurückzuführen. Ein Teil der Differenz kann möglicherweise dadurch erklärt werden, dass im MZ nach regelmäßig geleisteten Überstunden gefragt wird, im SSÖ dagegen nur nach Überstunden (siehe Tabelle 3).

Tabelle 3: Erfassung der Arbeitszeit im MZ und im SSÖ

MZ	Wie viele Stunden arbeiten Sie in Ihrer (S: selbständigen) Haupttätigkeit normalerweise pro Woche (U: einschließlich regelmäßig geleisteter Überstunden (TZ: oder Mehrstunden)? Mittagspausen über 30 Minuten bitte abziehen! Hinweis: (U: Lehrer geben bei voller Lehrverpflichtung 40 Stunden offene Antwortkategorie
SSÖ	Wie viele Stunden arbeiten Sie normalerweise in Ihrem Hauptberuf pro Woche einschließlich Überstunden? offene Antwortkategorie

4. Empfehlung

Wir empfehlen die Verwendung der Gewichtungsvariablen Gewicht_GES für die Analyse. Sie kann mit folgender Syntax an den bestehenden Datensatz angefügt werden.

```
GET  FILE='[QUELLVERZEICHNIS].sav'.

DATASET NAME DatenSet1 WINDOW=FRONT.

sort cases by NR_2016.

match files
```

```
/file=*

/FILE='[QUELLVERZEICHNIS]\GewichteSSOE2016.sav'

/By NR_2016.
```

Anhang A: Verteilungskennzahlen

Tabelle A1: Verteilungskennzahlen in den Gewichtungsvariablen in %

Angaben in Prozent	MZ 2015	unge-wichtet		Gewicht-Alt (a)		Design-gewicht (b)		Post-gewicht (c)		Gesamt-gewicht (d)	
Bundesland	in %	in %	Diff	in %	Diff	in %	Diff	in %	Diff	in %	Diff
Wien	21	20	1	21	0	21	0	21	0	21	0
Niederösterreich	19	18	1	19	0	19	0	19	0	19	0
Burgenland	3	3	0	3	0	3	0	3	0	3	0
Steiermark	14	14	0	14	0	14	0	14	0	14	0
Kärnten	7	7	0	7	0	6	1	7	0	7	0
Oberösterreich	17	17	0	17	0	17	0	17	0	17	0
Salzburg	6	8	2	6	0	6	0	6	0	6	0
Tirol	9	8	1	9	0	9	0	8	1	9	0
Vorarlberg	4	4	0	4	0	4	0	4	0	5	1
Summe	100	99	5		0		1		1		1
Alter x Geschlecht											
Männer 16-29 J	10	7	3	11	1	7	3	10	0	10	0
Frauen 16-29 J	10	10	0	10	0	10	0	10	0	10	0
Männer 30-39 J	8	9	1	8	0	9	1	8	0	8	0
Frauen 30-39 J	8	10	2	8	0	14	6	8	0	8	0
Männer 40-49 J.	9	10	1	9	0	11	2	9	0	9	0
Frauen 40-49 J.	9	9	0	9	0	12	3	9	0	9	0
Männer 50-59 J.	9	9	0	9	0	9	0	9	0	9	0
Frauen 50-59 J.	9	10	1	9	0	9	0	9	0	9	0
Männer 60-69 J.	6	7	1	6	0	5	1	6	0	6	0
Frauen 60-69 J.	7	8	1	7	0	6	1	7	0	7	0
Männer 70+ J.	6	5	1	7	1	4	2	7	1	7	1
Frauen 70+ J.	9	7	2	9	0	4	5	9	0	9	0
Summe	100	101	13		2		24		1		1
Bildung											
ohne Matura	71	68	3	70	1	67	4	71	0	71	0
mit Matura	29	32	3	30	1	33	4	29	0	29	0
Summe	100	100	6		2		8		0		0
Haushaltsgröße											
1 Person	20	35	15	36	16	17	3	36	16	20	0
2 Peronsen	31	32	1	32	1	27	4	32	1	31	0
3 Personen	20	15	5	14	6	20	0	14	6	19	1
4 Personen	18	14	4	13	5	21	3	13	5	18	0
5 u. m. Personen	12	5	7	5	7	15	3	5	7	13	1
Summe	101	101	32		35		13		35		2

(a) Gewichtungsvariable = GEWICHT, (b) Gewichtungsvariable = GEWICHT_DESIGN;
(c) Gewichtungsvariable = GEWICHT_POST; (d) Gewichtungsvariable = GEWICHT_GES;

Tabelle A2: Verteilungskennzahlen in den weiteren, nicht in die Gewichtung einbezogenen Variablen in %

	MZ	ungewichtet		Gewicht Alt (a)		Design-gewicht (b)		Post-gewicht (c)		Gesamt-gewicht (d)	
Erwerbsstatus	in %	in %	Diff	in %	Diff	in %	Diff	in %	Diff	in %	Diff
Erwerbstätig	58	63	5	60	2	67	9	60	2	59	1
Arbeitslos	4	4	0	4	0	3	1	3	1	3	1
Nichterwerbsperson	39	34	5	36	3	30	9	36	3	38	1
Präsenz-/Zivildiener	0										
Summe	101	101	10	100	5	100	19	99	6	100	3
Arbeitszeiz											
keine Stunden											
bis 11 Stunden	6	1	5	1	5	1	5	1	5	1	5
12 bis 24 Stunden	11	7	4	6	5	9	2	6	5	8	3
25 bis 35 Stunden	13	13	0	13	0	14	1	13	0	13	0
36 bis 40 Stunden	47	53	6	54	7	49	2	54	7	50	3
41 bis 59 Stunden	19	23	4	23	4	22	3	23	4	23	4
60 u. m. Stunden	5	3	2	3	2	4	1	3	2	5	0
Summe	100	100	22	100	24	99	15	100	24	100	16
Geburtsland											
Österreich	81	91	10	91	10	90	9	91	10	90	9
Nicht-Österreich	19	9	10	9	10	10	9	9	10	10	9
Summe	100	100	20	100	20	100	18	100	20	100	18
Einwohnergröße											
bis 2000	16	15	1	15	1	15	1	15	1	15	1
2001 bis 5000	25	23	2	23	2	25	0	23	2	25	0
5001 bis 20.000	21	22	1	22	1	22	1	22	1	21	0
20.001 bis 50.000	5	6	1	6	1	7	2	6	1	7	2
50.001 bis 300.000	11	13	2	13	2	11	0	13	2	11	0
Wien	21	21	0	21	0	21	0	21	0	21	0
Summe	100	100	7	100	7	100	4	101	7	100	3
Familienstand											
ledig	34	34	0	35	1	30	4	35	1	30	4
verheiretat	50	44	6	42	8	56	6	42	8	53	3
verwitwet	7	7	0	9	2	4	3	9	2	7	0
geschieden	9	15	6	15	6	10	1	15	6	10	1
Summe	100	100	12	101	17	100	14	101	17	100	8
Kind unter 17 lebt im Haushalt											
nein	72	78	6	80	8	63	9	80	8	71	1
ja	28	22	6	20	8	37	9	20	8	29	1
Summe	100	100	12	100	16	100	18	100	16	100	2

(a) Gewichtungsvariable = GEWICHT, (b) Gewichtungsvariable = GEWICHT_DESIGN;
(c) Gewichtungsvariable = GEWICHT_POST; (d) Gewichtungsvariable = GEWICHT_GES;