Archival Preservation of Digital Databases - Teilautomatisierung oder Standardformat? Vergleich

Database History – Histories of Datebasing and Databasing of History

23. Juni 2023

Dr. Michael Puchta M.A. / Dr. Markus Schmalz M.A.

Generaldirektion der Staatlichen Archive Bayerns

Gesetzlicher Auftrag zur

- dauerhaften Archivierung aller Informationen von bleibendem Wert aller staatlichen Stellen in Bayern
- Beratung der Datenproduzenten im Informations-management
- möglichst FAIREn Zugänglichmachung der Informationen u.a. für Wissenschaft und Forschung

Dimensionen

Daten aus:

DB, Fachverfahren, GIS,
DMS/VBS,
ePublishing,
Email, File-Ablagen,
Großrechnerdaten,
Forschungsdaten

ca. 764 Mio. Informationsobjekte
ca. 27.000 GB

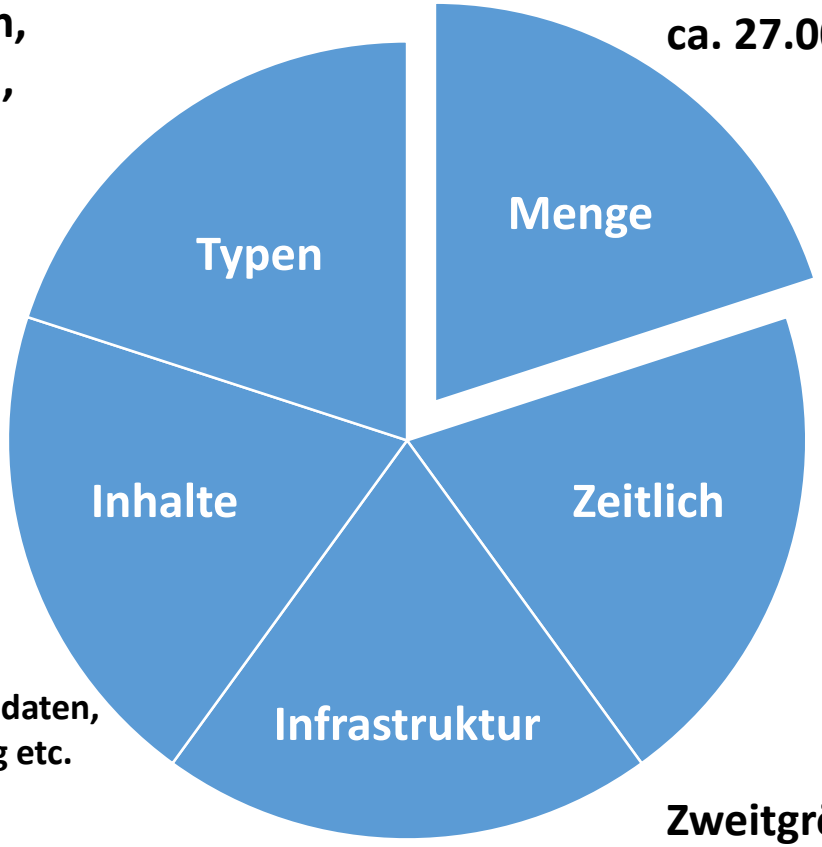

ALLE BEREICHE DER STAATSVERWALTUNG
u.a.
INVEKOS, EPS-WEB, Geobasisdaten, KLIP4, VIVA, Biotopkartierung etc. von Verbänden und privaten Nachlassgebern

Aus 1950 – 2022 n. Chr.
Für Immer!

Zweitgrößte IT-Installation im Freistaat Bayern / IT-DLZ mit ca. 120 virtualisierten Servern und 60 Datenbanken

1.

Ausgangslage

2.

Datenbankarchivierung mit SIARD

3.

Der Generalisierte XML-Aussonderungsclient der Staatlichen Archive Bayerns

4.

Vergleich zweier Archivierungskonzepte

Ausgangslage

Ausgangslage – ZIELE (I/II)

Datenbankbasierte Fachverfahren als Teil „materieller Aktenführung“ / eAkte-Systeme sind unvollständig	• Archivierung von Daten aus Fachverfahren unverzichtbar für qualitative und rechtskonforme Überlieferungsbildung
Große Heterogenität und Vielzahl der Systeme	• In bayer. Staatsverwaltung rund 4.000 unterschiedliche IT-Systeme, großteils datenbankbasiert
KEINE FAIRE Datenhaltung	• i.d.R. KEINE Archivierungsschnittstellen • Häufig begrenzter XML-Export möglich

Ausgangslage – ZIELE (II/II)

Aufwandsreduktion	• **Möglichst geringe Aufwände für die Abgabestellen bei der Archivierung**
Data Provenance / Authentizität	• **Hohes Interesse an der Nachvollziehbarkeit der archivischen Arbeitsprozesse bei der Überlieferungsbildung**
Bewertung	• **Inhalte von DB und Fachverfahren häufig nur teilweise archivwürdig**
Nachnutzung	• **Einzelfallbezogene Nutzung UND Auswertung großer Datenmengen aus Datenbanken** • **Schutzfristen: auch Datenbankteile und einzelne Inhalte**

Datenbankarchivierung mit SIARD

Software Independent Archiving of Relational Databases (SIARD)

Entwickelt vom Schweizer Bundesarchiv zur Archivierung von DB unabhängig von ihrer Software

Einsatz in über 50 Ländern – In BRD noch kaum im Einsatz

Offene Software SIARD-Suite (Github)

Offenes Datenformat SIARD basierend auf XML, SQL:2008, UNICODE und ZIP64

Pilotierung bei den Staatl. Archiven Bayerns im Kontext der Nationalen Forschungsdateninfrastruktur (NFDI)

- Use Case im Rahmen der NFDI 4 BIODIVERSITY

→ LZA von Sammlungsdatenbanken der Staatl. Naturwissenschaftl. Sammlungen Bayerns

Datenbankarchivierung mit SIARD - Workflow

- Installation der SIARD-Suite beim Datenproduzenten
- Ggf. Festlegung der zu archivierenden (Projekt-)Datenbanken
- Definition des Dokumentationsmaterials und zusätzlicher Angaben zur Erschließung
- Extraktion der DB Inhalte und Erzeugung der SIARD-Datei
- Übernahme und Ingest
- „Händische“ Erschließung

Der Generalisierte XML-Aussonderungsclient der Staatlichen Archive Bayerns GXAC

GXAC - Ziele

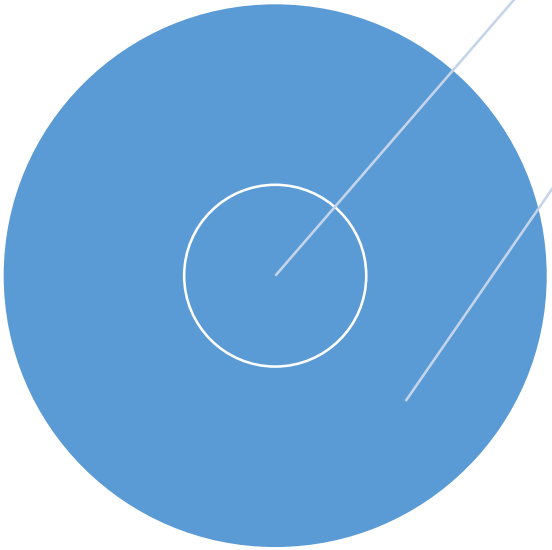

Archivierung der für die Geschäftsprozesse zentralen Informationsbezie-hungen / Entitäten

Erhaltung der Datenbankstruk-tur NICHT zentral

Unterstützung unterschiedlicher Ansätze:

- Zusammenfassung der einzelnen Tupel einer Relation in einer XML-Datei
- relationsübergreifende Bildung von Datensätzen entlang von Verwaltungsprozessen

GXAC - Grundkonzeption (I/II)

Modulares Fachverfahren

- GUI-basiert
- mit Workflow-Komponente

Generisches System

- Verarbeitung unterschiedlichster XML-Metadaten sowie ggf. vorhandene BLOBs, CLOBs oder datenbankextern referenzierte Primärdateien

Konfiguration für das Abgabesystem

- Datenmapping für Datenauswahl zur Bewertung und Erschließung und Strukturierung in AIP

GXAC - Funktionsbereiche (I/II)

Autom. Detektion der Anlieferung von Daten auf einem festgelegten Share und Information des zust. Archivs per Mail.

Erstellung eines flexiblen Datensatzmappings als Grundlage für die archivische Bewertung und AIP-Bildung

GUI-basierte Bewertung der Datensätze auf der Grundlage des Mapping (optional, Vier-Augen-Prinzip wird unterstützt)

Nachkassation nicht archivwürdiger Datensätze

Transaktionssichere Datenübertragung und Ingestierung in den Archivspeicher

GXAC - Funktionsbereiche (II/II)

- Automatische Strukturierung der Abgabeportion in AIPs im Archivspeicher auf der Grundlage des Datenmappings
- Automatische Grundverzeichnung durch Metadatenextraktion aus den Datensätzen im Archivinformationssystem.
- Automatische Quittierung der erfolgreichen Archivierung gegenüber der Abgabestelle als Voraussetzung für die Datenlöschung
- Automatische Dokumentation aller Verarbeitungsschritte zur Sicherung der Data Provenance und Authentizität

Stack Overflow - | Fragen an die GD | Fragen an die GD | Sammelticket: Of | Anbindung Dima | KT 2: normale un | Fragen an GDA: k | Gda XmlAc -

localhost:8893/jsf/abgaben.xhtml?step=share 80%

XML-Aussonderungsclient – Abgaben

Startseite / Abgaben

Angemeldet als: user Abmelden

Prozessschritt: share

Zurück zur Workflow-Übersicht

Abgaben

Mandant	Abgebende Stellen	Abgabezeitpunkt (Erkennung durch Share-Prüfer)	Beschreibung aus Mapping Tool	ID	Verzeichnis (rel.)	letzte Änderung	Schritt	Status	SubStatus	Tes
BAYHSTA				190e91e0-0eca-11eb-9c19-f104205dc0df	KlmA1	2021-05-12T14:33:22.202816Z	MAPPING	ERFOLGREICH	MAPPING_ERFOLGREICH	Ne
BAYHSTA				873eac10-e6d7-11ea-a2e7-ef6dec7ac8dc	GrmA	2021-04-26T18:11:01.766947Z	HARVESTER	ERFOLGREICH	ERFOLGREICH	Ja
BAYHSTA				550e91e0-0eca-22eb-9c19-f104205dc0df	KlmA1ohneProlog	2021-04-26T17:39:28.761558Z	MAPPING	FEHLGESCHLAGEN	KEINE_PASSENDE_KONFIGURATION	Ne
BAYHSTA				330e91e0-0eca-11eb-9c19-f104205dc0df	KlmA2_FolderTest\direkterImport	2021-04-26T17:39:16.641585Z	HARVESTER	ERFOLGREICH	ERFOLGREICH	Ja
BAYHSTA				110e91e0-0eca-11eb-9c19-f104205dc0df	KlmA2_FolderTest\direkterImport	2021-04-26T17:39:13.875778Z	HARVESTER	FEHLGESCHLAGEN	VALIDIERUNG_FEHLGESCHLAGEN	Ja
BAYHSTA				11cb1799-4b9d-4296-8b83-34eb8403a711	schema_valid	2021-04-26T17:39:08.203105Z	HARVESTER	ERFOLGREICH	ERFOLGREICH	Ja
BAYHSTA				2d76aa20-0ef5-11eb-	KlmoA	2021-04-26T17:39:06.671101Z	HARVESTER	ERFOLGREICH	ERFOLGREICH	Ja

Vergleich zweier Archivierungskonzepte

Schwächen von SIARD und des GXAC bei der Archivierung von Daten aus Datenbanken

SIARD

- Archivierung codierter Attribute und Werte
- Bildung großer AIPs (1 DB = 1 AIP)
- „Händische“ Erschließung
- Beständigkeit des SIARD-Formats langfristig fraglich
- Zusätzliche Lösung für Ingest etc. nötig
- Keine Bewertung unterhalb der Datenbankebene möglich

GXAC

- Quasi-Standardisierung ABER trotzdem höhere Aufwände für Exportschnittstellen als bei SIARD
- Feste Kopplung an Digitales Magazin
- DB-Struktur bleibt nicht erhalten

Stärken der Tools bei der Archivierung von Daten aus Datenbanken

SIARD

- Ressourcenschonend
- Sicherung der DB-Struktur
- weit verbreiteter „Quasi-Standard“

GXAC

- Automatisierte Verarbeitung von Übernahme bis Erschließung
- Automatisierte Dokumentation aller Verarbeitungsschritte (Data Provenance)
- Strukturierung in kleine AIP – Nachnutzbarkeit!
- Archivierung „menschenlesbarer“ Attribute und Werte

Anwendungsszenarien bei den Staatlichen Archiven Bayerns

SIARD

- Tendenz: Klassische DB mit großen Mengen an Informationsobjekten u.a. aus dem Bereich der Sammlungen und Museen
- Überlieferungsziel: Informationsobjekte und Datenbankstrukturen
- Aufwändige Exportschnittstelle nicht umsetzbar (Altsysteme)
- Auswertung im Gesamtkontext wahrscheinlich

GXAC

- Tendenz: Prozessgeborene Daten aus Fachverfahren
- Überlieferungsziel: Vernetzte Informationsobjekte und Entstehungszusammenhänge
- Integration der Exportschnittstelle in frühem Stadium des Datenlebenszyklus (Softwarekonzeption)
- Einzelfallbezogene Nachnutzung wahrscheinlich

Strategische Schlussfolgerungen

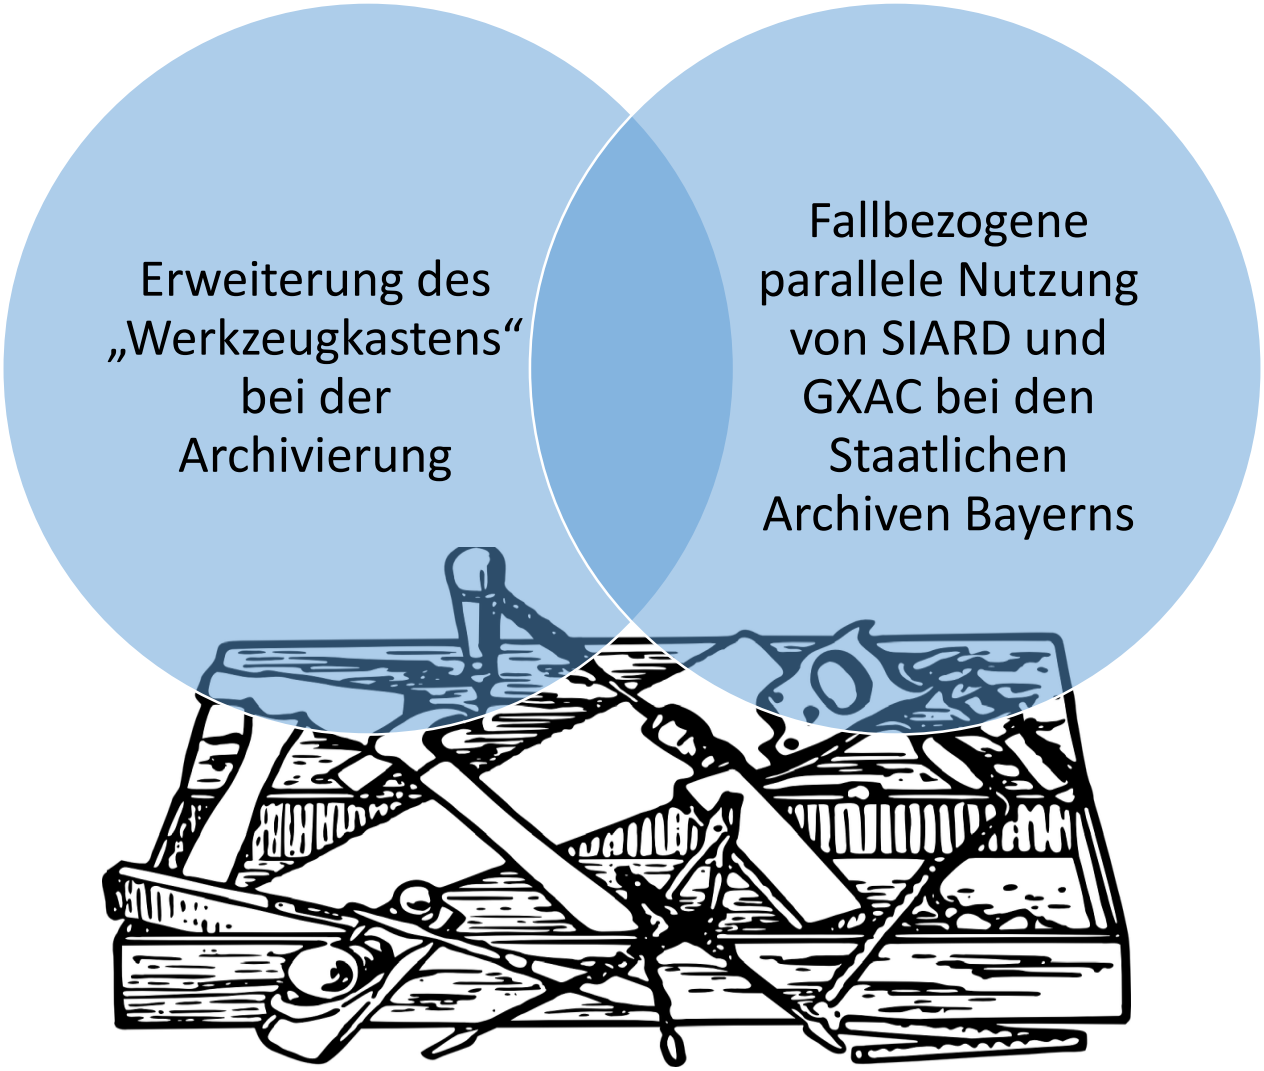

Vielen Dank für Ihre Aufmerksamkeit

Michael.Puchta@gda.bayern.de / Markus.Schmalzl@gda.bayern.de