Instituto Federal de Educação, Ciência e Tecnologia de São Paulo
Laboratório Maxwell de Micro-ondas e Eletromagnetismo Aplicado
Anais do Workshop de Micro-ondas DOI: 10.5281/zenodo.10050587 ISSN 2675-4460

CLASSIFICAÇÃO DE CARDIOMIOPATIAS UTILIZANDO CLASSIFICADORES GAUSSIANOS BAYESIANOS

Patrícia Tavares Leitão, Igor Rocha de Sousa, Jermana Lopes de Moraes, Auzuir Ripardo de Alexandria.
IFCE - patricia.tavares@alu.ufc.br, UFC - igor.sousa@alu.ufc.br, UFC - jermana@ufc.br, IFCE - auzuir@ifce.edu.br.

Resumo - Neste trabalho, é realizada a classificação de cardiomiopatias utilizando os classificadores gaussianos bayesanos *Linear Discriminant Analysis* (LDA), *Quadratic Discriminant Analysis* (QDA) e *Naive* Bayes. São aplicadas técnicas de aprimoramento no banco de dados a fim de torná-lo mais adequado para os classificadores utilizados, como a transformação de Box-Cox. É realizado um aumento artificial de dados nas classes com pouquíssimas amostras a fim de melhorar a qualidade dos classificadores. É realizada uma comparação destes resultados com os encontrados na literatura, em que o classificador LDA, de baixa complexidade, obteve resultados similares aos alcançados por classificadores não lineares como MLP, SOM, K-means e KNN.

Palavras-chave: Cardiomiopatias; reconhecimento de padrões; classificadores guassianos bayesianos.

INTRODUÇÃO

O monitoramento cardíaco, realizado em ambientes clínicos, é fundamental para proporcionar um diagnóstico precoce de doenças cardíacas (1). Esse monitoramento pode ser feito através do método do eletrocardiograma (ECG) ou da fotopletismografia (*photoplethysmography* - PPG) (2). O PPG é uma técnica que detecta a variação da absorção óptica da pele causada pela mudança do volume sanguíneo durante o ciclo cardíaco (3).
Como exemplo de trabalhos sobre classificadores gaussianos bayesianos, pode-se citar Bemando *et al.* (4), que utilizam o classificador *Naive* Bayes (NB), Li *et al.*(5) que utilizaram o classificador *Linear Discriminant Analysis* (LDA) e Shariatnia *et al.* (6) que utilizaram o classificador *Quadratic Discriminant Analysis* (QDA).
O NB, assim como o LDA e o QDA, são classificadores bayesanos que, assumindo a hipótese gaussiana sobre a distribuição dos dados, são chamamos de classificadores bayesianos gaussianos. São fáceis de serem implementados e são capazes de alcançar altas taxas de acurácia com baixo esforço computacional devido a sua simplicidade (7). São considerados classificadores ótimos para dados com distribuição gaussiana. Além disso, podem superar métodos de classificação mais sofisticados (8).
O objetivo deste trabalho é comparar as técnicas de reconhecimento de padrões para a classificação de cardiomiopatias utilizando classificadores gaussianos bayesianos, tais como LDA, QDA e NB. O banco de dados é apresentado em (9). Esses dados foram coletados no Hospital Dr. Carlos Studart Gomes, também conhecido por Hospital do Coração de Messejana, em Fortaleza, Ceará, Brasil.

DESENVOLVIMENTO

Na Fig. 1, é apresentado a sequência de passos para o desenvolvimento deste trabalho. Primeiramente, é realizado o aumento de dados das classes que possuem poucas amostras. Para a realização do aumento das amostras, é adicionado um ruído branco com variância de 10^{-4} em cópias das amostras originais, gerando assim novas amostras. Para isso, o banco de dados aumentado é normalizado entre -1 e 1.
Posteriormente o passo do aumento de dados é aplicada a transformação de Box-Cox, na tentativa de tornar a função

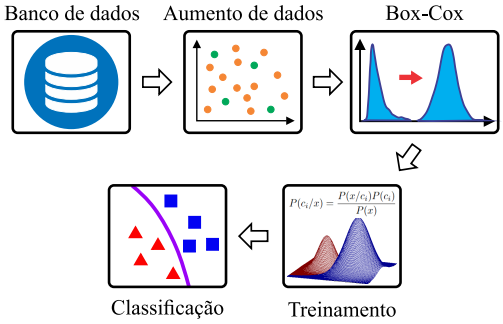

Figura 1 – Passos utilizados para a classificação.

densidade de probabilidade mais próximos da distribuição normal, ou seja, mais próximo da Gaussiana. Para a realização da transformação de Box-Cox, o banco de dados aumentado é normalizado entre 0,1 e 1.
Por fim, o conjunto de dados resultante são utilizados para treinamento e teste dos classificadores bayesianos gaussianos. São avaliados os classificadores LDA, QDA e NB. Os dados são separados de forma aleatória em 70% para treinamento dos classificadores e 30% para teste. No total, são executadas 100 realizações deste procedimento, em que são avaliados a acurácia média, desvio-padrão, sensibilidade e precisão média.

RESULTADOS

Na Fig. 2, é apresentado o resultado das 100 realizações, através dos *boxplots* das acurácias dos classificadores nos dados de teste. Pode-se observar que a classificação com a transformação de Box-Cox (Fig. 2b) obteve melhor desempenho para todos os classificadores e em todos os grupos em relação à classificação sem a transformação de Box-Cox (Fig. 2a), com melhores acurácias.
Os valores de acurácia, desvio-padrão (d.p.), precisão e sensibilidade das classificações do banco de dados aumentado com transformação de Box-Cox são exibidos nas Tabelas 1, 2 e 3. Pode-se observar na Fig. 2b, que o classificador LDA obteve o melhor resultao em todas as métricas e em todos os grupos.
Pode-se observar que o QDA obteve um pior resultado, pois esse classificador possui uma matriz de covariância

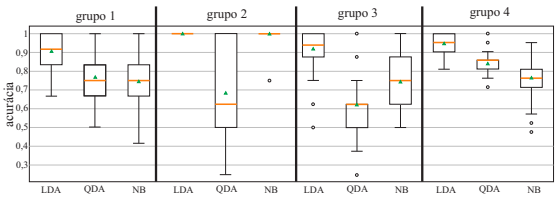

(a) Classificação do banco de dados aumentado.

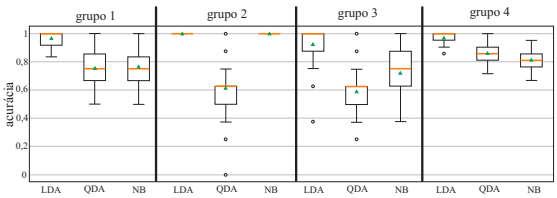

(b) Classificação do banco de dados aumentado com a transformação de *Box-Cox*.

Figura 2 – *Boxplots* das acurácias dos classificadores para dados de teste.

Tabela 1 – Resultados do Classificador LDA por grupos.

Grupo	*acurácia e d.p.*	*precisão*	*sensibilidade*
1	96,50 ± 4%	96,62%	94,43%
2	**100 ± 0%**	**100%**	**100%**
3	92,50 ± 11%	93,00%	94,00%
4	96,95 ± 3%	93,77%	93,00%

Tabela 2 – Resultados do Classificador QDA por grupos.

Grupo	*acurácia e d.p.*	*precisão*	*sensibilidade*
1	75,41 ± 13%	**48,98%**	58,65%
2	61,50 ± 21%	41,31%	**59,00%**
3	58,87 ± 17%	37,91%	56,98%
4	**85,90 ± 7%**	48,44%	54,75%

Tabela 3 – Resultados do Classificador NB por grupos.

Grupo	*acurácia e d.p.*	*precisão*	*sensibilidade*
1	76,50 ± 11%	70,25%	73,36%
2	**100 ± 0%**	**100%**	**100%**
3	72,00 ± 16%	73,45%	72,24%
4	81,42 ± 7%	67,93%	76,65%

para cada classe. Porém, o banco de dados aumentados possui poucas amostras e esse classificador precisa da inversa da matriz de covariância. Portanto, pode acontecer que a inversa da matriz de covariância seja de qualidade ruim. Já o LDA obteve um bom resultado, pois esse classificador assume que a matriz de covariância é a mesma para todas as classes. Portanto, são mais amostras para serem realizadas as estimativas dessa matriz de covariância.

A classificação de cardiomiopatias com este banco de dados, sem as técincas de aprimoramento e aumento de dados artificiais, foram realizadas em (9). Foram utilizados classificadores não lineares: rede neural MLP (*multilayer perceptron*), rede SOM (*self-organizing map*), *K-means* e KNN (*k nearest neighbor*). Nas nas Tabelas 4 e 5 são apresentadas as comparações entre os resultados obtidos em (9) e os alcançados neste trabalho.

Tabela 4 – Comparativo da acurácia média e desvio-padrão.

Banco de Dados	Classificador	*Grupo 1*	*Grupo 2*	*Grupo 3*	*Grupo 4*
apresentado em (9)	MLP	88,57 ± 0,05%	**100 ± 0%**	93,33 ± 0,08%	90,00 ± 0,04%
	SOM	**100 ± 0,08%**	**100 ± 0%**	87,50 ± 0,21%	87,50 ± 0,07%
	K-means	92,85 ± 0,34%	**100 ± 0%**	**100 ± 0%**	91,85 ± 0,34%
	KNN	92,60 ± 0,03%	100 ± 0,06%	90,00 ± 0,10%	**93,00 ± 0,05%**
Dados aum. com transf. de Box-Cox	LDA	**96,50 ± 4%**	**100 ± 0%**	**92,50 ± 11%**	**96,95 ± 3%**
	QDA	75,41 ± 13%	61,50 ± 21%	58,87 ± 17%	85,90 ± 7%
	NB	76,50 ± 11%	**100 ± 0%**	72,00 ± 16%	81,42 ± 7%

Tabela 5 – Comparativo da sensibilidade.

Dados	Classif.	*Grupo 1*	*Grupo 2*	*Grupo 3*	*Grupo 4*
apresentado em (9)	MLP	87,5%	**100%**	96,9%	88,5%
	SOM	**100%**	**100%**	90,0%	90,0%
	K-means	90,6%	**100%**	**100%**	**92,8%**
	KNN	89,5%	**100%**	90,0%	89,5%
dados aum. com transf. de Box-Cox	LDA	**94,4%**	**100%**	**94,0%**	**93,0%**
	QDA	58,6%	59,0%	56,9%	54,7%
	NB	73,36%	**100%**	72,24%	76,65%

CONCLUSÃO

Este artigo abordou técnicas de classificação de cardiomiopatias utilizando classificadores bayesanos gaussianos: LDA, QDA e *Naive* Bayes. Foram realizadas melhorias no banco de dados original, a fim deste tipo de classificador obter melhores resultados. A aplicação da transformação de *Box-cox* mostrou-se satisfatória, conforme apresentado na Fig. 2.

O classificador LDA obteve melhor desempenho entre os utilizados, com 96,5% de acurácia média no grupo 1 (idiopática × saudáveis), 100% no grupo 2 (chagásica × saudáveis), 92,5% no grupo 3 (isquêmica × saudáveis) e 96,95% no grupo 4 (cardiomiopatias × saudáveis). O classificador QDA apresentou baixo desempenho devido ao pequeno número de amostras por classe. Já o classificador LDA obteve, no geral, resultados similares aos alcançados por classificadores não lineares em (9), como a MLP, SOM, *K-means* e KNN.

REFERÊNCIAS

1 PINTO, R. A. et al. **Rede neural convolucional u-net para inferência do sinal eletrocardiograma a partir do sinal fotopletismograma**. Dissertação (Mestrado) — Universidade Federal do Amazonas, 2022.

2 OLIVEIRA, H. S. **Estimativa dos pontos de sistole e diástole para identificação de hipertensão a partir de sinais de fotopletismografia**. Dissertação (Mestrado) — Universidade Federal do Amazonas, 2022.

3 SOUZA, P. H. d. B. **Método para estimação da frequência cardíaca e variabilidade cardíaca com base em fotopletismografia por vídeo**. Dissertação (Mestrado) — Universidade de Brasilia, 2019.

4 BEMANDO, C.; MIRANDA, E.; ARYUNI, M. Machine-learning-based prediction models of coronary heart disease using naïve Bayes and random forest algorithms. In: IEEE. **2021 International Conference on Software Engineering & Computer Systems and 4th International Conference on Computational Science and Information Management (ICSECS-ICOCSIM)**. [S.l.], 2021. p. 232–237.

5 LI, B.; DING, H.; WANG, Z.; LIU, Z.; CAI, X.; YANG, H. Research on the difference between

patients with coronary heart disease and healthy controls by surface enhanced Raman spectroscopy. **Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy**, Elsevier, v. 272, p. 120997, 2022.

6 SHARIATNIA, S.; ZIARATBAN, M.; RAJABI, A.; SALEHI, A.; ZARRINI, K. A.; VAKILI, M. Modeling the diagnosis of coronary artery disease by discriminant analysis and logistic regression: a cross-sectional study. **BMC medical informatics and decision making**, Springer, v. 22, n. 1, p. 85, 2022.

7 KHARYA, S.; AGRAWAL, S.; SONI, S. Naive Bayes classifiers: a probabilistic detection model for breast cancer. **Int. J. Comput. Appl**, v. 92, n. 10, p. 26–31, 2014.

8 BAFJAISH, S. S. Comparative analysis of naive bayesian techniques in health-related for classification task. **Journal of Soft Computing and Data Mining**, v. 1, n. 2, p. 1–10, 2020.

9 MORAES, J. L. de. **Desenvolvimento de um sistema para estratificação de cardiopatias utilizando a fotopletismografia (PPG)**. Dissertação (Mestrado) — Instituto Federal de educaçãa, ciência e tecnologia do ceara, 2017.