Creating an open-access, multimedia corpus for Norwegian Sign Language: A benefit to researchers and the deaf community

Prof. Lindsay Ferrara

Norwegian University of Science and Technology

20 October 2025; Open Access Week

NTNU

Outline

- Introduce the Norwegian Sign Language Corpus
- Collecting non-anonymized data in the age of GDPR
- Gaining consent and building trust with research participants/language users
- Creating open access resources that benefit both the academic community and the Norwegian deaf community

The Norwegian Sign Language Corpus
(2019-2025)

- The corpus is a group of four datasets:
  - 2012: Ph.D. dissertation research (Halvorsen, 2012)
  - 2015: Pilot corpus project (Ferrara & Bø, 2015)
  - 2017-2018: Project investigating spatial language (Ferrara & Ringsø, 2017-2018)
  - 2020-2025: Project to collect a more representative corpus (Ferrara 2024)

- Current size of the corpus:
  - 100+ signers
  - 60+ hours of signing
  - 650 video clips
  - 410 associated ELAN files
  - Various additional file(types)

Collecting non-anonymous + personal data

Consent process

- Consent is one important way that we can protect the interests of research participants/language users, in a respectful and ethical way.
  - Providing information in accessible language formats
  - Re-consent process for participants of earlier projects.

Vil du være med i et nytt prosjekt om norsk tegnspråk?

«Språkbruk i det norske døvemiljøet: et dypdykk i norsk tegnspråkøkologi»?

**Du finner denne informasjon og samtykke på norsk tegnspråk her: https://youtu.be/TpWbVTcU5Qs

Innledning og formål
Norsk tegnspråk er en del av den norske kulturarven, men det finnes foreløpig veldig lite forskning om dette språket. Vi er interessert i å forske på norsk tegnspråk slik at vi kan dokumentere og beskrive det. Målet med dette forskningsprosjektet er å forske på hvordan døve bruker norsk tegnspråk, og hvordan språkbruken gjenspeiler fysiske, sosiale og historiske forhold i et språkmiljø i endring.

For å kunne gjøre det skal vi utvikle to digitale ressursbanker for norsk tegnspråk: en korpussamling med et stort og representativt utvalg av språket og en utvidet (tegn-)ordbok (leksikalske database). Dette er viktig, både for døvesamfunnet, ulike fagmiljø og for det norske språkmangfoldet.

Materialet som samles inn og som skapes i dette prosjektet (videoopptak, bakgrunns- og personlig informasjon, transkripsjoner, osv.) kan bli nyttig i undervisning og i fremtidige prosjekter der man ser på norsk tegnspråk samt andre temaer som er relevant for døvemiljøet. Vi ber derfor om å få lagre data (videoopptak, bakgrunns- og personlig informasjon, transkripsjoner, osv.) i et korpus for norsk tegnspråk som kan brukes for all fremtid.

Hvem er ansvarlig for forskningsprosjektet?
Institutt for språk og litteratur på NTNU er ansvarlig for prosjektet.

Prosjektet ledes av Førsteamanuensis Lindsay Ferrara (NTNU), og hun samarbeider med kollegaer fra NTNU, OsloMet og Høgskulen på Vestlandet, samt Norges Døveforbund, Forening for Norsk Tegnspråk, og Språkrådet.

Hvorfor får du spørsmål om å delta?

Open data: benefitting research and language communities

Language community

- The data with a CC license can be used to create teaching materials for various deaf and hearing groups.
- Support the development of other language resources, like a dictionary.
- Documentation of one part of Norway's rich linguistic heritage

Research community

- The time-consuming and resource intensive annotation of signed language data is mitigated and minimized
- Language users avoid research fatigue
- Provides a sound, empirical base to a body of research studies

Thank you

lindsay.n.ferrara@ntnu.no